

Programação Inteira - lidar com a complexidade

Investigação Operacional

J.M. Valério de Carvalho
vc@dps.uminho.pt

Departamento de Produção e Sistemas
Escola de Engenharia, Universidade do Minho

28 de Dezembro de 2021

Programação Inteira (PI) - lidar com a complexidade

antes

- Vimos os métodos dos planos de corte e de partição e avaliação.

Guião

- O uso de procedimentos para encontrar soluções inteiras admissíveis de boa qualidade e de modelos mais fortes
- permite reduzir a carga computacional de resolução de um problema de PI no método de partição e avaliação.
- nota: a análise e os exemplos apresentados são de um problema de maximização. Para um problema de minimização, a análise é idêntica com os devidos ajustes.

A prática mostra que

- é possível resolver ou, pelo menos, obter soluções de boa qualidade para modelos de problemas reais complexos.

Lidar com a complexidade da Programação Inteira

- O problema de PI pertence à classe de problemas NP-completos: não é conhecido nenhum método de resolução 'eficiente'.
- Os métodos dos planos de corte e de partição e avaliação podem requerer, no pior caso, um esforço computacional exponencialmente grande em relação ao número de variáveis de decisão.
- Dada a complexidade do problema de PI, temos de aceitar que a solução óptima pode não ser encontrada em tempo razoável.

Vamos ver, no âmbito do método de partição e avaliação, métodos para

- 1 tentar reduzir o esforço computacional, e
- 2 avaliar a qualidade da melhor solução inteira admissível conhecida (quão próximo é o seu valor do valor da solução óptima).

Esforço computacional (problema de maximização)

- A redução do esforço computacional é tentada através do aumento da taxa de sucesso de abandono de nós da árvore de pesquisa.
- Um critério de abandono de um nó é não haver, nos seus descendentes, uma solução melhor do que a melhor solução inteira admissível conhecida:

Lembrete: na avaliação, o nó i pode ser abandonado se


- o valor $z_{PL}(i)$ da solução óptima de PL do nó i , $x_{PL}(i)$, for menor ou igual ao valor da melhor solução inteira admissível conhecida.

Para tentar aumentar a taxa de sucesso de abandono de nós, vamos

- procurar soluções inteiras admissíveis de boa qualidade,
- usar *modelos mais fortes* (com menor valor de $z_{PL}(i)$ do nó i).


Exemplo: avaliação do nó 9 (problema de maximização)

- Antes respondemos à questão: podemos abandonar o nó 9?



Exemplo: avaliação do nó 9 (problema de maximização)

- Antes respondemos à questão: podemos abandonar o nó 9?



- Sim, no nó 8 foi encontrada uma solução inteira admissível de valor 5 e, nos descendentes do nó 9, não existe nenhuma solução melhor.

Soluções de boa qualidade (problema de maximização)

- Para além das soluções inteiras obtidas na resolução dos problemas de PL dos nós da árvore de pesquisa, podemos recorrer a:
 - *Heurísticas* são procedimentos que geram soluções admissíveis \mathbf{x}_{heur} para um modelo, mas que podem não ser óptimas.
 - Caso o valor de uma solução heurística seja melhor ($z_{heur} \geq z_{SI}$), essa solução heurística passa a ser a solução incumbente.


Limite Inferior (LI) para o valor do óptimo:

- O valor z_{SI} da solução incumbente \mathbf{x}_{SI} é um *limite inferior (LI)* para o valor z_I^* da solução óptima inteira \mathbf{x}_I^* :

$$z_{SI} \leq z_I^*$$

- Há heurísticas de baixa complexidade (e.g., linear ou quadrática em função da dimensão dos dados do problema) ou muito elaboradas.

Exemplo



$$\begin{aligned} \max \quad & 2x_1 + 1x_2 \\ \text{sujeito a} \quad & 2x_1 + 2x_2 \leq 7 \\ & 2x_1 - 2x_2 \leq 5 \\ & x_1, x_2 \geq 0 \text{ e inteiros} \end{aligned}$$

Soluções admissíveis:

- do problema inteiro: círculos cheios.
- da *relaxação linear*: região delimitada a vermelho.

Soluções óptimas:

- do problema inteiro: $\mathbf{x}_I^* = (x_1, x_2)_I^T = (2, 1)^T \rightarrow z_{PI} = 5$ (●) ;
- da *relaxação linear*: $\mathbf{x}_{RL} = (x_1, x_2)_{RL}^T = (3, 0.5)^T \rightarrow z_{RL} = 6.5$ (★).

Heurística miópica (problema de maximização)

- uma a uma, sem atender às outras variáveis, atribuir à variável de decisão o valor inteiro (permitido pelos recursos ainda disponíveis) que otimiza a contribuição para a função objectivo.

Algoritmo 1 Heurística míópica (problema de maximização)

Input: $A, c \geq 0, b$

▷ modelo

for $j \leftarrow 1, n$ **do**

if $\exists x_i$ inteiro que respeite as restrições **then**

$x_j^h \leftarrow$ valor x_j inteiro que otimiza contribuição para o f. obj.

else

```
return Heurística falhou
```

end if

atualizar modelo fazendo a atribuição: $x_j \leftarrow x_j^h$

end for

return solução inteira admissível $\mathbf{x}_{heur} = (x_1^h, \dots, x_n^h)^\top$

Assume-se $c \geq 0$ para simplificar a apresentação da heurística.

Exemplo: aplicação da heurística miópica

$$\begin{array}{ll}\max & 2x_1 + 1x_2 \\ \text{sujeito a} & 2x_1 + 2x_2 \leq 7 \\ & 2x_1 - 2x_2 \leq 5 \\ & x_1, x_2 \geq 0 \text{ e inteiros}\end{array}$$

- $j \leftarrow 1$: atribuir a x_1 o valor 2 (o valor 3 violaria a segunda restrição); quando se fixa $x_1 = 2$, as restrições ficam $2x_2 \leq 3$ e $-2x_2 \leq 1$ (i.e., $2x_2 \geq -1$), respectivamente.
- $j \leftarrow 2$: atribuir a x_2 o valor 1.

- Solução heurística: $\mathbf{x}_{heur} = (2, 1)^T$, com valor $z_{heur} = 5$.
- Limite inferior para o valor do ótimo: $z_{heur} = 5 \leq z_I^*$.

Heurística de arredondamento (problema de maximização)

- arredondar (para cima/para baixo) os valores da solução óptima fraccionária, para construir uma solução inteira.

Algoritmo 2 Heurística de arredondamento (problema de maximização)

```

Input:  $\mathbf{x}^f = (x_1^f, \dots, x_n^f)^\top$ ;  $\mathbf{A}, \mathbf{c} \geq \mathbf{0}, \mathbf{b} \triangleright$  sol. óptima fraccionária; modelo
for  $j \leftarrow 1, n$  do
    if  $x_j = \lceil x_j^f \rceil$  for admissível then
         $x_j^h \leftarrow \lceil x_j^f \rceil$ 
    else if  $x_j = \lfloor x_j^f \rfloor$  for admissível then
         $x_j^h \leftarrow \lfloor x_j^f \rfloor$ 
    else
        return Heurística falhou
    end if
    atualizar modelo fazendo a atribuição:  $x_j \leftarrow x_j^h$ 
end for
return solução inteira admissível  $\mathbf{x}_{heur} = (x_1^h, \dots, x_n^h)^\top$ 

```

Exemplo: aplicação de heurística de arredondamento

max	$2x_1 + 1x_2$		x_1	x_2	s_1	s_2	
sujeito a	$2x_1 + 2x_2 \leq 7$	x_1	1	0	1/4	1/4	3
	$2x_1 - 2x_2 \leq 5$	x_2	0	1	1/4	-1/4	1/2
	$x_1, x_2 \geq 0$ e inteiros		0	0	3/4	1/4	6 1/2

- $j \leftarrow 1$: a variável x_1 é inteira;
quando se fixa $x_1 = 3$, as restrições ficam $2x_2 \leq 1$ e $-2x_2 \leq -1$ (i.e., $2x_2 \geq 1$), respectivamente.
 - $j \leftarrow 2$: A variável x_2 não pode ser arredondada para cima, nem para baixo; não há nenhum valor inteiro que obedeça às duas restrições.
 - A heurística falha, não produzindo uma solução admissível.
- Ambas as heurísticas são simples, de complexidade linear.
 - Heurísticas deste tipo são por vezes usadas em todos os nós da árvore de pesquisa.

Limite superior (problema de maximização)

Seja LS um *Limite Superior* para o valor do óptimo:

- Um LS é um valor para o qual é válida a seguinte relação:

$$z_I^* \leq LS.$$

- Não está associado a nenhuma solução inteira admissível.

Exemplos:

- o valor do óptimo da relaxação linear z_{RL} é um *limite superior* para o valor do óptimo inteiro z_I^* , dado que todas as soluções inteiras pertencem à relaxação linear do modelo.
- o mesmo para o valor da solução após adicionar planos de corte.

Qualidade da solução (problema de maximização)

- O método de partição e avaliação fornece também limites superiores.

O valor da solução óptima inteira (z_I^*) está contido no intervalo

$$z_I^* \in [LI, LS],$$

sendo LI (Limite Inferior) e LS (Limite Superior).

A *diferença (gap) de integralidade* (em %), dada por $(LS - LI)/LI$,

- é uma medida da qualidade da melhor solução inteira conhecida.
- Há a garantia de que a melhor solução inteira conhecida tem um valor que se aproxima do valor do óptimo a menos de uma percentagem igual ao *gap*.

Exemplo: limite superior (raiz da árvore)


max	$2x_1 + 1x_2$		x_1	x_2	s_1	s_2	
suj. a	$2x_1 + 2x_2 \leq 7$	x_1	1	0	1/4	1/4	3
	$2x_1 - 2x_2 \leq 5$	x_2	0	1	1/4	-1/4	1/2
	$x_1, x_2 \geq 0$ e inteiros		0	0	3/4	1/4	6 1/2

- O valor do óptimo inteiro $z_I^* \leq z_{RL} = 6 \frac{1}{2}$.
- Neste exemplo, é possível fixar um limite superior mais forte, $z_I^* \leq 6 = \lfloor 6 \frac{1}{2} \rfloor$, dado que z_I^* é necessariamente um valor inteiro, porque os coeficientes da função objectivo são inteiros e as variáveis de decisão têm de ser inteiras.
- As heurísticas e o LS podem ser obtidos após a resolução da relaxação linear do problema, permitindo obter a seguinte informação.

na raiz da árvore de pesquisa,

- $LS=6$ e a solução heurística (inteira e admissível) tem valor $5 = LI$.
 - O valor do ótimo inteiro $z_I^* \in [5, 6]$.
 - O $gap = (6 - 5) / 5 = 20\%$.
 - Há a garantia de que a solução inteira conhecida está a menos de 20% do ótimo (ou, em valor absoluto, a 1 unidade do ótimo).
-
- Quando $gap = 0$, o LS (num problema de maximização) prova que a solução incumbente (com o valor LI) é a solução ótima.
 - Podemos querer interromper a pesquisa quando o valor do gap é suficientemente pequeno.
-
- O uso de limites inferiores e superiores pode reduzir substancialmente o esforço computacional para encontrar uma solução ótima inteira.

Exemplo: resolução com LI e LS (prob. de maximização)



- 1 LS=6, LI=5
- 2 solução fraccionária, com valor 5; abandonar nó: nos descendentes, não há solução melhor do que $x_{heur} = (2, 1)^T$ com valor $z_{heur} = 5$.
- 3
- 4 solução fraccionária, com valor 5.5; $[5.5] = 5$; abandonar nó.
- 5 Impossível; ListaNós vazia; solução dada pela heurística é ótima.

Evolução do LS (problema de maximização)

O LS vai diminuindo à medida que se pesquisa a árvore:

- Seja A_k o conjunto de *nós em aberto* (nós que ainda falta avaliar) quando se avalia o nó k .
- O LS para o valor do óptimo inteiro é dado pelo maior valor de um nó em aberto quando se avalia o nó k :

$$LS = \max_{i \in A_k} \{z_{PL}(i)\},$$

- dado que potencialmente ainda podemos vir a encontrar uma solução inteira admissível com esse valor num descendente do nó que determina o valor de LS.
-
- Menores valores de LS aumentam a taxa de sucesso de abandono dos nós.

Modelos mais fortes (problemas de maximização)


Ideia a explorar:

- O LS é melhor se tivermos um modelo de PI cuja relaxação linear seja 'mais próxima' do conjunto de soluções inteiras admissíveis.
- Restrições equivalentes para o problema inteiro (com o mesmo domínio inteiro) podem ter domínios diferentes quando se relaxam as restrições de integralidade das variáveis.

Exemplo

- A restrição $2x_1 + 2x_2 \leq 6$ define o mesmo domínio inteiro (tem o mesmo conjunto de soluções inteiras admissíveis) que $2x_1 + 2x_2 \leq 7$.
- Os domínios das respectivas relaxações lineares são diferentes.

Exemplo de motivação



A primeira restrição $2x_1 + 2x_2 \leq 7$
do modelo pode ser substituída por:

$$\begin{array}{ll}\max & 2x_1 + 1x_2 \\ \text{sujeito a} & 2x_1 + 2x_2 \leq 6 \\ & 2x_1 - 2x_2 \leq 5 \\ & x_1, x_2 \geq 0 \text{ e inteiros}\end{array}$$

A solução óptima fraccionária $(3, 0.5)^T$ do modelo anterior não é admissível no novo modelo.

Soluções óptimas:

- do problema inteiro: $\mathbf{x}_I^* = (x_1, x_2)_I^T = (2, 1)^T \rightarrow z_{PI} = 5$ (●) ;
- da *relaxação linear*: $\mathbf{x}_{RL} = (x_1, x_2)_{RL}^T = (2.75, 0.25)^T \rightarrow z_{RL} = 5.75$ (★).

na raiz da árvore de pesquisa,

- O valor do óptimo inteiro $z_I^* \leq z_{RL} = 5.75$.
- Neste exemplo, é possível fixar um limite superior mais forte, $z_I^* \leq 5 = \lfloor 5.75 \rfloor$ (como vimos, z_I^* é necessariamente um valor inteiro).
- $LS=5$ e a solução heurística (inteira e admissível) tem valor $5 = LI$.
- O $gap = 0$: o LS comprova que a solução heurística é óptima.
- O problema fica resolvido na raiz da árvore de pesquisa.

Relaxação linear de um modelo de PI

- Um modelo de programação inteira (PI) têm a seguinte forma:

$$\begin{array}{ll}\max z_{PI} &= \mathbf{c}\mathbf{x} \\ \text{sujeito a} & \mathbf{A}\mathbf{x} \leq \mathbf{b} \\ & \mathbf{x} \geq \mathbf{0} \text{ e inteiro}\end{array}$$

- O domínio (conjunto de soluções admissíveis) do modelo PI é:

$$X_{PI} = \{\mathbf{x} \in \mathbb{Z}_+^n : \mathbf{A}\mathbf{x} \leq \mathbf{b}\}.$$

- O modelo de Programação Linear (PL) que resulta da relaxação das *restrições de integralidade* tem variáveis de decisão $\mathbf{x} \in \mathbb{R}_+^n$:

$$\begin{array}{ll}\max z_{RL} &= \mathbf{c}\mathbf{x} \\ \text{sujeito a} & \mathbf{A}\mathbf{x} \leq \mathbf{b} \\ & \mathbf{x} \geq \mathbf{0}\end{array}$$

- O domínio (conjunto de soluções admissíveis) da relaxação linear do modelo é:

$$X_{RL} = \{\mathbf{x} \in \mathbb{R}_+^n : \mathbf{A}\mathbf{x} \leq \mathbf{b}\}.$$

Relaxações lineares de diferentes modelos de PI

- Muitas vezes, existem diferentes formulações de um problema de PI.
- Qualquer modelo de PI é válido se o seu conjunto de soluções inteiras admissíveis for o X_{PI} desejado.
- Mas pode haver diferenças nas respectivas relaxações lineares.
- Sejam $X_{RL_1} \subseteq \mathbb{R}^n$ e $X_{RL_2} \subseteq \mathbb{R}^n$ os domínios das relaxações lineares de dois modelos de PI válidos.
- Ambas as relaxações lineares contêm o mesmo conjunto de soluções inteiras admissíveis:


$$X_{PI} = X_{RL_1} \cap \mathbb{Z}_+^n = X_{RL_2} \cap \mathbb{Z}_+^n.$$

Um modelo de PI é mais forte

- se o domínio da sua relaxação linear X_{RL_1} estiver contido no domínio da relaxação linear do outro modelo, com um domínio X_{RL_2} :

$$X_{RL_1} \subset X_{RL_2}.$$

Exemplo



- O modelo mais forte de todos é o que tem uma relaxação linear cujos vértices são soluções inteiras admissíveis;
- o domínio dessa relaxação linear designa-se por *envolvente convexa* do domínio inteiro (um conjunto discreto de pontos).

Algumas formas de tornar os modelos mais fortes

- aumento de coeficientes em restrições do tipo \leq .
 - redução de coeficientes em restrições do tipo \geq .
 - desagregação de restrições
 - restrições de clique e de ciclo
-
- Muitos dos exemplos que se seguem usam variáveis binárias.
 - na relaxação linear, substitui-se x_j binário por $0 \leq x_j \leq 1$.

Aumento de Coeficientes (*coefficient lifting*)

- Se o coeficiente de uma variável puder ser aumentado de uma quantidade que não altera o conjunto de soluções inteiras admissíveis, a restrição resultante é mais forte.

Exemplo

- Restrição com variáveis binárias $7x_1 + 8x_2 + 9x_3 \leq 12$.
- Todos os coeficientes das variáveis podem ser aumentados para 12, porque, se qualquer uma das variáveis tomar o valor 1, as outras variáveis devem ser nulas.
- A restrição é equivalente a $x_1 + x_2 + x_3 \leq 1$.
- O conjunto de soluções 0-1 das duas restrições é o mesmo.

- Se uma restrição se tornar redundante quando uma das variáveis binárias é fixada num dos seus limites,
- o coeficiente dessa variável pode ser reduzido de uma quantidade igual ao valor pelo qual a restrição se tornou redundante.

Exemplo

- Restrição com variáveis binárias $3x_1 + x_2 + x_3 \geq 2$.
- Se a variável x_1 for fixada em 1, a restrição torna-se redundante.
- O coeficiente de x_1 pode ser reduzido para o valor 2, passando a restrição a ser $2x_1 + x_2 + x_3 \geq 2$.
- O conjunto de soluções 0-1 das duas restrições é igual.

Desagregação de restrições (*constraint disaggregation*)

- Restrições agregadas originam modelos mais fracos.
- Do ponto de vista computacional, é preferível ter um número de restrições mais elevado, para obter uma relaxação linear mais forte.

Exemplo

- Restrições com variáveis binárias:

$$x_{1A} \leq y_A$$

$$x_{2A} \leq y_A$$

- A restrição agregada $x_{1A} + x_{2A} \leq 2y_A$ é válida, mas mais fraca que as duas restrições em conjunto (porquê?)
- Este tipo de restrições ocorre, e.g., em problemas de localização.
- A primeira restrição traduz uma implicação: atribuir o cliente 1 ao servidor A implica a implantação do servidor A; idem para a segunda.
- A restrição agregada também: atribuir, pelo menos, um dos clientes ao servidor A implica a implantação do servidor A.

- É largamente reconhecido que o uso de modelos fortes se traduz em melhorias substanciais dos tempos de computação.
- Os *solvers* de PI fazem um pré-processamento dos modelos que lhes são submetidos, que inclui, entre outras, as operações apresentadas.
- O objectivo é estabelecer limites mais apertados para os valores das variáveis, ou mesmo a fixação do seu valor, obtendo modelos mais fortes e com menos variáveis.

Outras técnicas de obtenção de formulações mais fortes

- Há formulações que são mais fortes, mas que podem ter um número exponencial de variáveis.
- Há técnicas para resolver estes modelos sem haver necessidade de gerar todas as variáveis possíveis.
- Este tipo de modelos é usado, por exemplo, em encaminhamento de veículos (*vehicle routing*) e corte e empacotamento (*cutting and packing*).

- Nas últimas décadas, desenvolvimentos teóricos (modelos mais fortes) e o aumento da capacidade de computação têm permitido resolver instâncias de dimensão cada vez maior.
- A programação inteira é hoje em dia usada rotineiramente para encontrar soluções para problemas reais complexos em muitas indústrias e serviços.
- Geralmente, é possível obter, em tempos razoáveis, soluções inteiras óptimas, ou então soluções com diferenças (*gaps*) de integralidade inferiores a 5%, muitas vezes de 1% ou 2%.
- O valor de *gap* é uma garantia da qualidade das soluções!
- Formulação mais forte produz um melhor valor do limite superior (inferior) para o valor do óptimo do problema de programação inteira de maximização (minimização).
- Qualidade da formulação é mais importante do que a dimensão da formulação (número de variáveis ou restrições).

- Inequações válidas para o PI

Inequações válidas para o problema inteiro

- Há também *inequações válidas para o problema inteiro* que podem ser obtidas a partir de um conjunto de restrições do modelo original.
- Adicioná-las ao modelo, tornam-no mais forte.
- Exemplo: restrições que representam um conflito entre os vértices i e j , de um grafo $G = (V, A)$.

Exemplo 1: inequações de clique:

- Uma clique K_p é um subgrafo completo com p vértices.

$$\sum_{i \in K_p} x_i \leq 1$$

Exemplo 2: inequações de ciclos ímpares (*odd holes*) :

- Um ciclo C_p com um número de vértices ímpar p .

$$\sum_{i \in C_p} x_i \leq \lfloor p/2 \rfloor$$


Inequações válidas para o problema de empacotamento

Problema de empacotamento (*set packing problem*)

$$\max\{\mathbf{c}\mathbf{x} : \mathbf{A}\mathbf{x} \leq \mathbf{1}, \mathbf{x} \in \{0,1\}^n\}, \text{ sendo } \mathbf{A} \in \{0,1\}^{m \times n}.$$

- Exemplo:

	x_1	x_2	x_3	x_4	x_5	x_6	x_7	
1	1	1	1				1	≤ 1
2	1			1	1			≤ 1
3		1		1		1	1	≤ 1
4			1		1	1	1	≤ 1
solução: 0.33 0.33 0.33 0.33 0.33 0.33								



Inequação para a clique K_4 :

- $x_1 + x_2 + x_3 + x_4 + x_5 + x_6 \leq 1$


Inequações válidas para o problema de empacotamento

Problema de empacotamento *Set packing problem*

$$\max\{\mathbf{c}\mathbf{x} : \mathbf{A}\mathbf{x} \leq \mathbf{1}, \mathbf{x} \in \{0,1\}^n\}, \text{ sendo } \mathbf{A} \in \{0,1\}^{m \times n}.$$

- Exemplo:

	x_1	x_2	x_3	x_4	x_5	x_6	x_7	
1	1	1		1			1	≤ 1
2		1	1		1		1	≤ 1
3	1		1			1	1	≤ 1
solução: 0.5 0.5 0.5								



- A inequação válida é mais forte, porque a soma das restrições:

$$\begin{array}{rrcrcl} 2x_1 & +2x_2 & +2x_3 & \leq & 3 \\ x_1 & + x_2 & + x_3 & \leq & 3/2 \\ x_1 & + x_2 & + x_3 & \leq & 1 \end{array}$$

Inequação para o ciclo C_3 :

- $x_1 + x_2 + x_3 \leq 1$

