Universidade do Minho
Departamento de Informática

APRENDIZAGEM E DECISÃO INTELIGENTES

LEI/MiEI @ 2022/2023, 2º sem [ADI^3]

ISLab
Synthetic Intelligence Lab

Agenda

- Sistemas de aprendizagem conexionistas
- Redes Neuronais Artificiais
- Resolução de problemas com RNA
- Treino de RNA

ISLab
Synthetic Intelligence Lab

Aprendizagem Automática (*Machine Learning*)

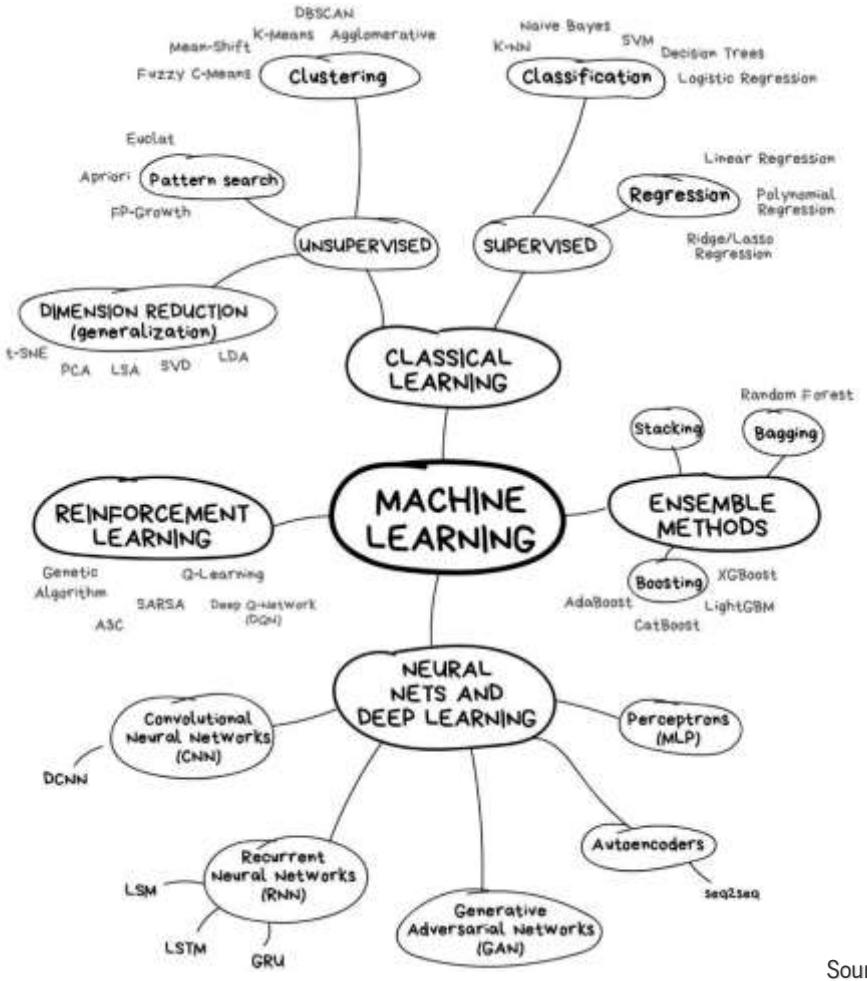

Source: The map of the machine learning world
Vasily Zubarev (vas3k.com)

ISLab
Synthetic Intelligence Lab

Redes Neuronais Artificiais

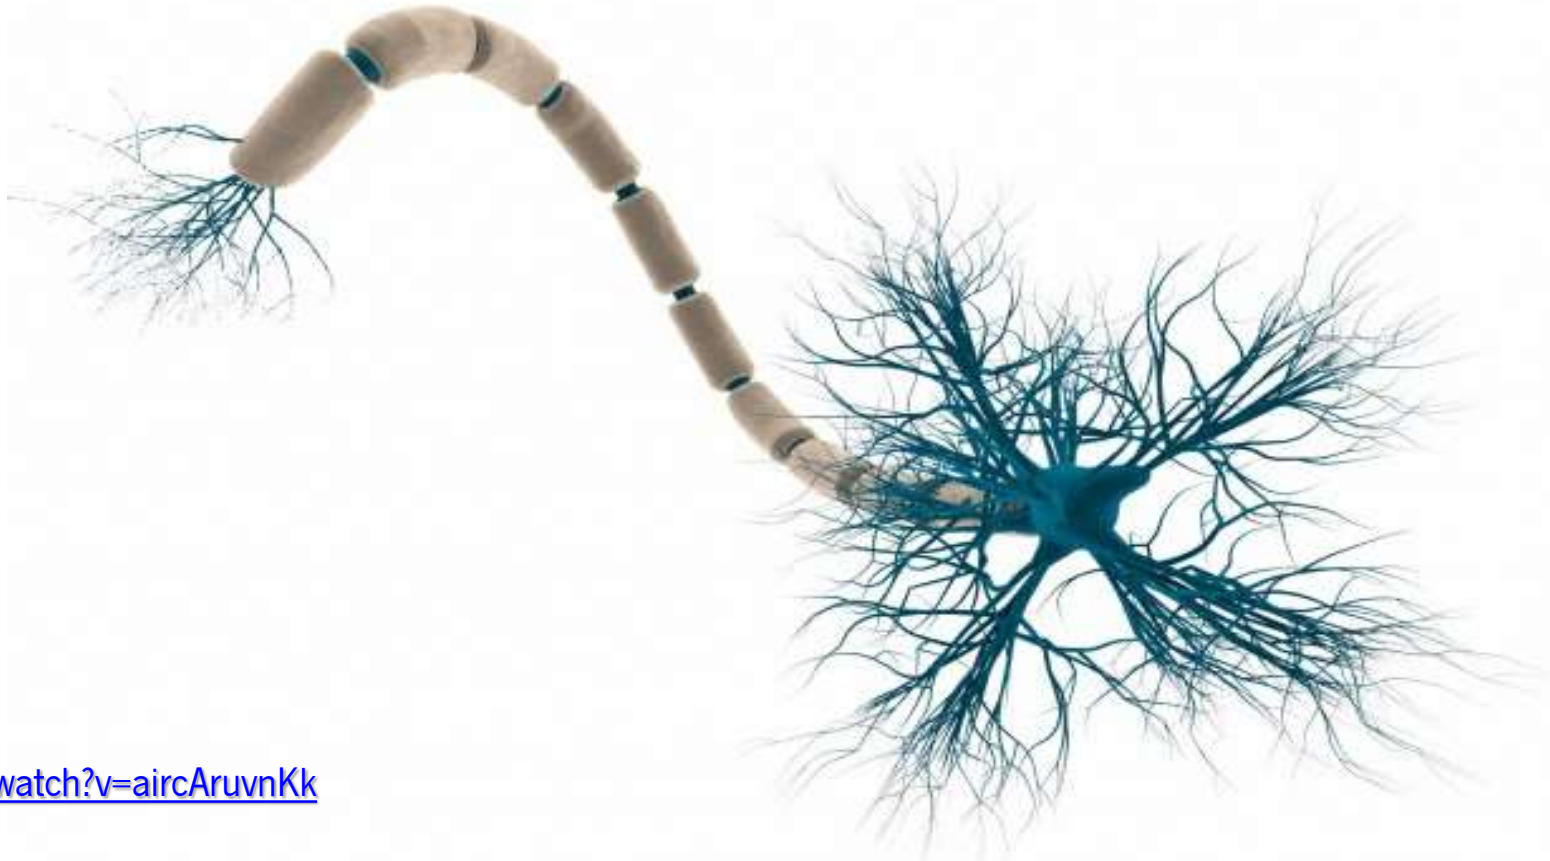

www.youtube.com/watch?v=aircAruvnKk

ISLab
Synthetic Intelligence Lab

Evolução
Redes Neuronais Artificiais

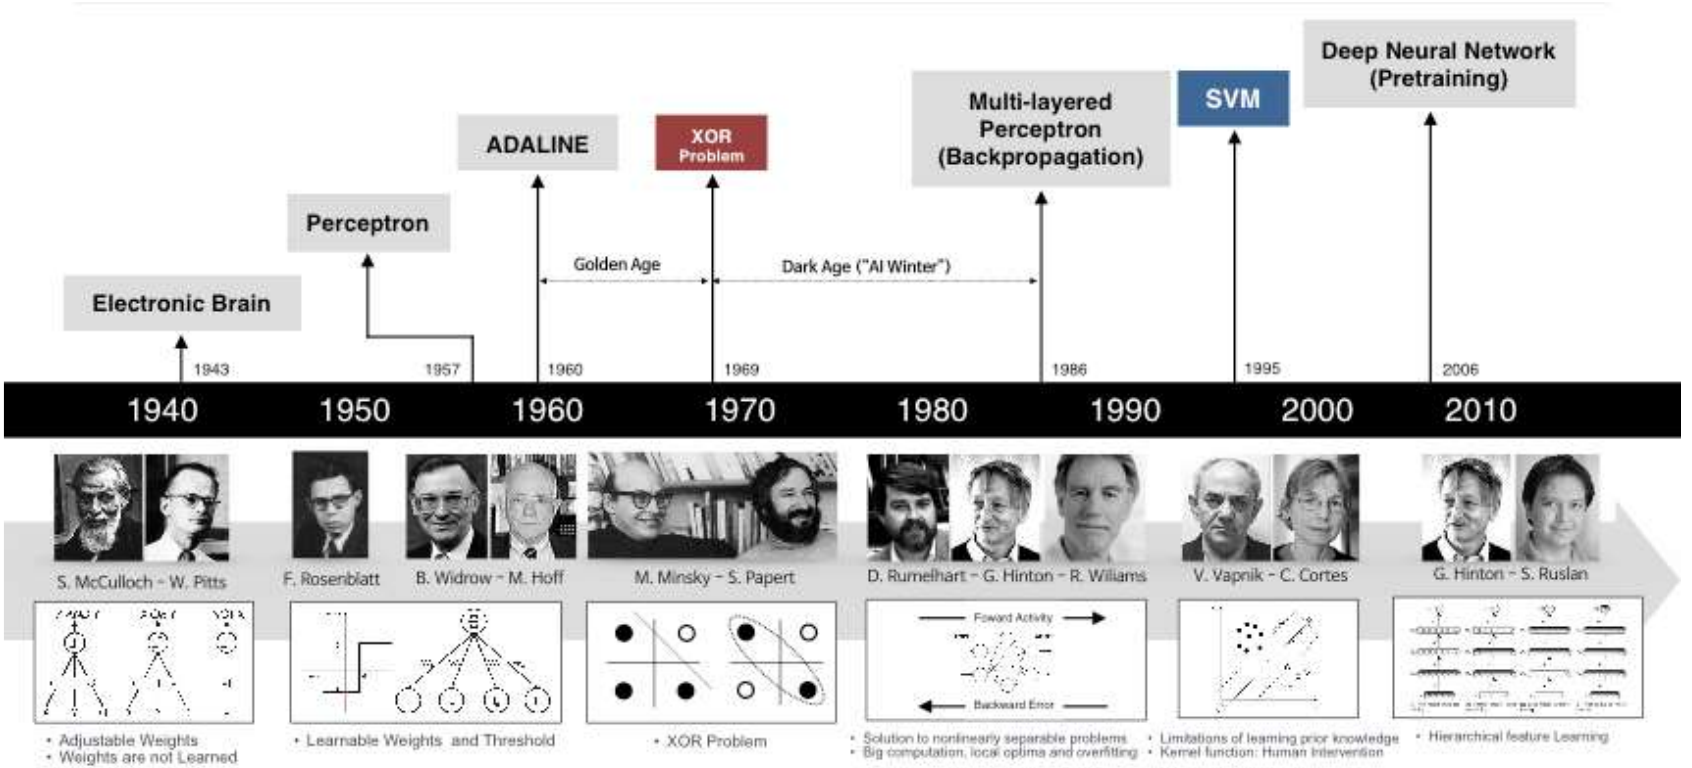

github.com/qingkaikong/20161202_ANN_basics

ISLab
Synthetic Intelligence Lab

Definição
Redes Neuronais Artificiais

- Uma **Rede Neuronal Artificial** (RNA) é um sistema computacional de base conexionista para a resolução de problemas.
- Uma RNA é concebida com base num **modelo** simplificado **do sistema nervoso central** dos seres humanos.
- Uma RNA é definida por uma estrutura interligada de unidades computacionais, designadas **neurónios**, com capacidade de **aprendizagem**.

support.bccvl.org.au/support/solutions/articles/(...)-artificial-neural-network

ISLab
Synthetic Intelligence Lab

Definição
Redes Neuronais Artificiais

- Uma **Rede Neuronal Artificial** (RNA) é um sistema computacional de base conexionista para a resolução de problemas.
- Uma RNA é concebid
- Uma RNA é definida p
capacidade de **apren**

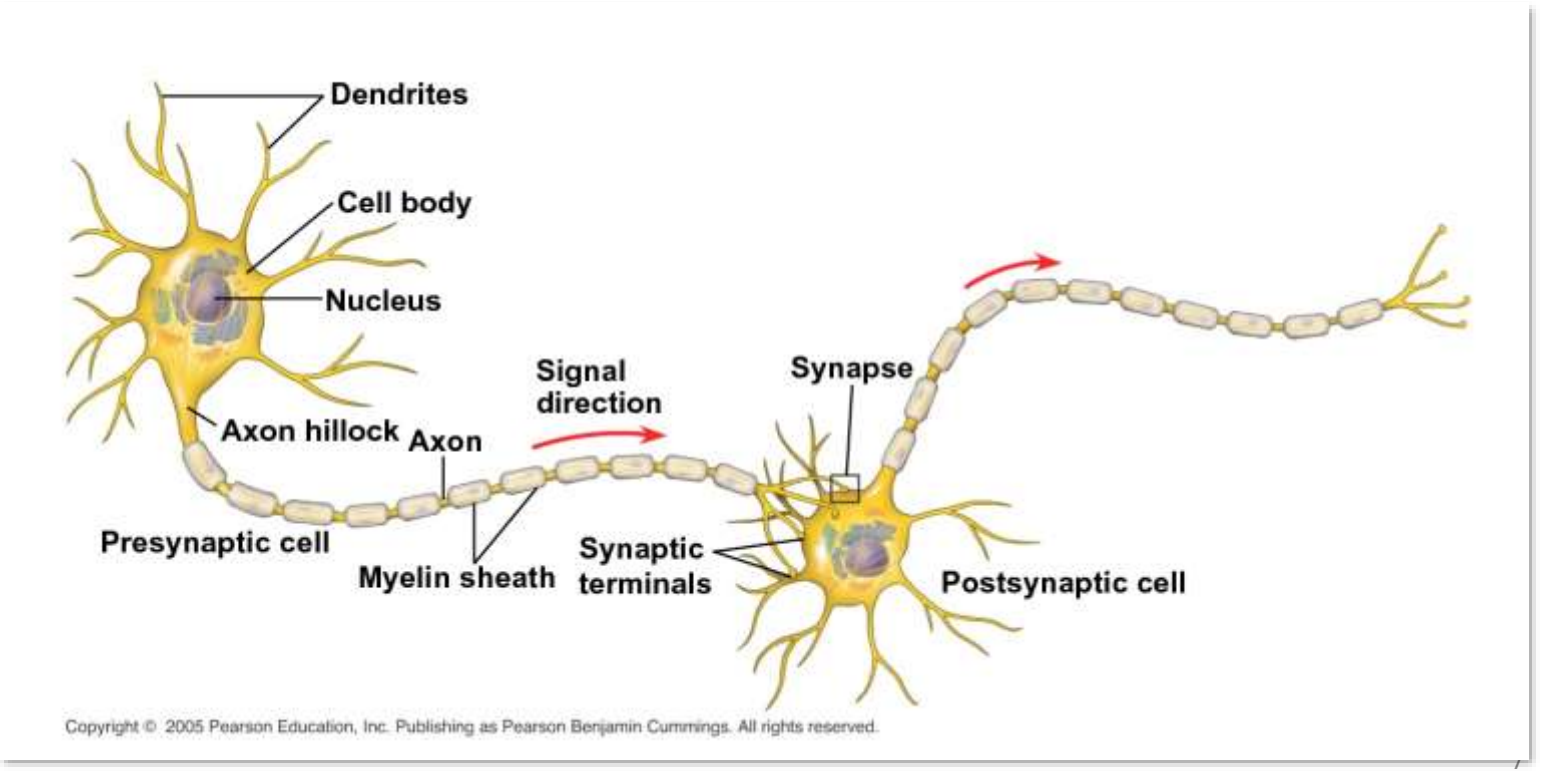

ISLab
Synthetic Intelligence Lab

Definição
Redes Neuronais Artificiais

- Uma **Rede Neuronal Artificial** (RNA) é um sistema computacional de base conexionista para a resolução de problemas.
- Uma RNA é concebida com base num **model**
- Uma RNA é definida por uma estrutura interli
capacidade de **aprendizagem**.

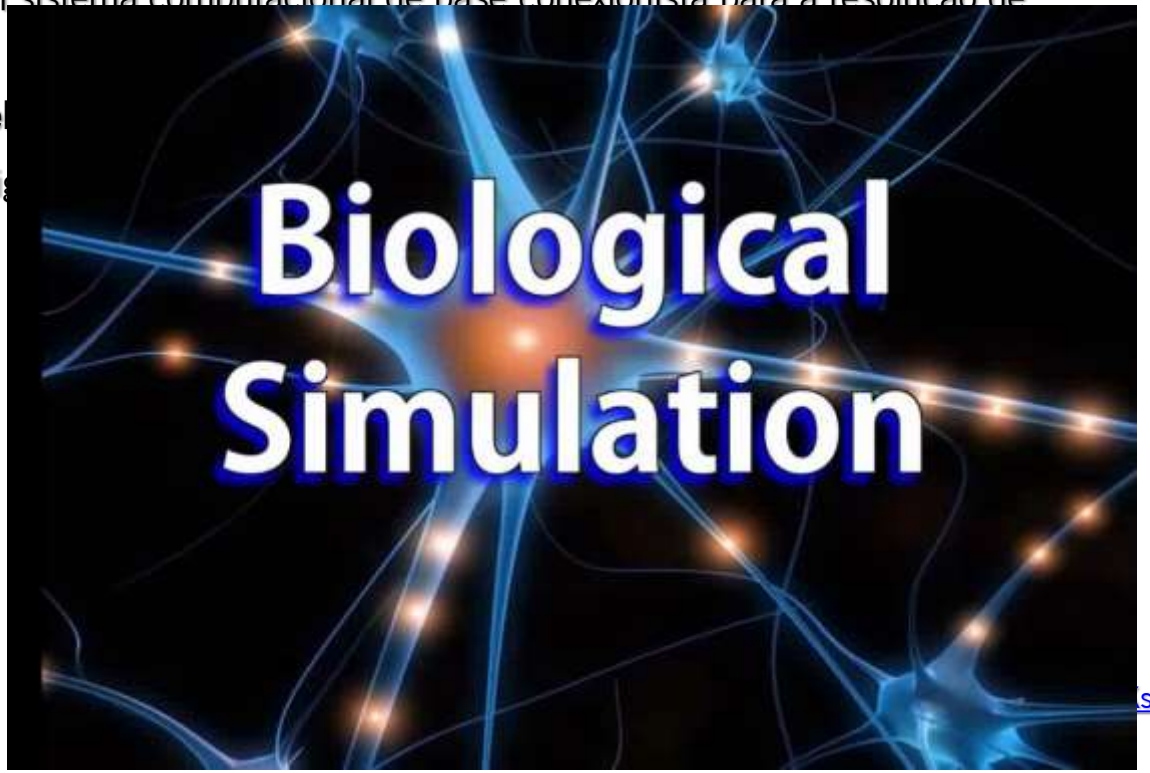

sLA

ISLab
Synthetic Intelligence Lab

Por onde andam?
Redes Neuronais Artificiais

- Reconhecimento de carateres
- Deteção de fraudes
- Reconhecimento de áudio/vídeo

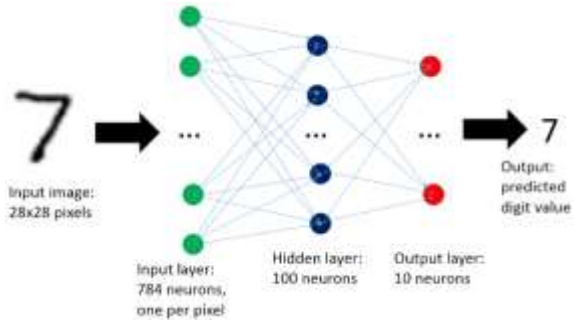

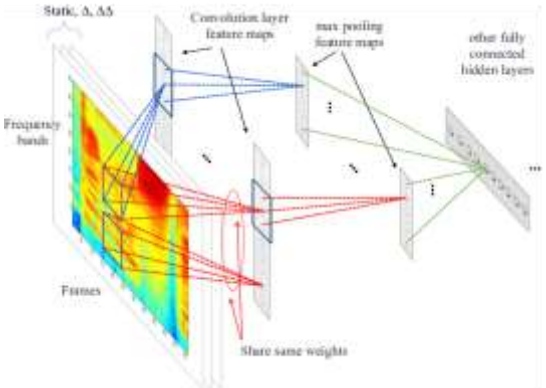

ISLab
Synthetic Intelligence Lab

Por onde andam?
Redes Neuronais Artificiais

www.boredpanda.es/ algoritmo-aprendizaje-profundo-imita-pintura-maestros/ ...

www.deepmind.com/ blog/ alphago-zero-starting-from-scratch

ISLab
Synthetic Intelligence Lab

Por onde andam?
Redes Neuronais Artificiais

- **AlphaGO (Google DeepMind)**
  - A partida entre Lee Sedol (o campeão do mundo de GO) e a máquina não correu bem (para o ele!);
  - GO é um jogo para 2 participantes, similar ao xadrez mas bastante mais complexo;
  - AlphaGO combina *deep neural networks* (avaliação) e algoritmos de procura Monte Carlo (seleção), numa combinação de paradigmas de aprendizagem supervisionada e por reforço.

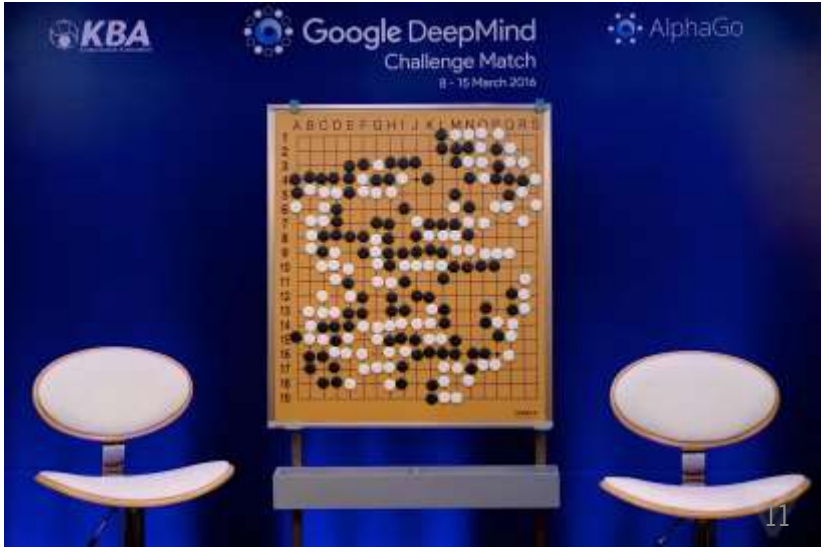

ISLab
Synthetic Intelligence Lab

Por onde andam?
Redes Neuronais Artificiais

- **AlphaGO (Google DeepMind)**
  - A partida entre Lee Sedol (o campeão do mundo de GO) e a máquina não correu bem (para o ele!);
  - GO é um jogo para 2 participan
  - AlphaGO combina *deep neural* Monte Carlo (seleção), numa cc aprendizagem supervisionada e

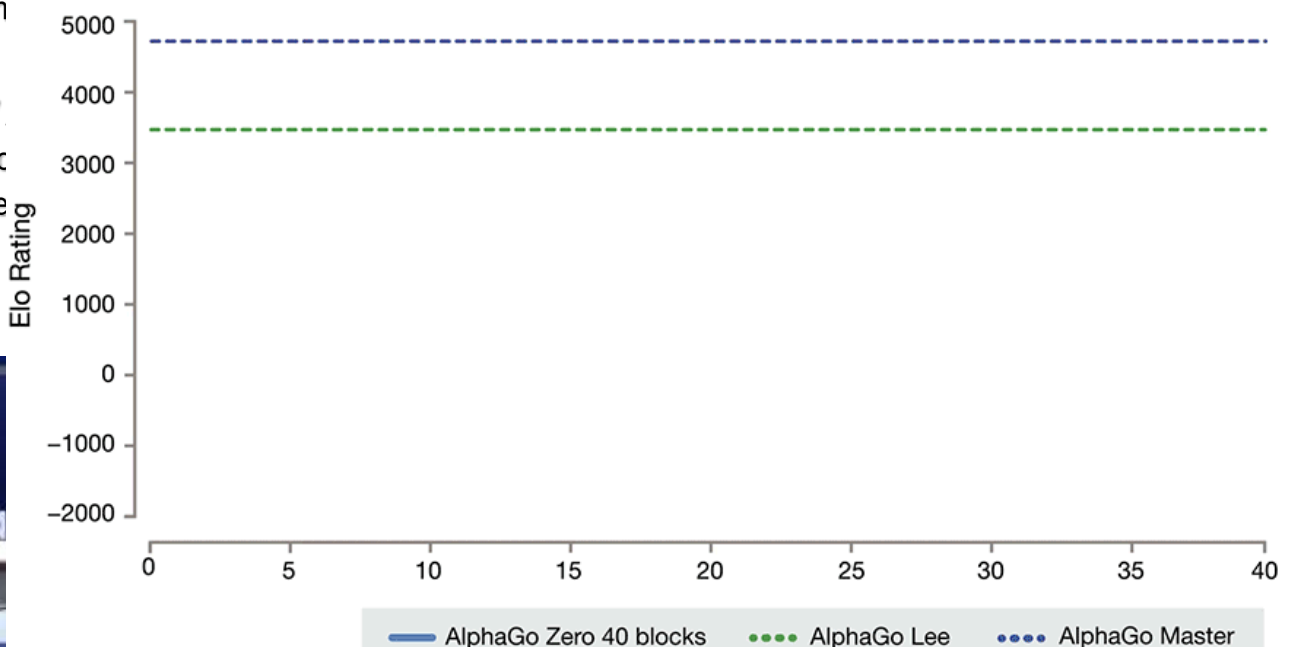

ISLab
Synthetic Intelligence Lab

O cérebro humano

- 100.000.000.000 neurónios
- 10.000 entradas por neurónio
- 1 sinal eletroquímico em cada neurónio
- Neurónios são conectados através de neurotransmissores químicos (dopamina, serotonina, glutamato ↑, gama-aminobutírico ↓)

- Representa 2% da massa do corpo humano
- Recebe 25% do sangue bombeado pelo coração

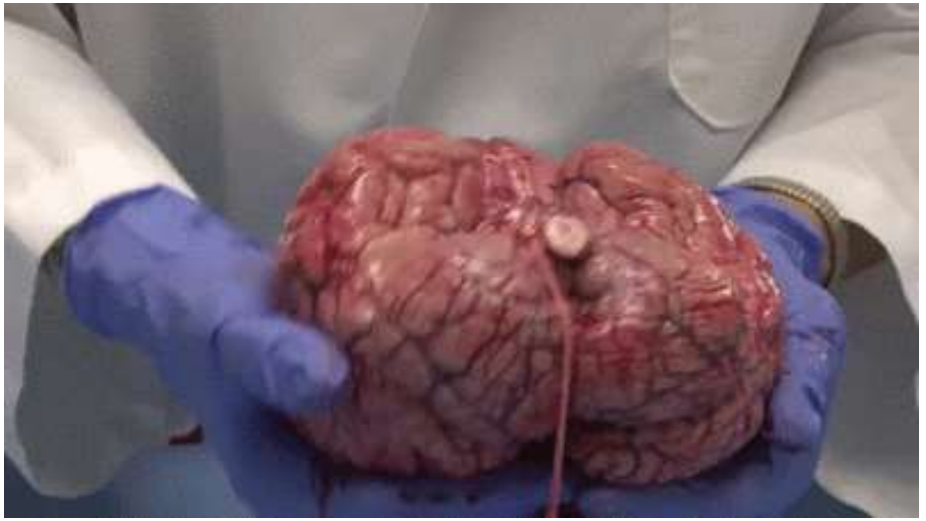

ISLab
Synthetic Intelligence Lab

O “cérebro” artificial

- Perceptron (por volta de 1960)

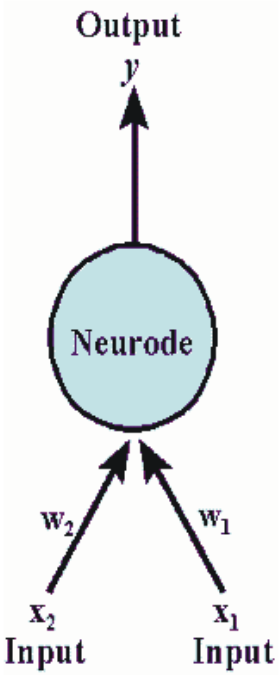

web.csulb.edu/~cwallis/artificialn/History.htm

ISLab
Synthetic Intelligence Lab

O “cérebro” artificial

- Perceptron (por volta de 1960)

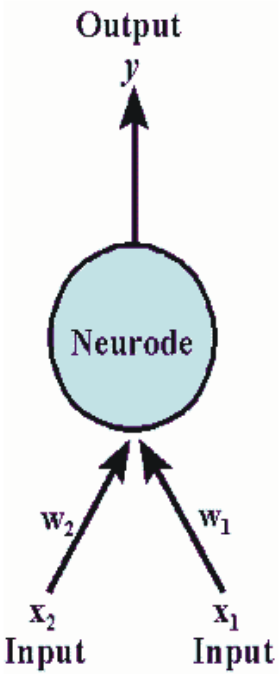

web.csulb.edu/~cwallis/artificialn/History.htm

- Função linear

p	q	and
𝕍	𝕍	𝕍
𝕍	𝔽	𝔽
𝔽	𝕍	𝔽
𝔽	𝔽	𝔽

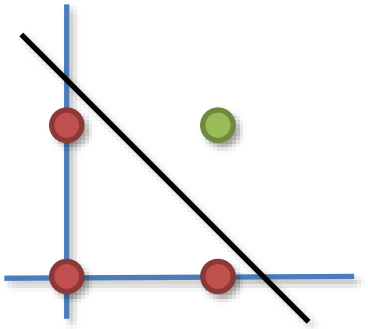

ISLab
Synthetic Intelligence Lab

O “cérebro” artificial

- Perceptron (por volta de 1960)

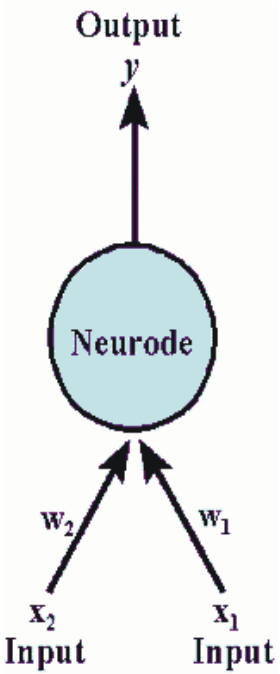

web.csulb.edu/~cwallis/artificialn/History.htm

- Função linear

p	q	or
𝕍	𝕍	𝕍
𝕍	𝔽	𝕍
𝔽	𝕍	𝕍
𝔽	𝔽	𝔽

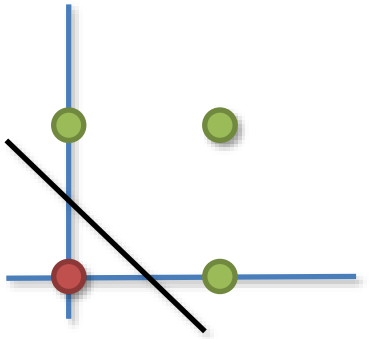

ISLab
Synthetic Intelligence Lab

O “cérebro” artificial

- Perceptron (por volta de 1960)

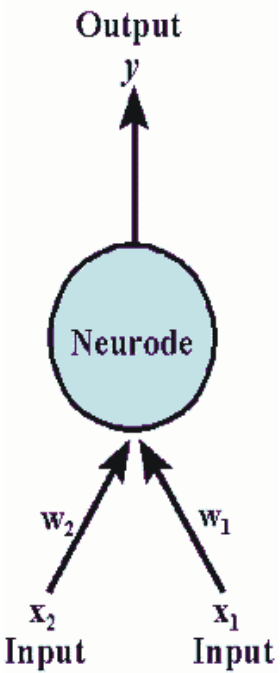

web.csulb.edu/~cwallis/artificialn/History.htm

- Função linear

p	q	or
𝕍	𝕍	𝕍
𝕍	𝔽	𝕍
𝔽	𝕍	𝕍
𝔽	𝔽	𝔽

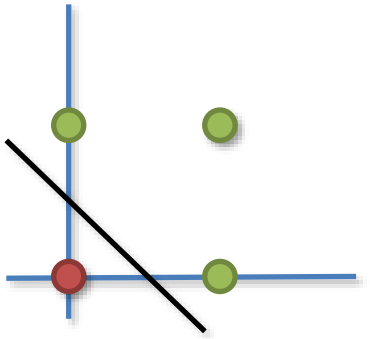

p	q	xor
𝕍	𝕍	𝔽
𝕍	𝔽	𝕍
𝔽	𝕍	𝕍
𝔽	𝔽	𝔽

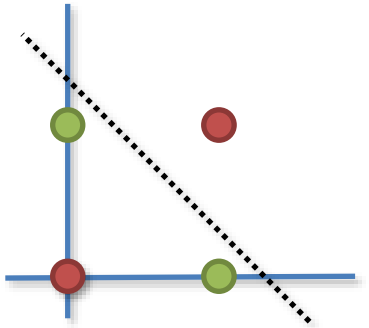

ISLab
Synthetic Intelligence Lab

O “cérebro” artificial

- Perceptron (por volta de 1960)

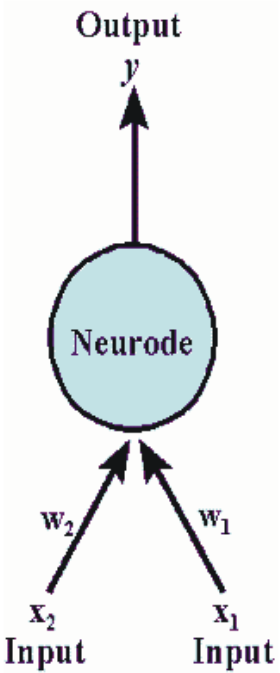

web.csulb.edu/~cwallis/artificialn/History.htm

- Função linear

p	q	or
𝕍	𝕍	𝕍
𝕍	𝔽	𝕍
𝔽	𝕍	𝕍
𝔽	𝔽	𝔽

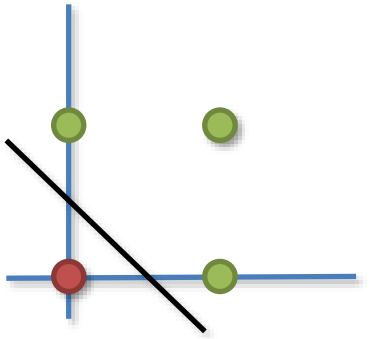

p	q	xor
𝕍	𝕍	𝔽
𝕍	𝔽	𝕍
𝔽	𝕍	𝕍
𝔽	𝔽	𝔽

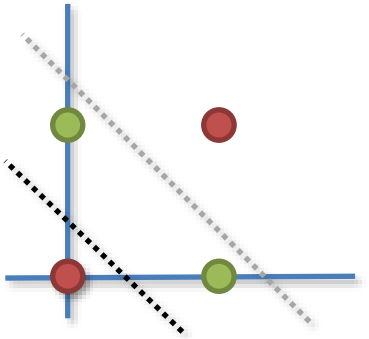

ISLab
Synthetic Intelligence Lab

O “cérebro” artificial

- Perceptron (por volta de 1960)

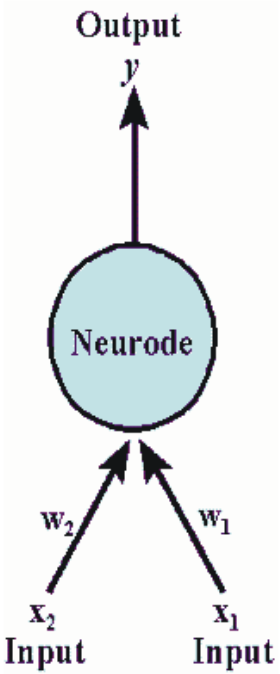

web.csulb.edu/~cwallis/artificialn/History.htm

- Função linear

p	q	or
𝕍	𝕍	𝕍
𝕍	𝔽	𝕍
𝔽	𝕍	𝕍
𝔽	𝔽	𝔽

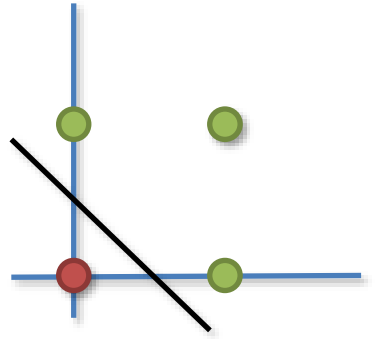

p	q	xor
𝕍	𝕍	𝔽
𝕍	𝔽	𝕍
𝔽	𝕍	𝕍
𝔽	𝔽	𝔽

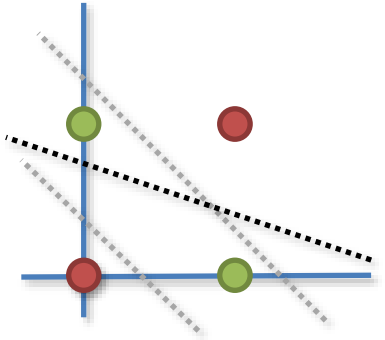

ISLab
Synthetic Intelligence Lab

O “cérebro” artificial

- Perceptron (por volta de 1960)

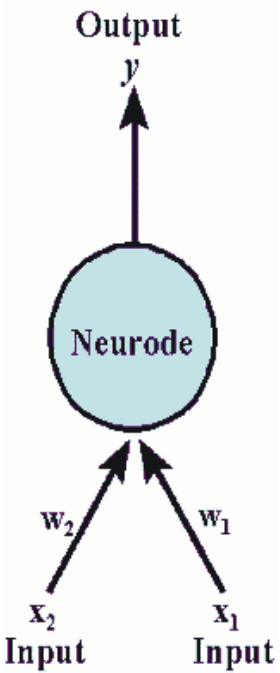

web.csulb.edu/~cwallis/artificialn/History.htm

- Função linear

p	q	or
𝕍	𝕍	𝕍
𝕍	𝔽	𝕍
𝔽	𝕍	𝕍
𝔽	𝔽	𝔽

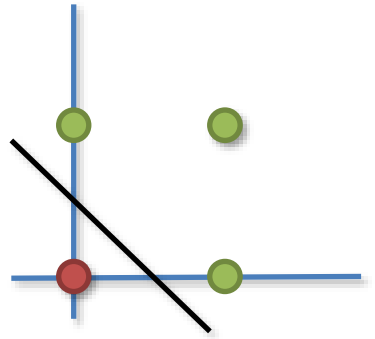

p	q	xor
𝕍	𝕍	𝔽
𝕍	𝔽	𝕍
𝔽	𝕍	𝕍
𝔽	𝔽	𝔽

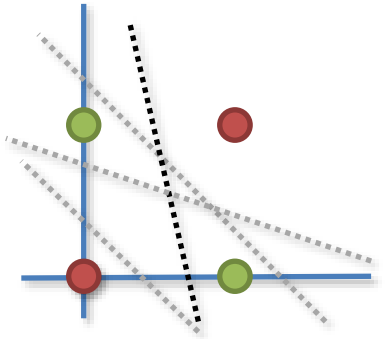

ISLab
Synthetic Intelligence Lab

O “cérebro” artificial

ISLab
Synthetic Intelligence Lab

Problema: XOR

p	q	xor
1	1	0
1	0	1
0	1	1
0	0	0

- Função de ativação:
  $\mathcal{F}_A = \sum$ entradas x pesos

- Função de transferência:

$f_T =$

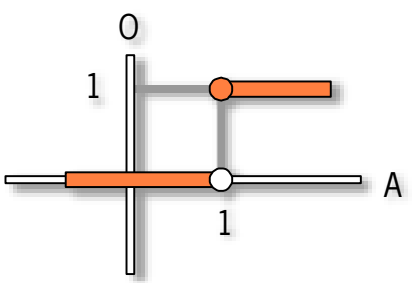

ISLab
Synthetic Intelligence Lab

Problema: XOR
Perceptron

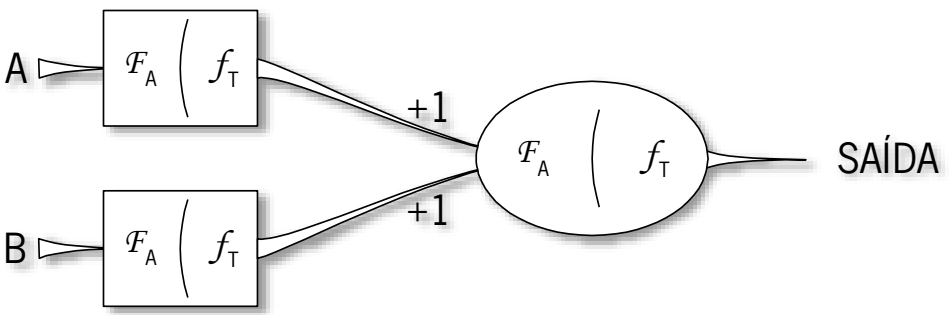

$\mathcal{F}_A$ = $\sum$ entradas x pesos

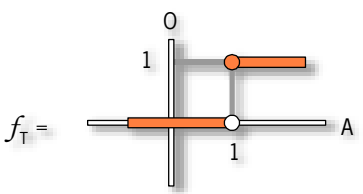

ISLab
Synthetic Intelligence Lab

Problema: XOR
Perceptron

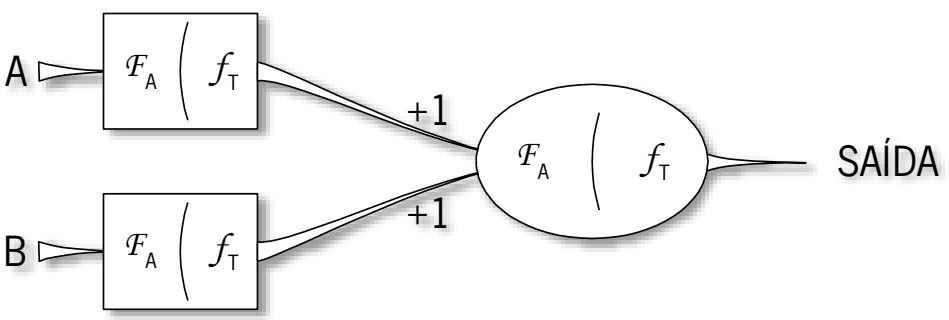

p	q	xor
1	1	1
1	0	1
0	1	1
0	0	0

$\mathcal{F}_A = \sum$ entradas x pesos

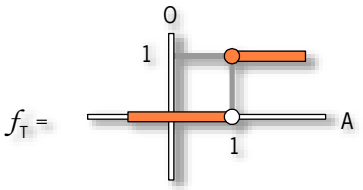

ISLab
Synthetic Intelligence Lab

Problema: XOR
Multi-layer Perceptron

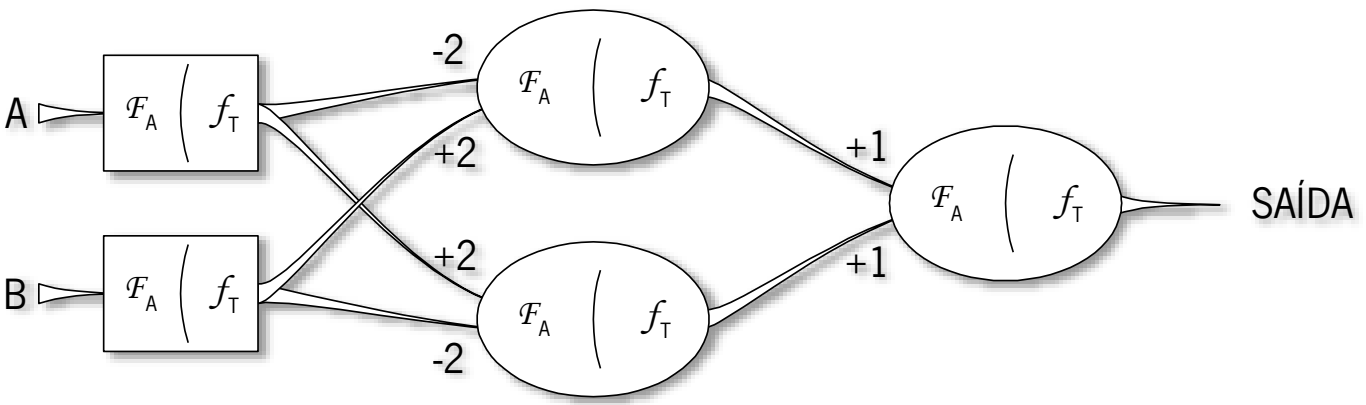

$\mathcal{F}_A$ = $\sum$ entradas x pesos

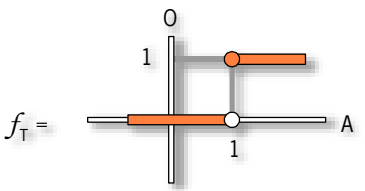

ISLab
Synthetic Intelligence Lab

Problema: XOR
Multi-layer Perceptron

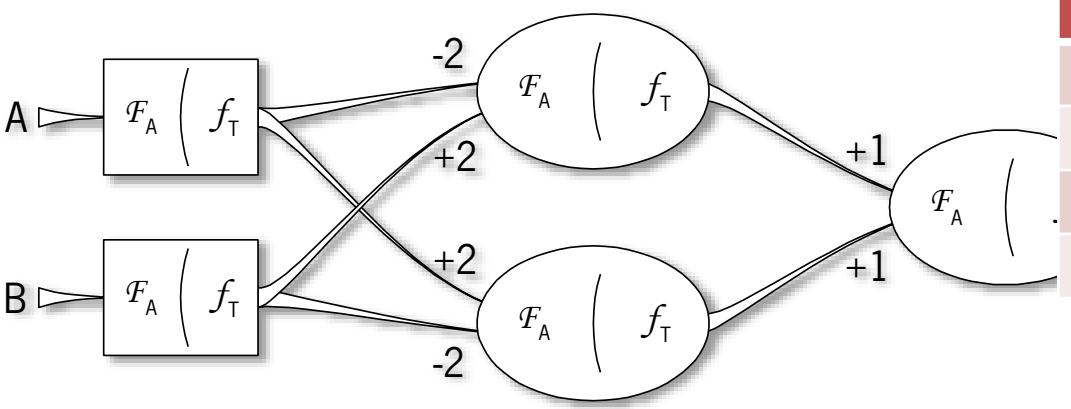

p	q	xor
1	1	0
1	0	1
0	1	1
0	0	0

$\mathcal{F}_A$ = $\sum$ entradas x pesos

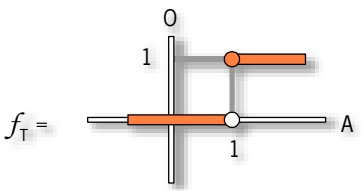

Conceitos e definições

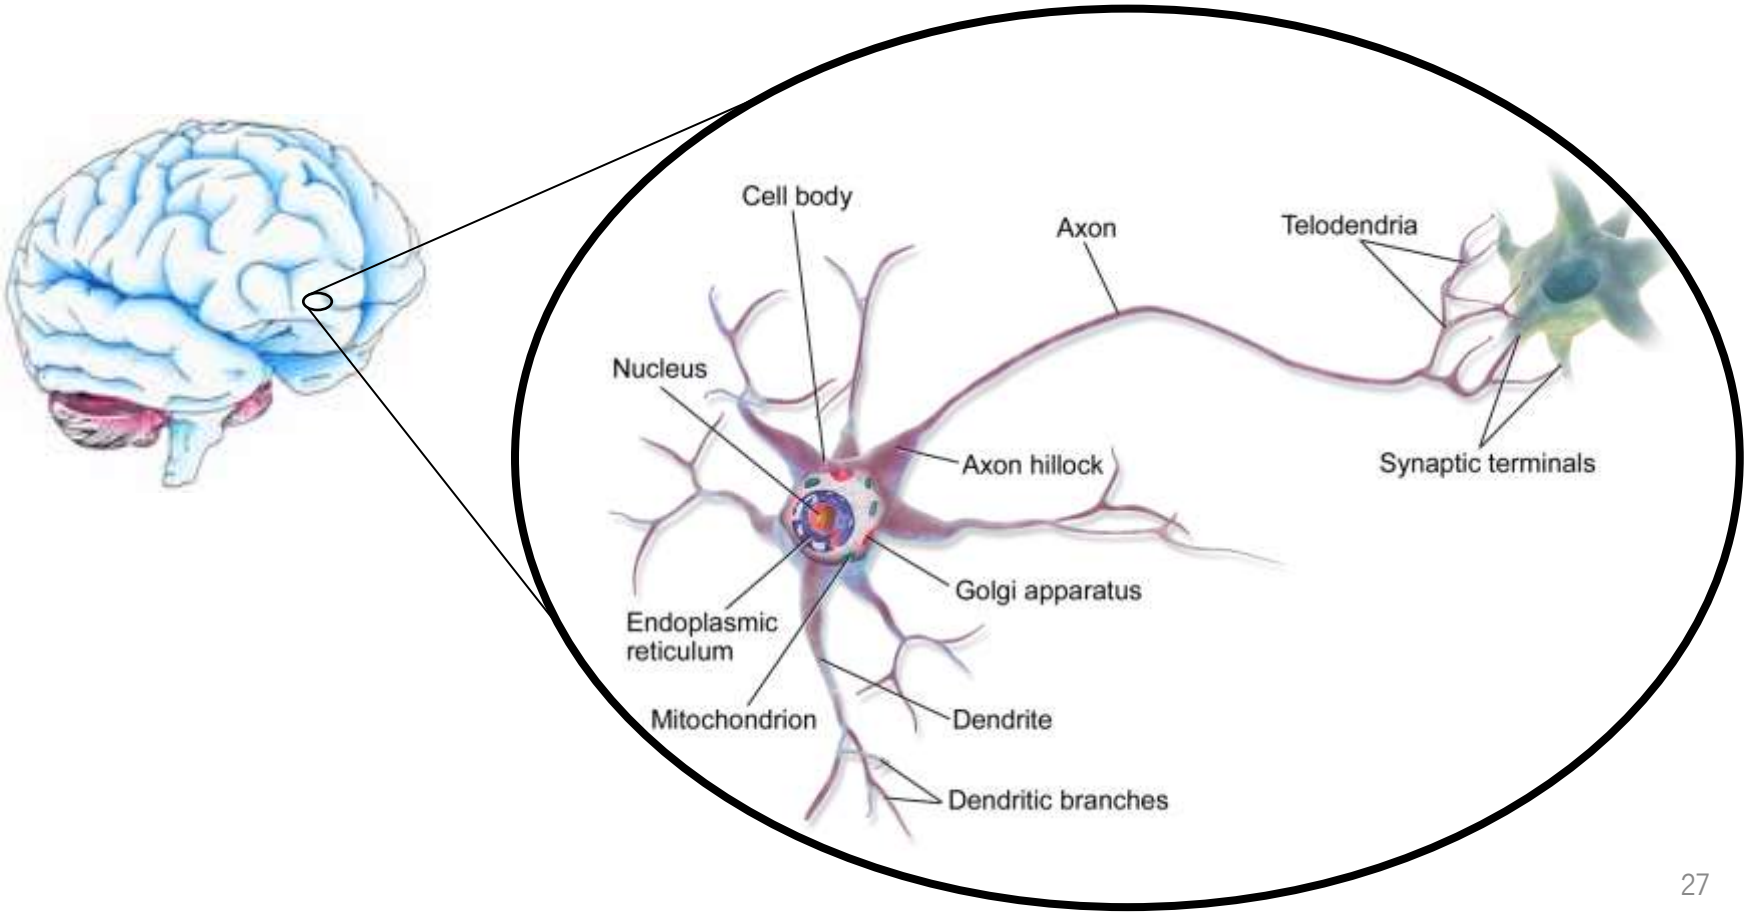

ISLab
Synthetic Intelligence Lab

Conceitos e definições
Neurónio

- **Unidade computacional** de composição da RNA.
- **Identificado** pela sua **posição** na rede.
- Caracterizado pelo **valor do estado**.

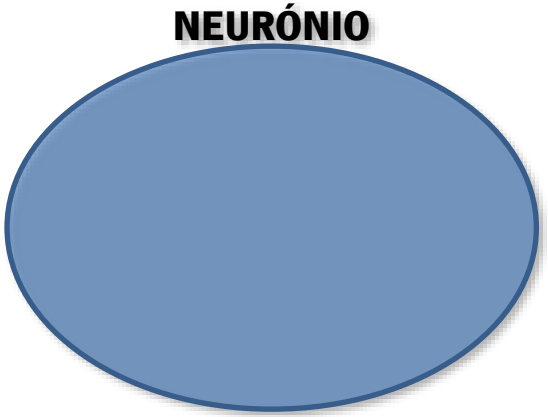

ISLab
Synthetic Intelligence Lab

Conceitos e definições
Axónio

- **Via de comunicação** entre os neurónios.
- Pode **ligar qualquer neurónio**, incluindo o próprio.
- As ligações podem **variar** ao longo do **tempo**.
- A informação circula em **um só sentido**.

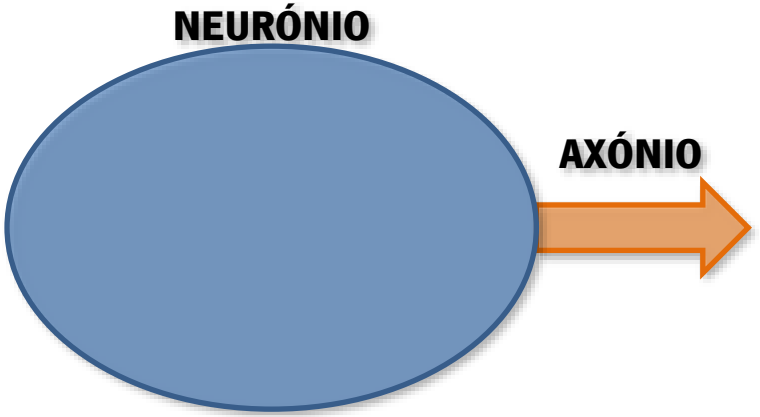

Conceitos e definições
Sinapses

- **Ponto de ligação** entre axónios e neurónios.
- O **valor da sinapse** determina o **peso** (importância) do sinal a entrar no neurónio: excitativo, inibidor ou nulo.
- A **variação no tempo determina a aprendizagem** da RNA.

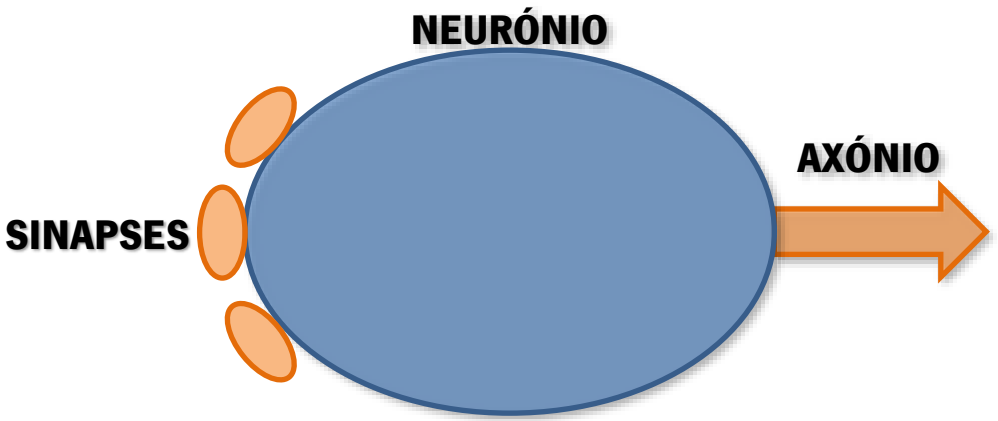

Conceitos e definições
Ativação

- O valor de ativação é representado por **um único valor**.
- O valor de ativação **varia com o tempo**.
- A gama de valores varia com o modelo adotado
  (normalmente está dependente das entradas e de algum efeito de memória).

ISLab
Synthetic Intelligence Lab

Conceitos e definições
Transferência

- O valor de transferência de um neurónio determina **o valor** que é **colocado na saída** (transferido através do axónio).
- É calculado como uma função do valor de ativação (eventualmente com algum efeito de memória).

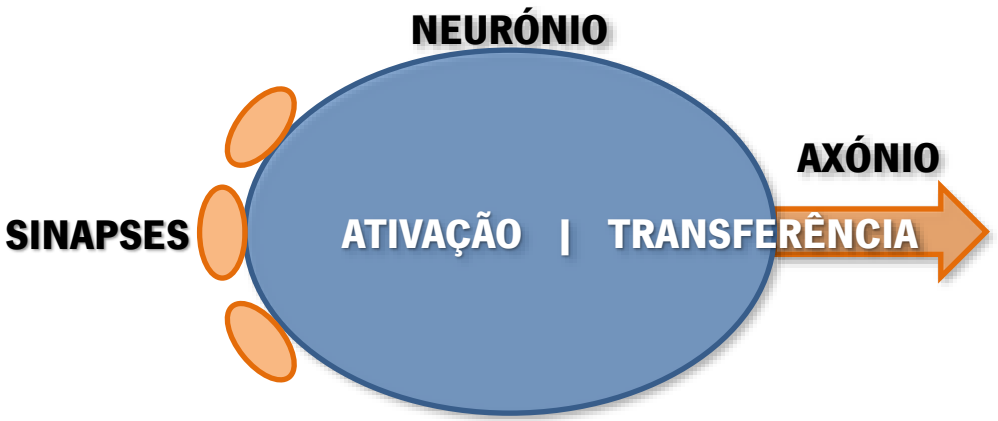

ISLab
Synthetic Intelligence Lab

Tarefas dos neurónios

- Cálculo do valor de saída (output = O_i), função do valor de ativação, por uma função de transferência (f_T):

$$O_i = f_T (A_i)$$

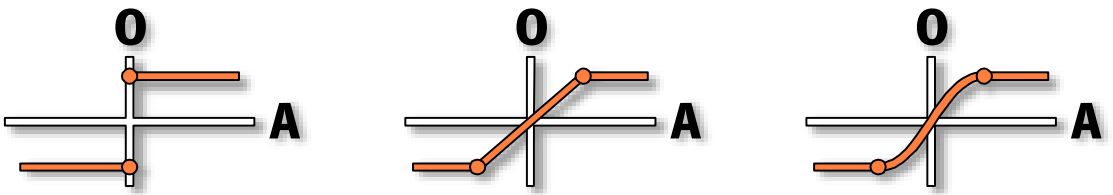

Binária ou Escada | Linear | Sigmoid

- Cálculo do valor de ativação (A_j).
- Varia no tempo com o seu próprio valor e o de outras entradas (w_i ; I):

$$A_j = \mathcal{F}(A_{j-1}; I_j; \sum w_{i,j} \times O_i)$$

- **Aprendizagem**: regras de modificação dos pesos (w_i).

ISLab
Synthetic Intelligence Lab

Organização dos neurónios

- Arquitetura *Feed forward*, de uma só camada: (*Perceptron*)

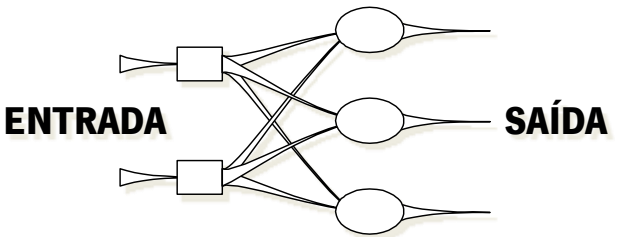

- Arquitetura *Feed forward*, multi-camada: (*Multi-layer Perceptron*)

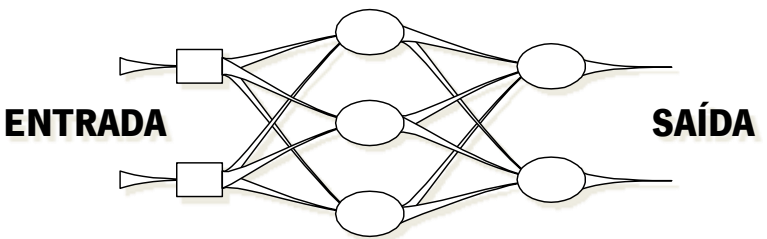

- Arquitetura Recorrente

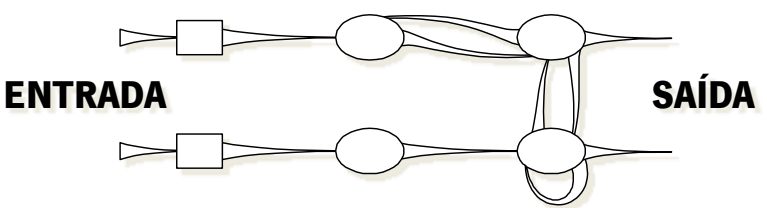

Aprendizagem (treino)

- Sem supervisão:

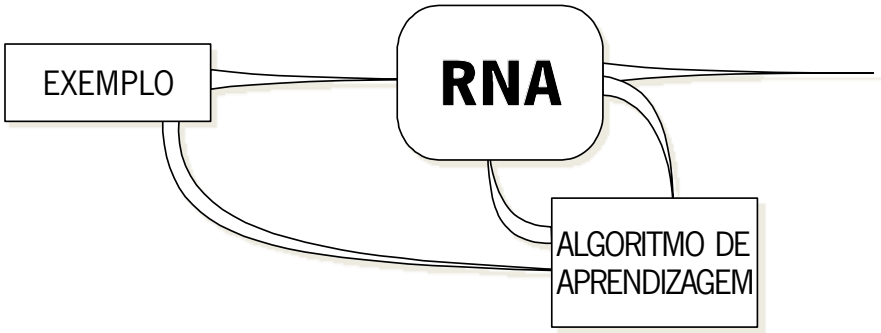

(p.ex., quando dois neurónios adjacentes têm variações da ativação no mesmo sentido, então o peso da ligação deve ser progressivamente aumentado.)

Aprendizagem (treino)

- Com supervisão:

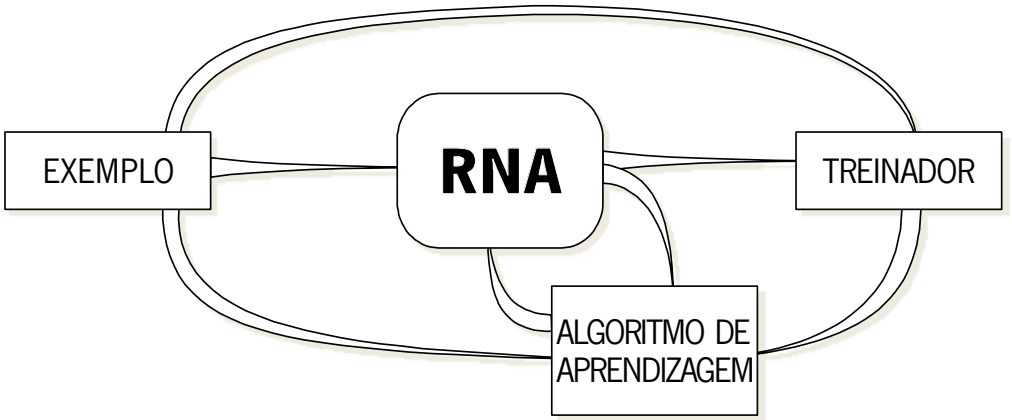

(p.ex., os ajustes nos pesos das ligações são efetuados por forma a minimizar o erro produzido pelos resultados da RNA.)

- De reforço: o exemplo contém, apenas, uma indicação sobre a correção do resultado.

ISLab
Synthetic Intelligence Lab

Regras de aprendizagem

- O treino de uma RNA corresponde à **aplicação de regras de aprendizagem**, por forma a fazer **variar os pesos das ligações** (sinapses);

Regras de aprendizagem

- O treino de uma RNA corresponde à **aplicação de regras de aprendizagem**, por forma a fazer **variar os pesos das ligações** (sinapses);
- Regras de aprendizagem mais comuns:
  - *Hebbian Learning Rule*
    - Desenvolvida por Donald Hebb em 1949 para o treino não supervisionado de RNAs;
    - Se dois neurónios adjacentes sofrem variações no mesmo sentido, o peso da ligação deve aumentar;
    - Se as variações acontecem em sentido oposto, o peso da ligação deve diminuir;
    - Não havendo variação, o peso deve manter-se inalterado;
    - Os pesos são inicializados a zero;

$$W_{ij} = x_i * x_j$$

Regras de aprendizagem

- O treino de uma RNA corresponde à **aplicação de regras de aprendizagem**, por forma a fazer **variar os pesos das ligações** (sinapses);
- Regras de aprendizagem mais comuns:
  - *Hebbian Learning Rule*
  - *Perceptron Learning Rule*
    - Desenvolvida para aprendizagem supervisionada;
    - Os pesos iniciais são atribuídos aleatoriamente;
    - Os *inputs* são processados pela rede e comparados com o *output* desejado;
    - Calcula-se o erro produzido pela rede na forma:

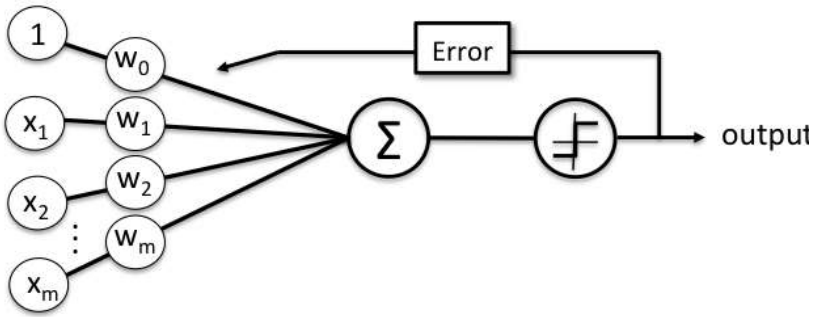

$$\sum_i \sum_j \left(E_{ij} - O_{ij} \right)^2$$

- A função de alteração dos pesos usa este erro para calcular a atualização dos seus valores;

ISLab
Synthetic Intelligence Lab

Regras de aprendizagem

- O treino de uma RNA corresponde à **aplicação de regras de aprendizagem**, por forma a fazer **variar os pesos das ligações** (sinapses);
- Regras de aprendizagem mais comuns:
  - *Hebbian Learning Rule*
  - *Perceptron Learning Rule*
  - *Widrow-Hoff Learning Rule*
    - Desenvolvida por Bernard Widrow e Marcian Hoff;
    - A principal diferença para *Perceptron Learning* é a de que é usado um sinal linear e não binário para calculo do erro e consequente atualização dos pesos;

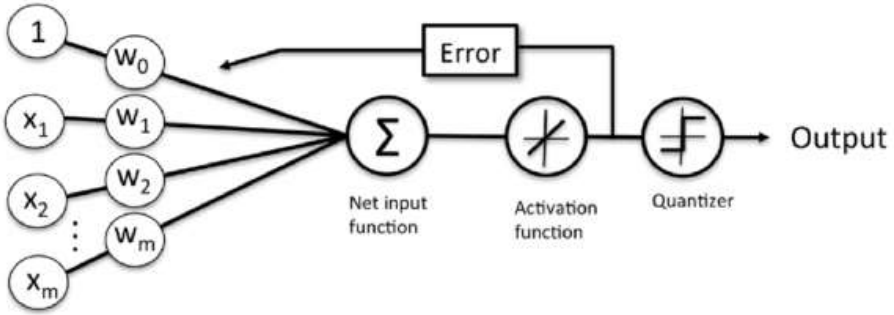

Regras de aprendizagem

- O treino de uma RNA corresponde à **aplicação de regras de aprendizagem**, por forma a fazer **variar os pesos das ligações** (sinapses);
- Regras de aprendizagem mais comuns:
  - *Hebbian Learning Rule*
  - *Perceptron Learning Rule*
  - *Widrow-Hoff Learning Rule*
  - *Competitive Learning Rule*
    - Desenvolvida para aprendizagem não supervisionada;
    - Os neurónios de *output* competem entre si para representarem o padrão do *input*;
    - O neurónio com maior *output* para um dado *input* é declarado vencedor, sendo o único a alterar os pesos;

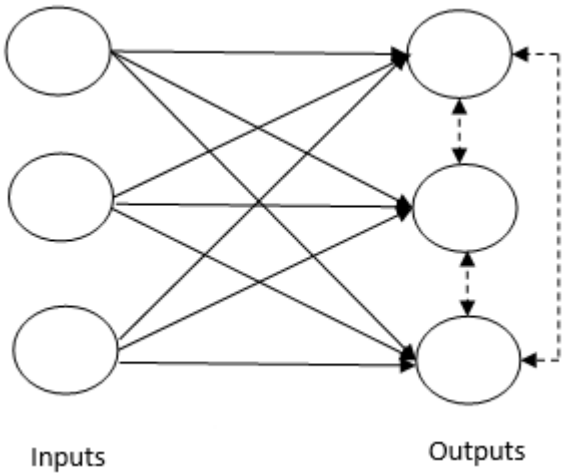

ISLab
Synthetic Intelligence Lab

Regras de aprendizagem

- O treino de uma RNA corresponde à **aplicação de regras de aprendizagem**, por forma a fazer **variar os pesos das ligações** (sinapses);
- Regras de aprendizagem mais comuns:
  - *Hebbian Learning Rule*
  - *Perceptron Learning Rule*
  - *Widrow-Hoff Learning Rule (Delta Rule)*
  - *Competitive Learning Rule (Winner-takes-it-all Rule)*
  - *Correlation Learning Rule*
  - *Outstar Learning Rule (Grossberg Rule)*

ISLab
Synthetic Intelligence Lab

Treino de uma RNA
(Afinação de parâmetros)

- Quantidade de neurónios:
  - na camada de entrada;
  - na camada de saída;
  - nas camadas intermédias;
- Níveis (ou camadas) da RNA;
- Ligações entre neurónios;
- Topologia das ligações;
- Esquema de atribuição e atualização dos pesos;
- Funções:
  - de transferência;
  - de ativação;
  - de aprendizagem;
- Métodos de treino.

Treino de RNAs

Treino de RNAs

- Considere-se uma Rede Neuronal Artificial...

Treino de RNAs

- ... composta por 2 neurónios à entrada e 1 à saída...

Treino de RNAs

- ... *feed forward*, completamente ligada, com 1 camada intermédia.

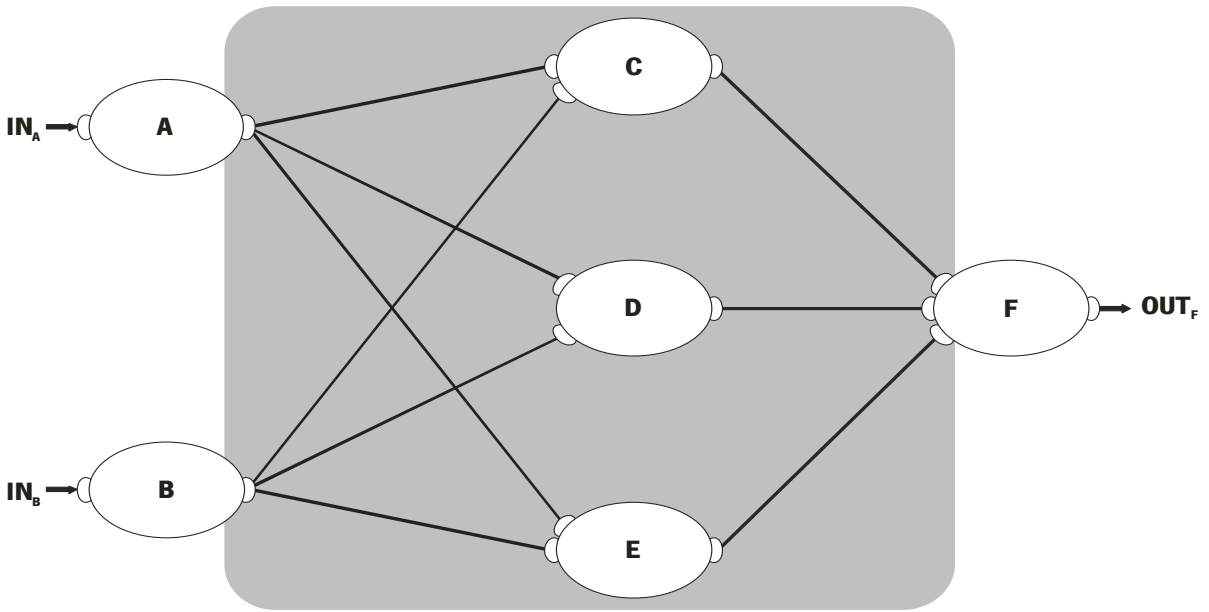

Treino de RNAs

- Os exemplos de treino contêm os resultados pretendidos, pelo que a aprendizagem será supervisionada.

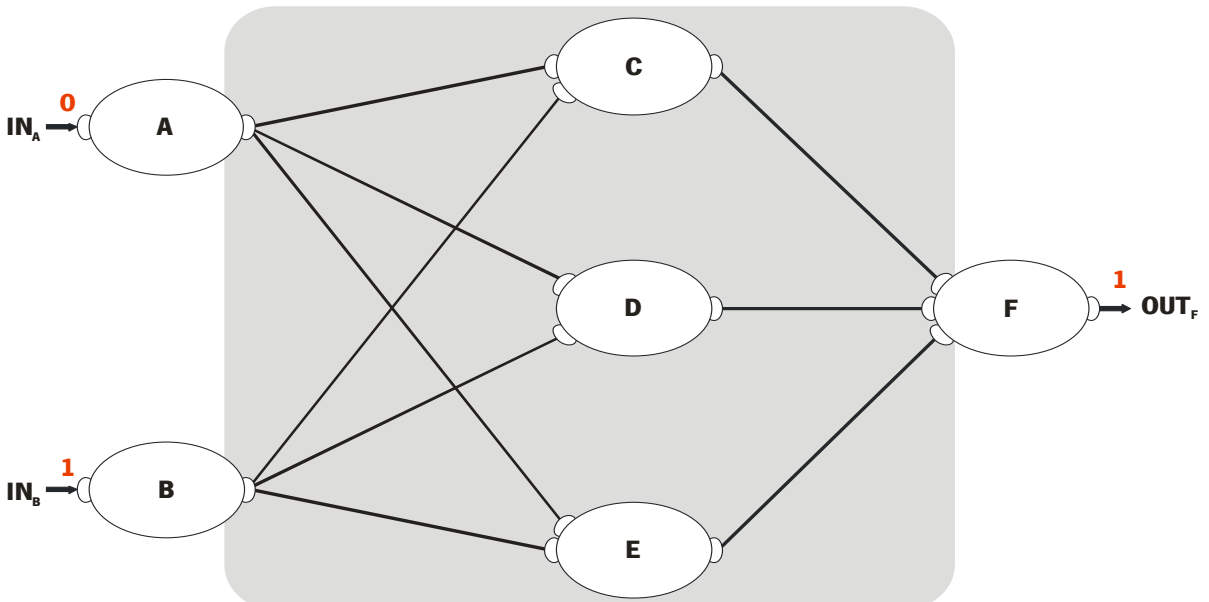

Treino de RNAs

- Atribuição aleatória dos pesos às sinapses.

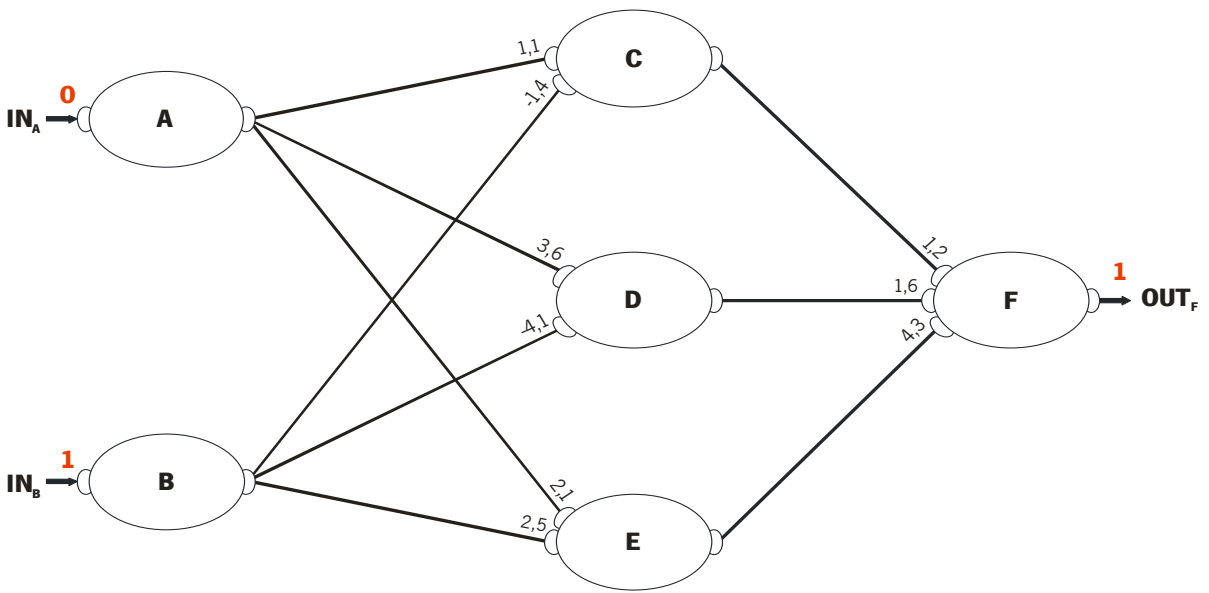

$$f_A(P,E) = \sum P \times E$$

$$f_T(A) = A$$

Treino de RNAs

- Fluxo dos dados pela rede, calculando os valores de ativação...

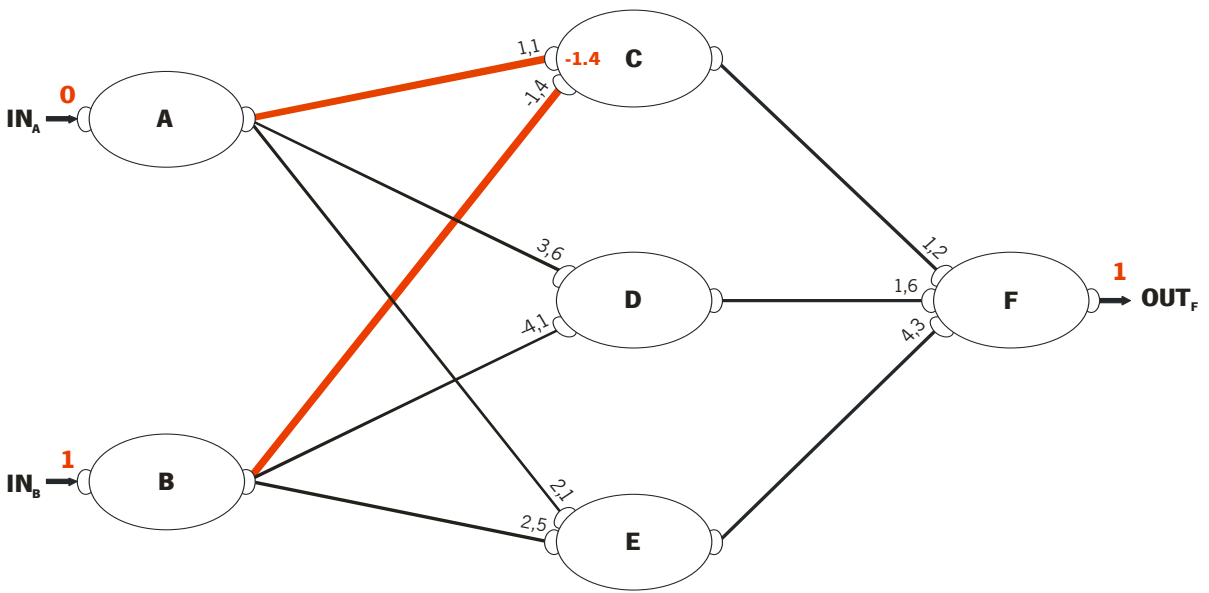

$$f_A(P,E) = \sum P \times E$$

$$f_T(A) = A$$

Treino de RNAs

- ... para todos os neurónios da camada intermédia.

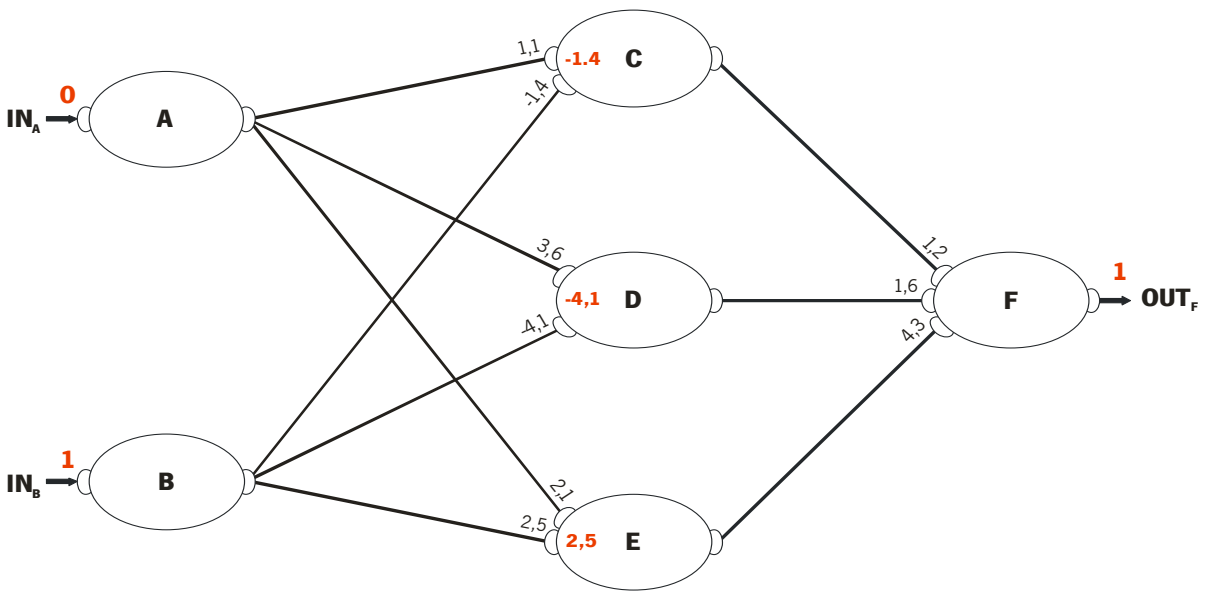

$$f_A(P,E) = \sum P \times E$$

$$f_T(A) = A$$

Treino de RNAs

- Cálculo do valor de transferência (dado pela função identidade por facilidade de demonstração!).

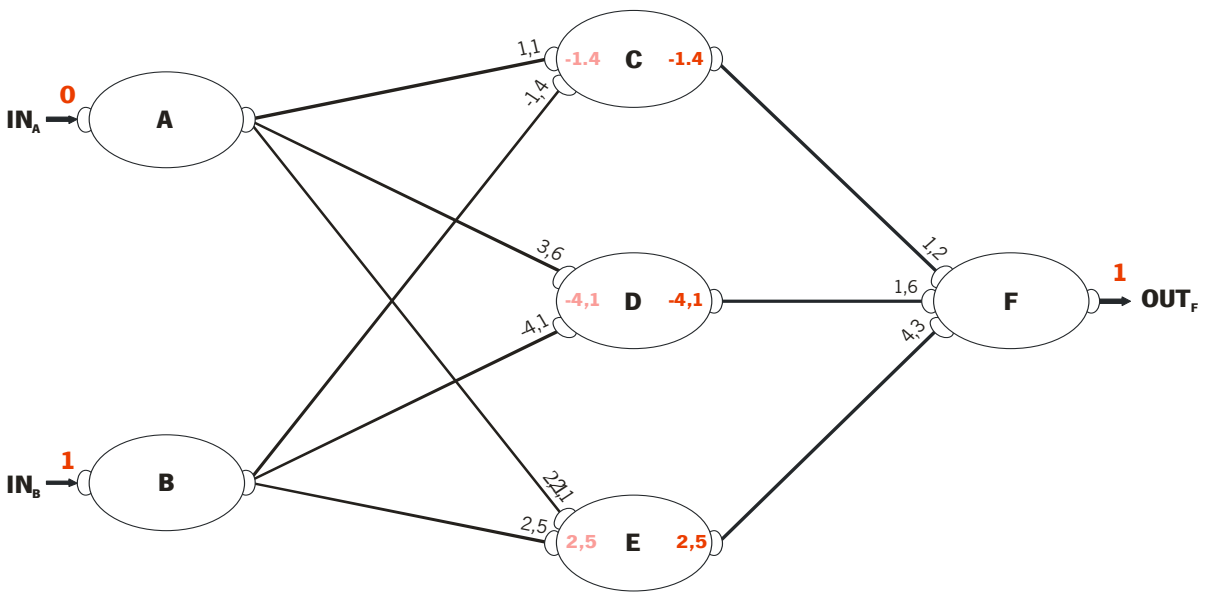

$$f_A(P,E) = \sum P \times E$$

$$f_T(A) = A$$

Treino de RNAs

- Fluxo da informação e cálculo do valor de ativação na camada de saída...

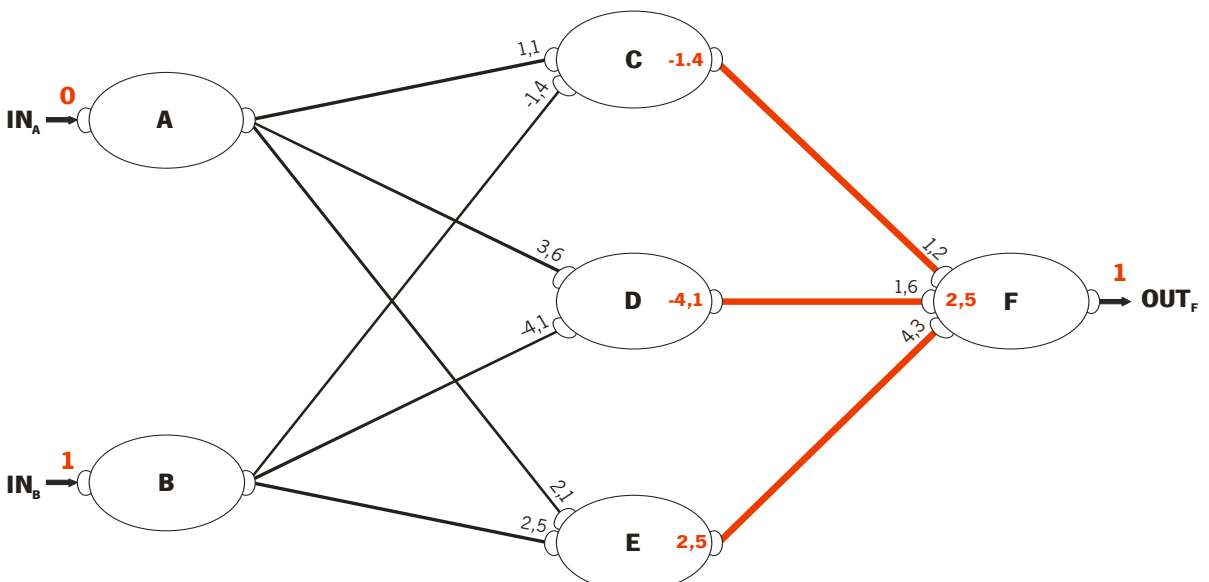

$$f_A(P,E) = \sum P \times E$$

$$f_T(A) = A$$

Treino de RNAs

- ... e respetivo valor de transferência.

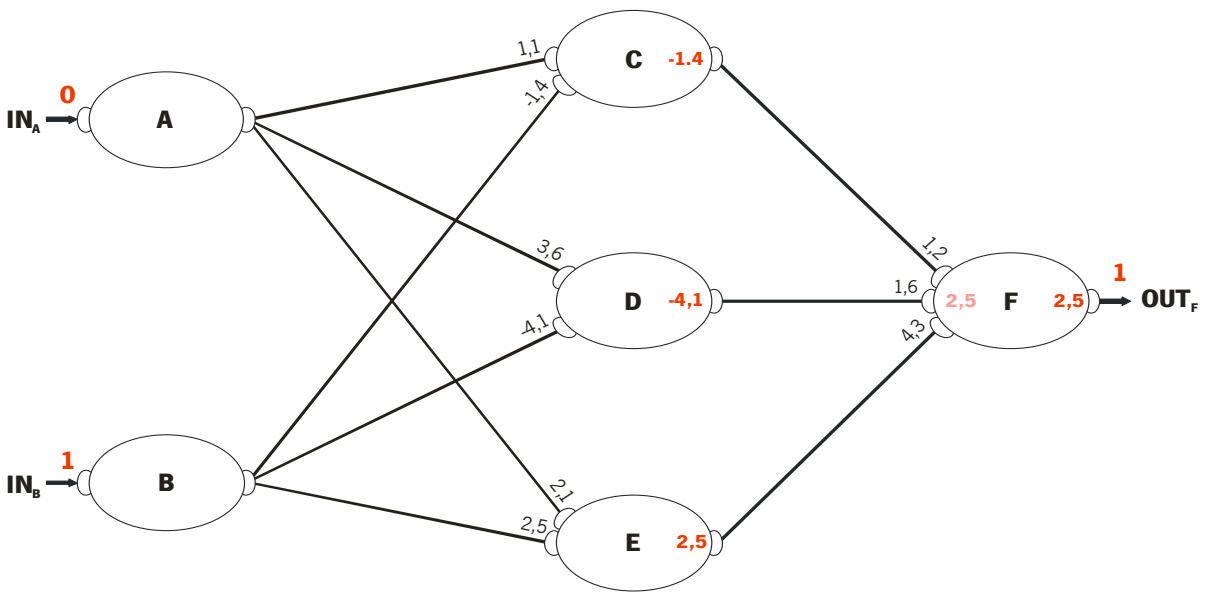

$$f_A(P,E) = \sum P \times E$$

$$f_T(A) = A$$

Treino de RNAs

- Cálculo do erro na camada de saída...

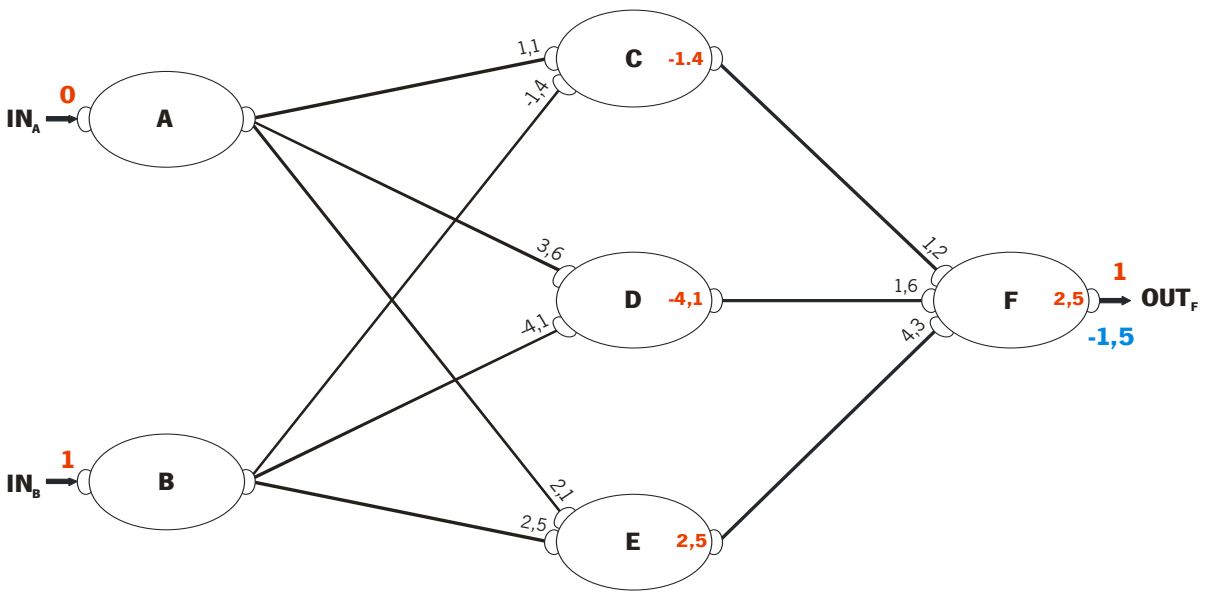

$$\mathcal{E} = OUT_{\mathcal{D}} - OUT_{C}$$

$$\mathcal{E}_{\leftarrow} = \mathcal{E} \times P$$

Treino de RNAs

- ... e cálculo do valor estimado do erro na camada intermédia.

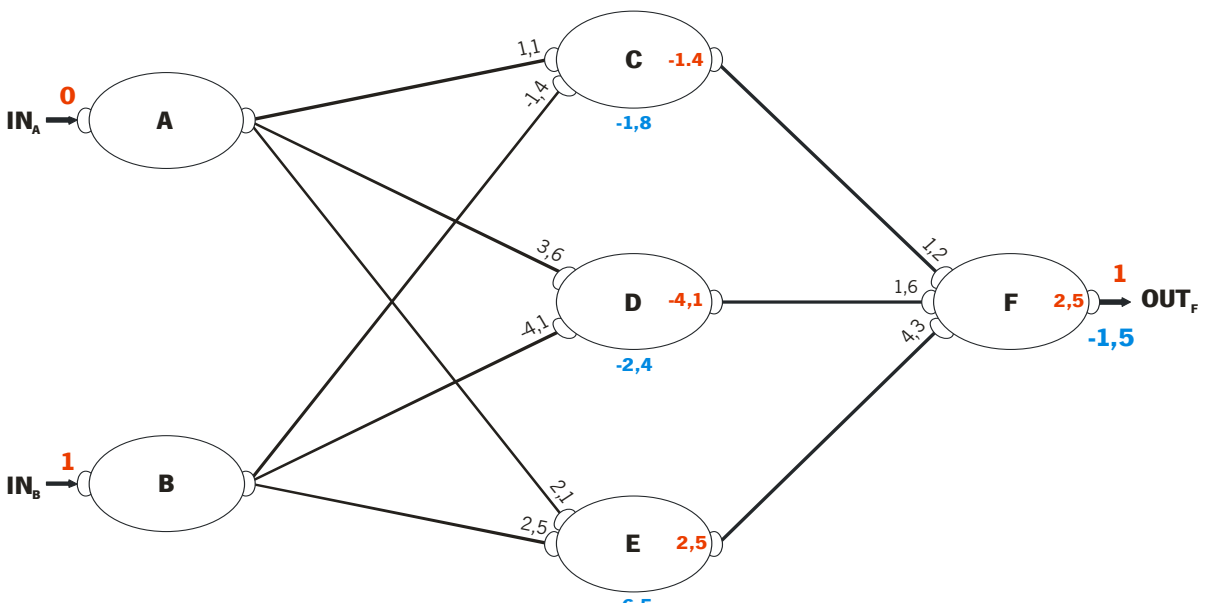

$$\mathcal{E} = OUT_{\mathcal{D}} - OUT_{C}$$

$$\mathcal{E}_{\leftarrow} = \mathcal{E} \times P$$

Treino de RNAs

- Aplicação de uma regra de atualização dos pesos das sinapses...

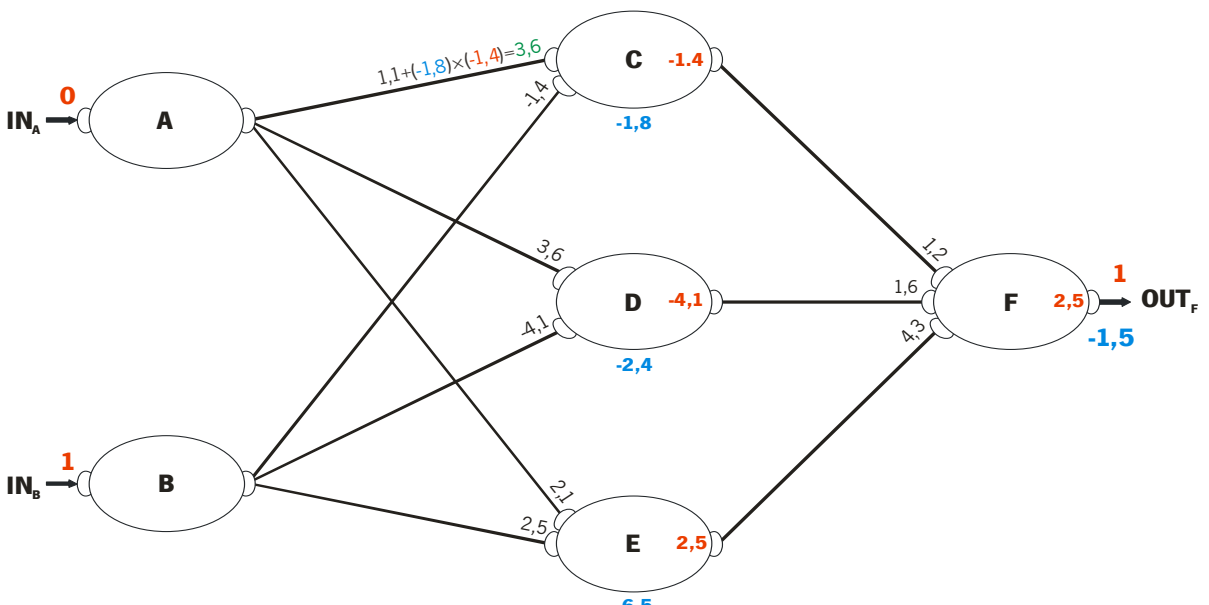

$$P_{i+1} = P_i + \varepsilon \times f_T$$

Treino de RNAs

- ... para atualizar os valores das sinapses de todos os neurónios.

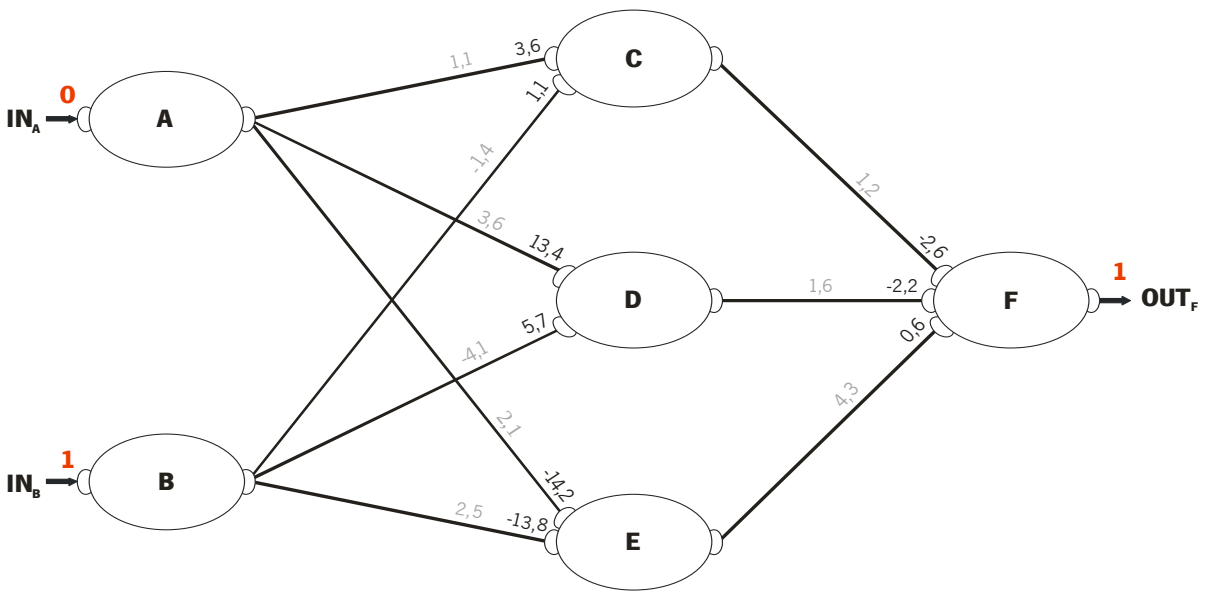

$$P_{i+1} = P_i + \varepsilon \times f_T$$

Treino de RNAs

- Segunda iteração da propagação do caso de treino...

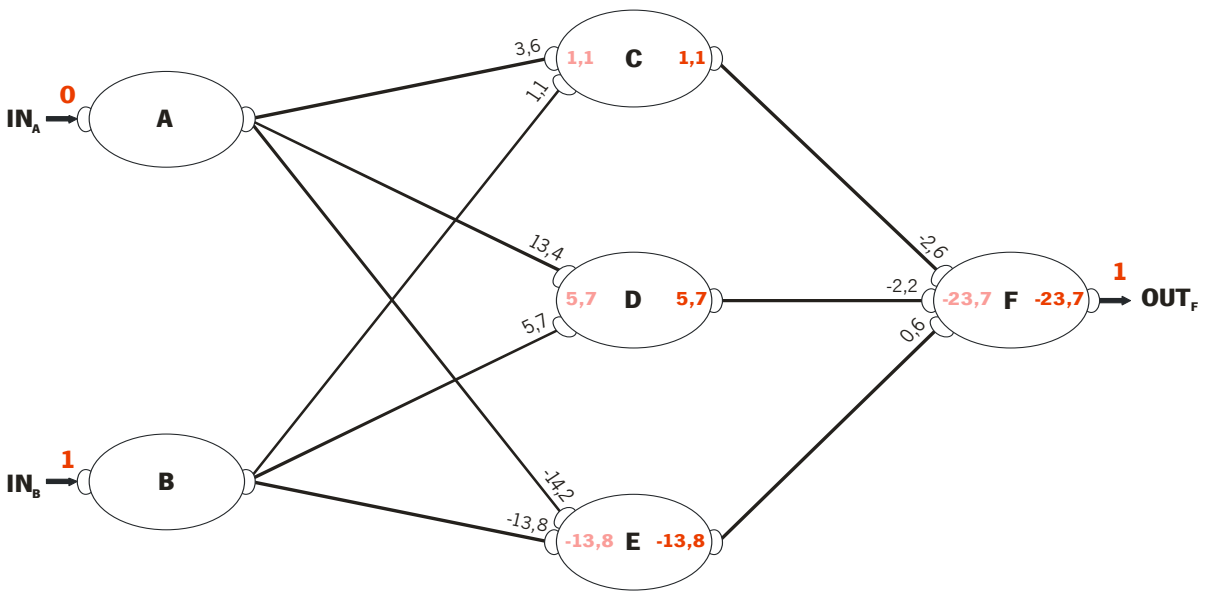

$$f_A(P,E) = \sum P \times E$$

$$f_T(A) = A$$

Treino de RNAs

- ... e cálculo do erro produzido pela RNA na segunda iteração.

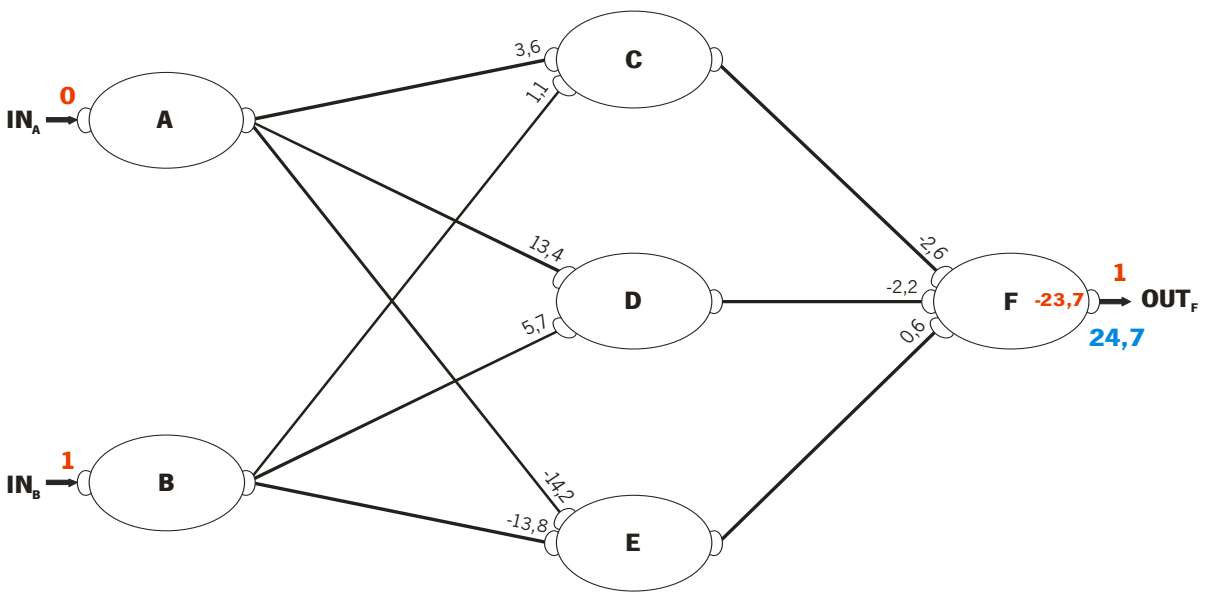

ISLab
Synthetic Intelligence Lab

Referências bibliográficas

- Cortez, P., Neves, J., “Redes Neuronais Artificiais”, Unidade de Ensino, Departamento de Informática, Universidade do Minho, 2000;
- Haykin, S., “Neural Networks - A Comprehensive Foundation”, Prentice-Hall, New Jersey, 1999, ISBN 978-0-13-273350-2;
- Bishop, Christopher M., “Neural networks for pattern recognition”, Clarendon Press, 1995, ISBN 978-0-19-853849-3;
- Charu C. Aggarwal, “Neural Networks and Deep Learning”, Springer, 2018, ISBN 978-3-319-94463-0.

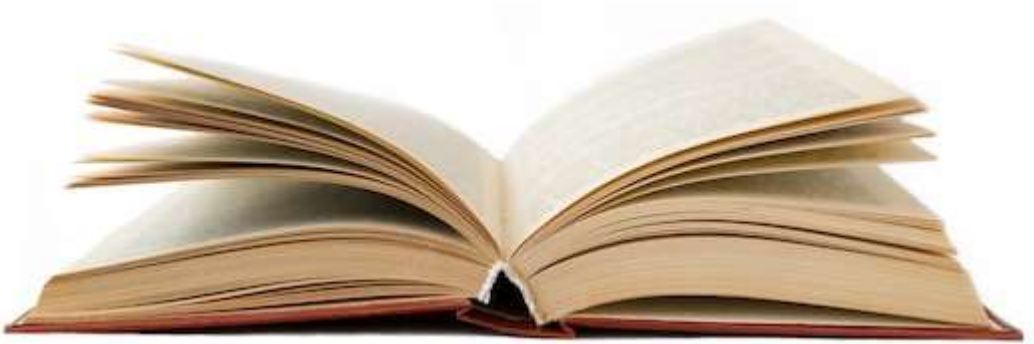

Universidade do Minho
Departamento de Informática

APRENDIZAGEM E DECISÃO INTELIGENTES

LEI/MiEI @ 2022/2023, 2º sem [ADI^3]

ISLab
Synthetic Intelligence Lab

Treino de RNAs

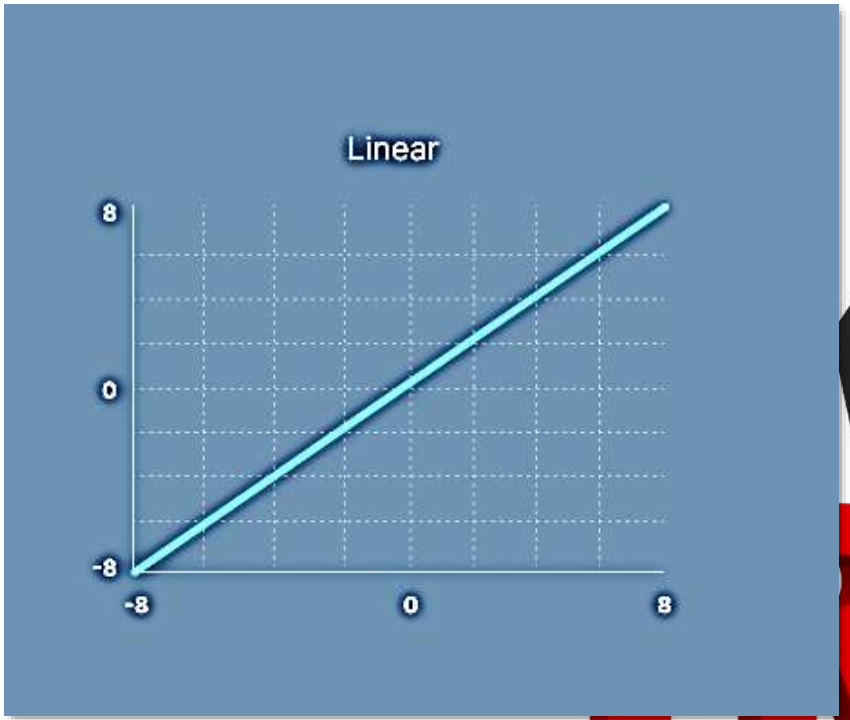

RNA

Universidade do Minho

Cesar Analide, Paulo Novais, José Neves

RNA - Treino Linear

(1)


RNA

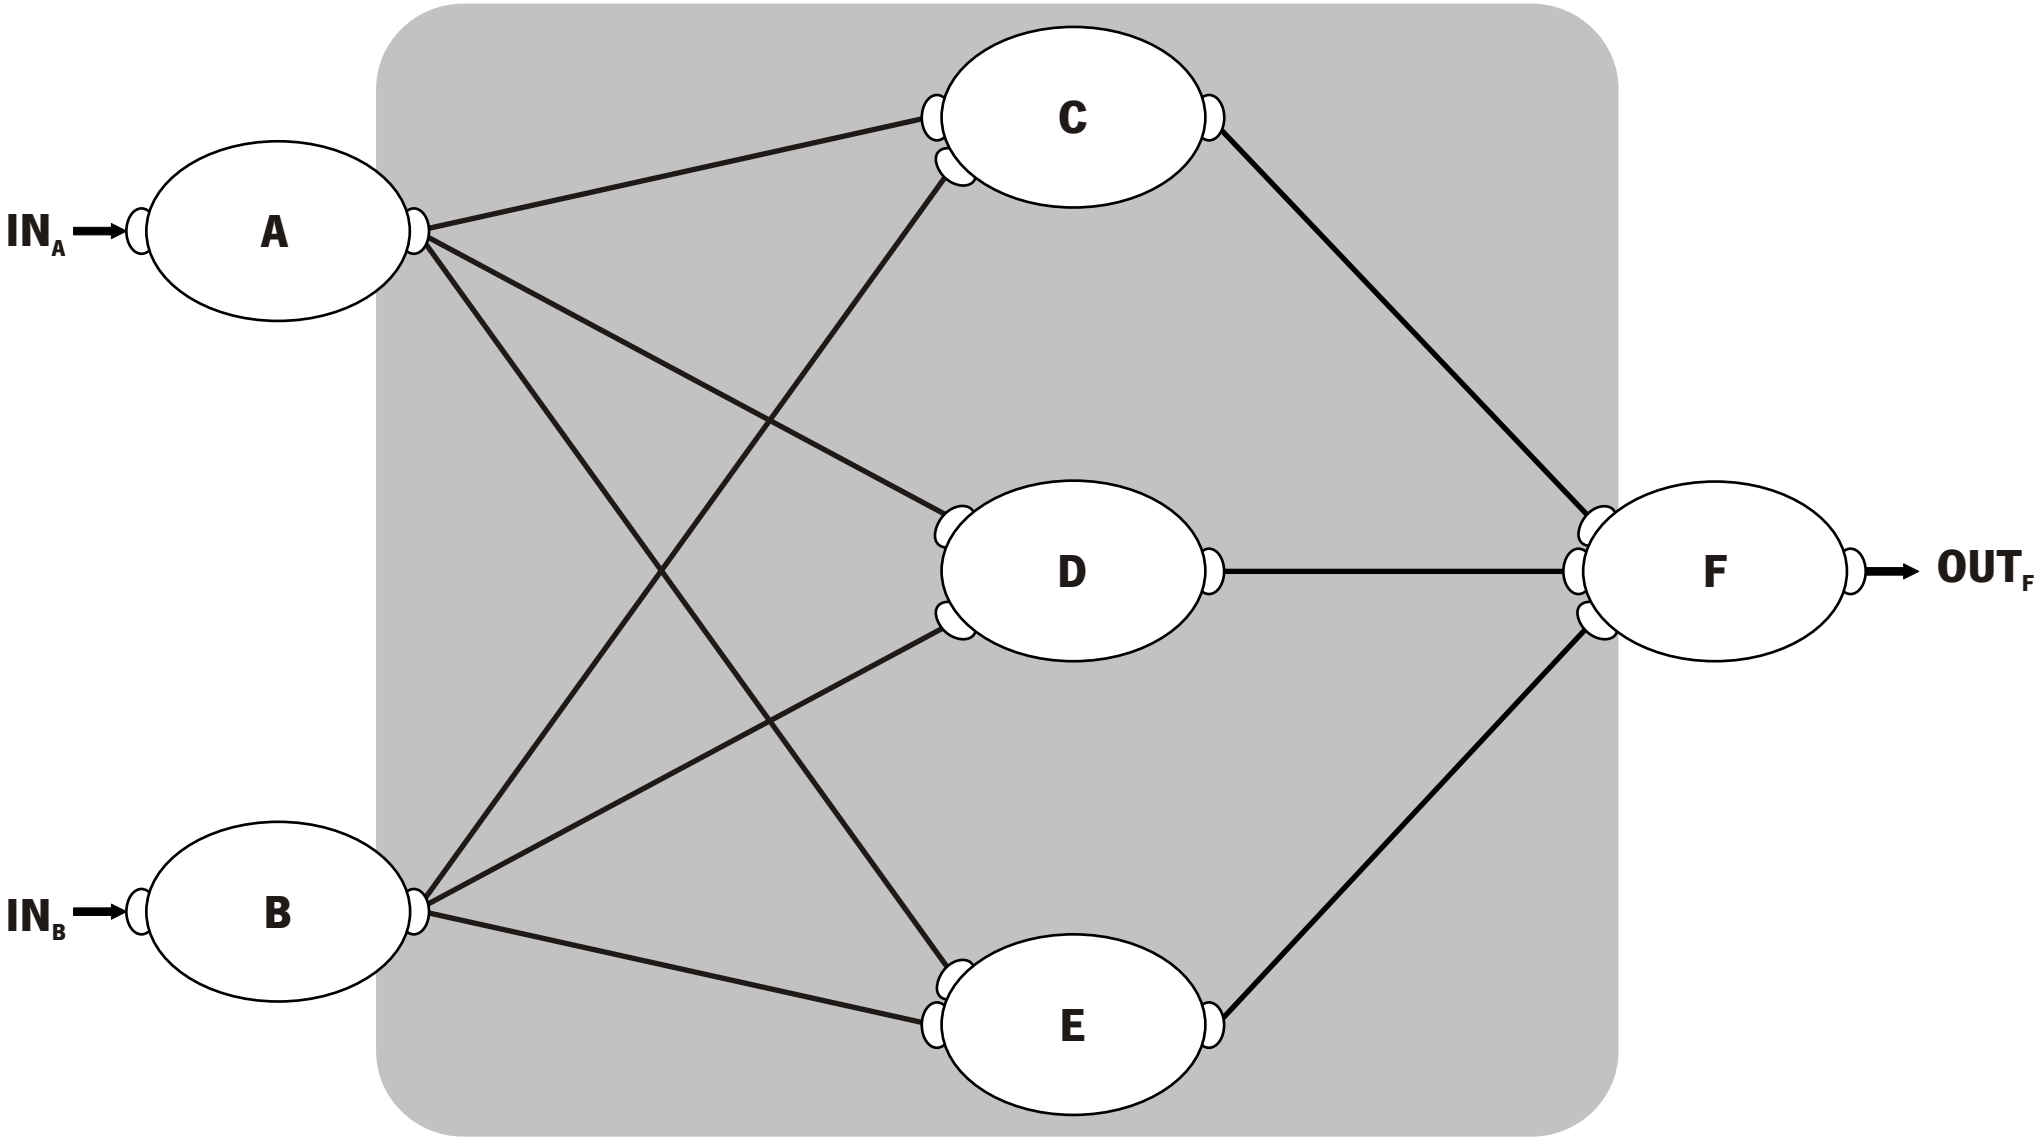
IN_A
A
C
IN_B
B
D
E
F
OUT_F

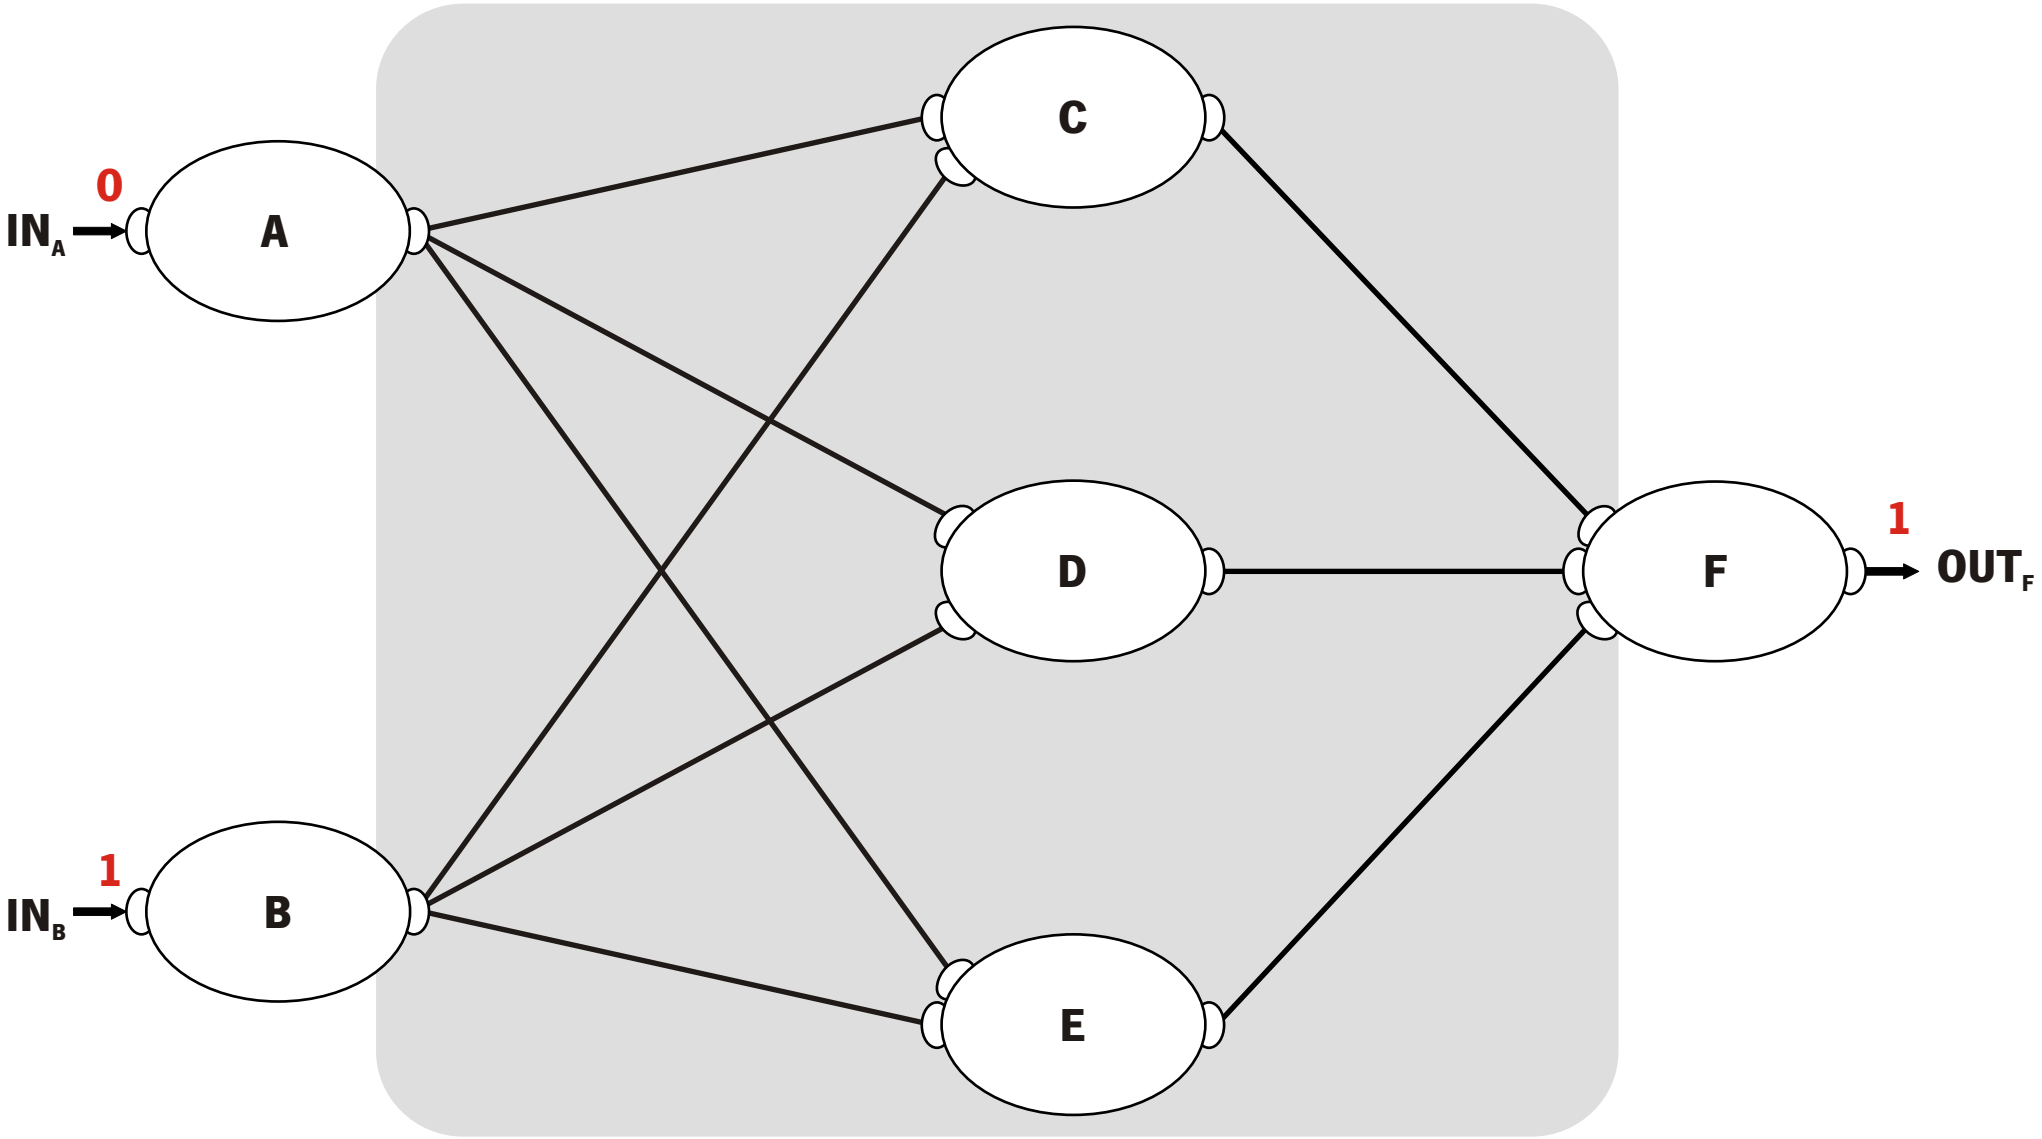
0
IN_A
A
1
IN_B
B
C
D
E
F
1
OUT_F

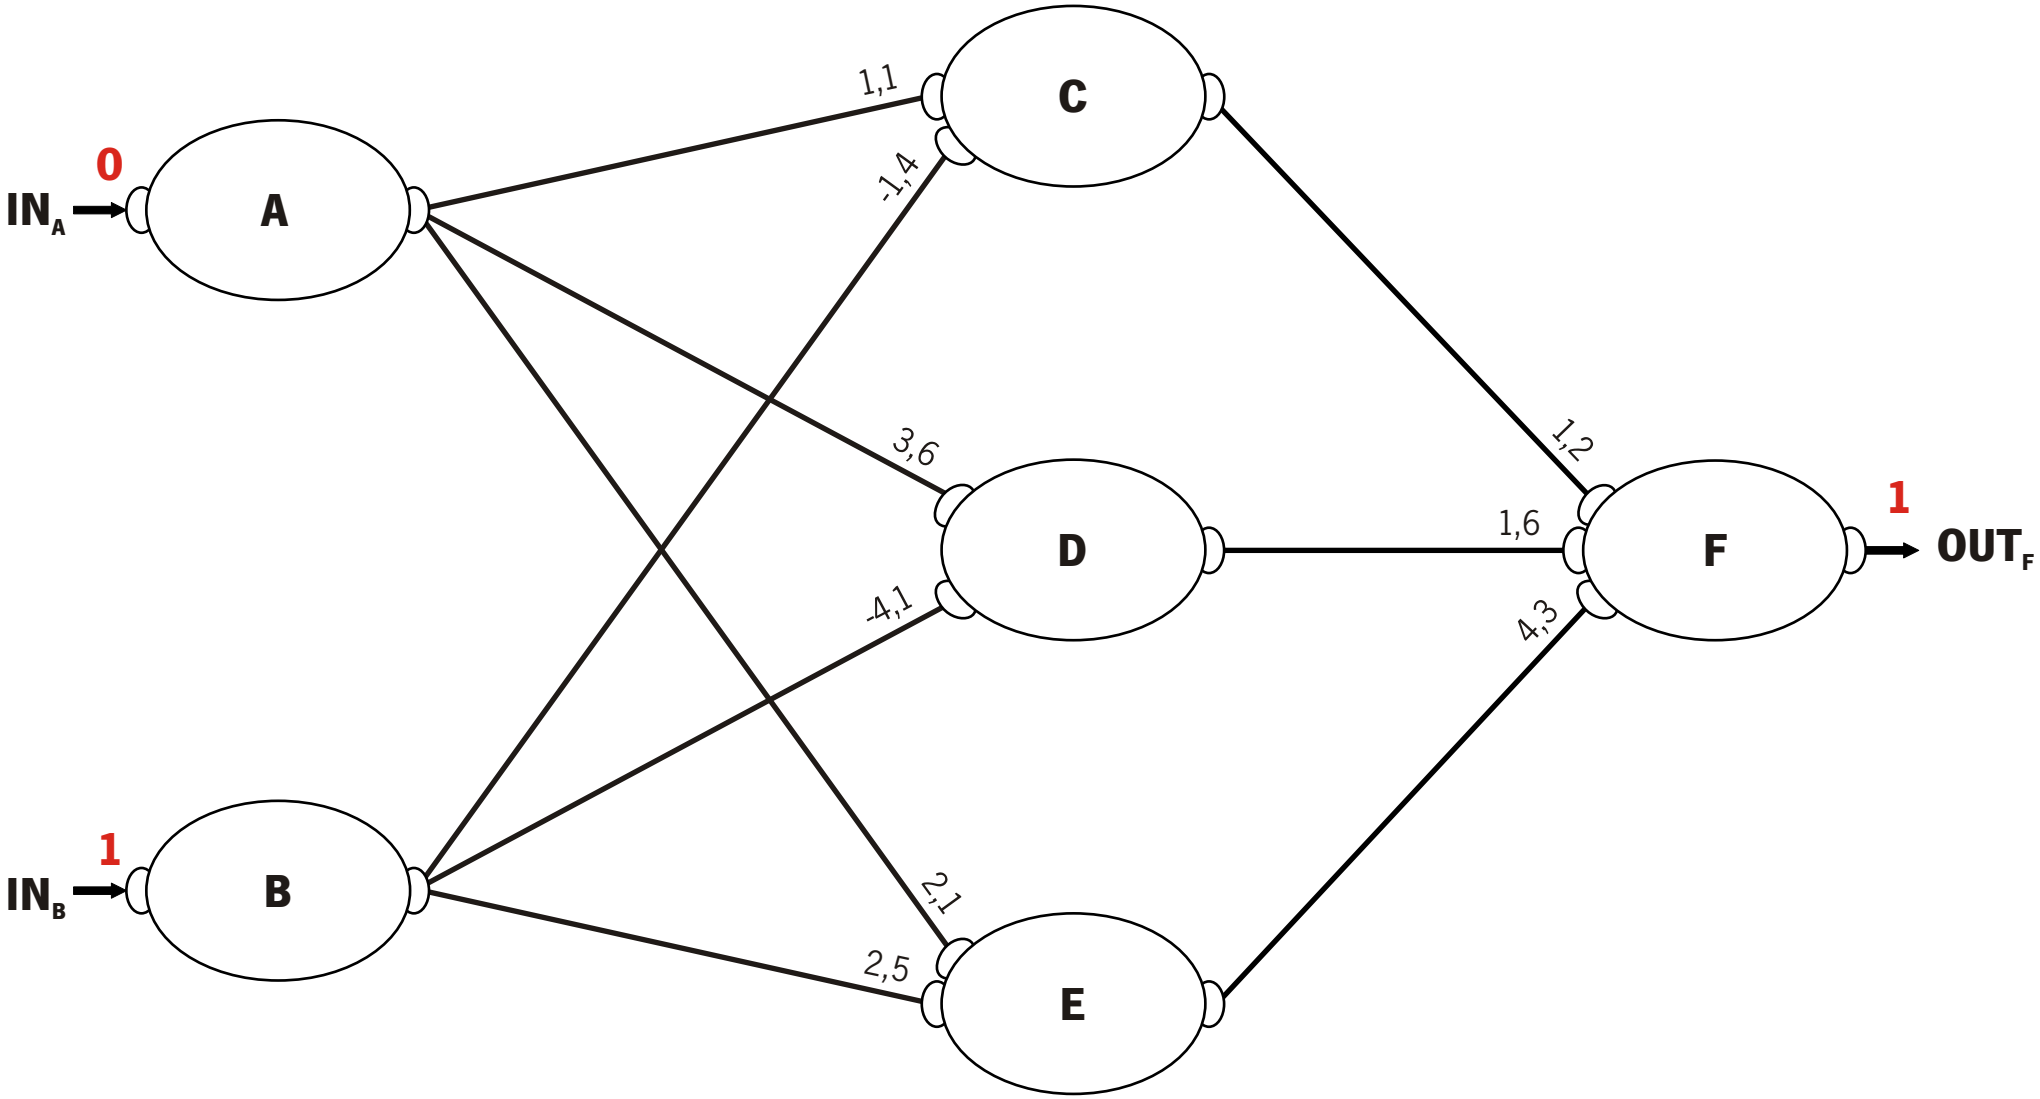

$$f_A(P,E) = \sum P \times E$$

$$f_T(A) = A$$

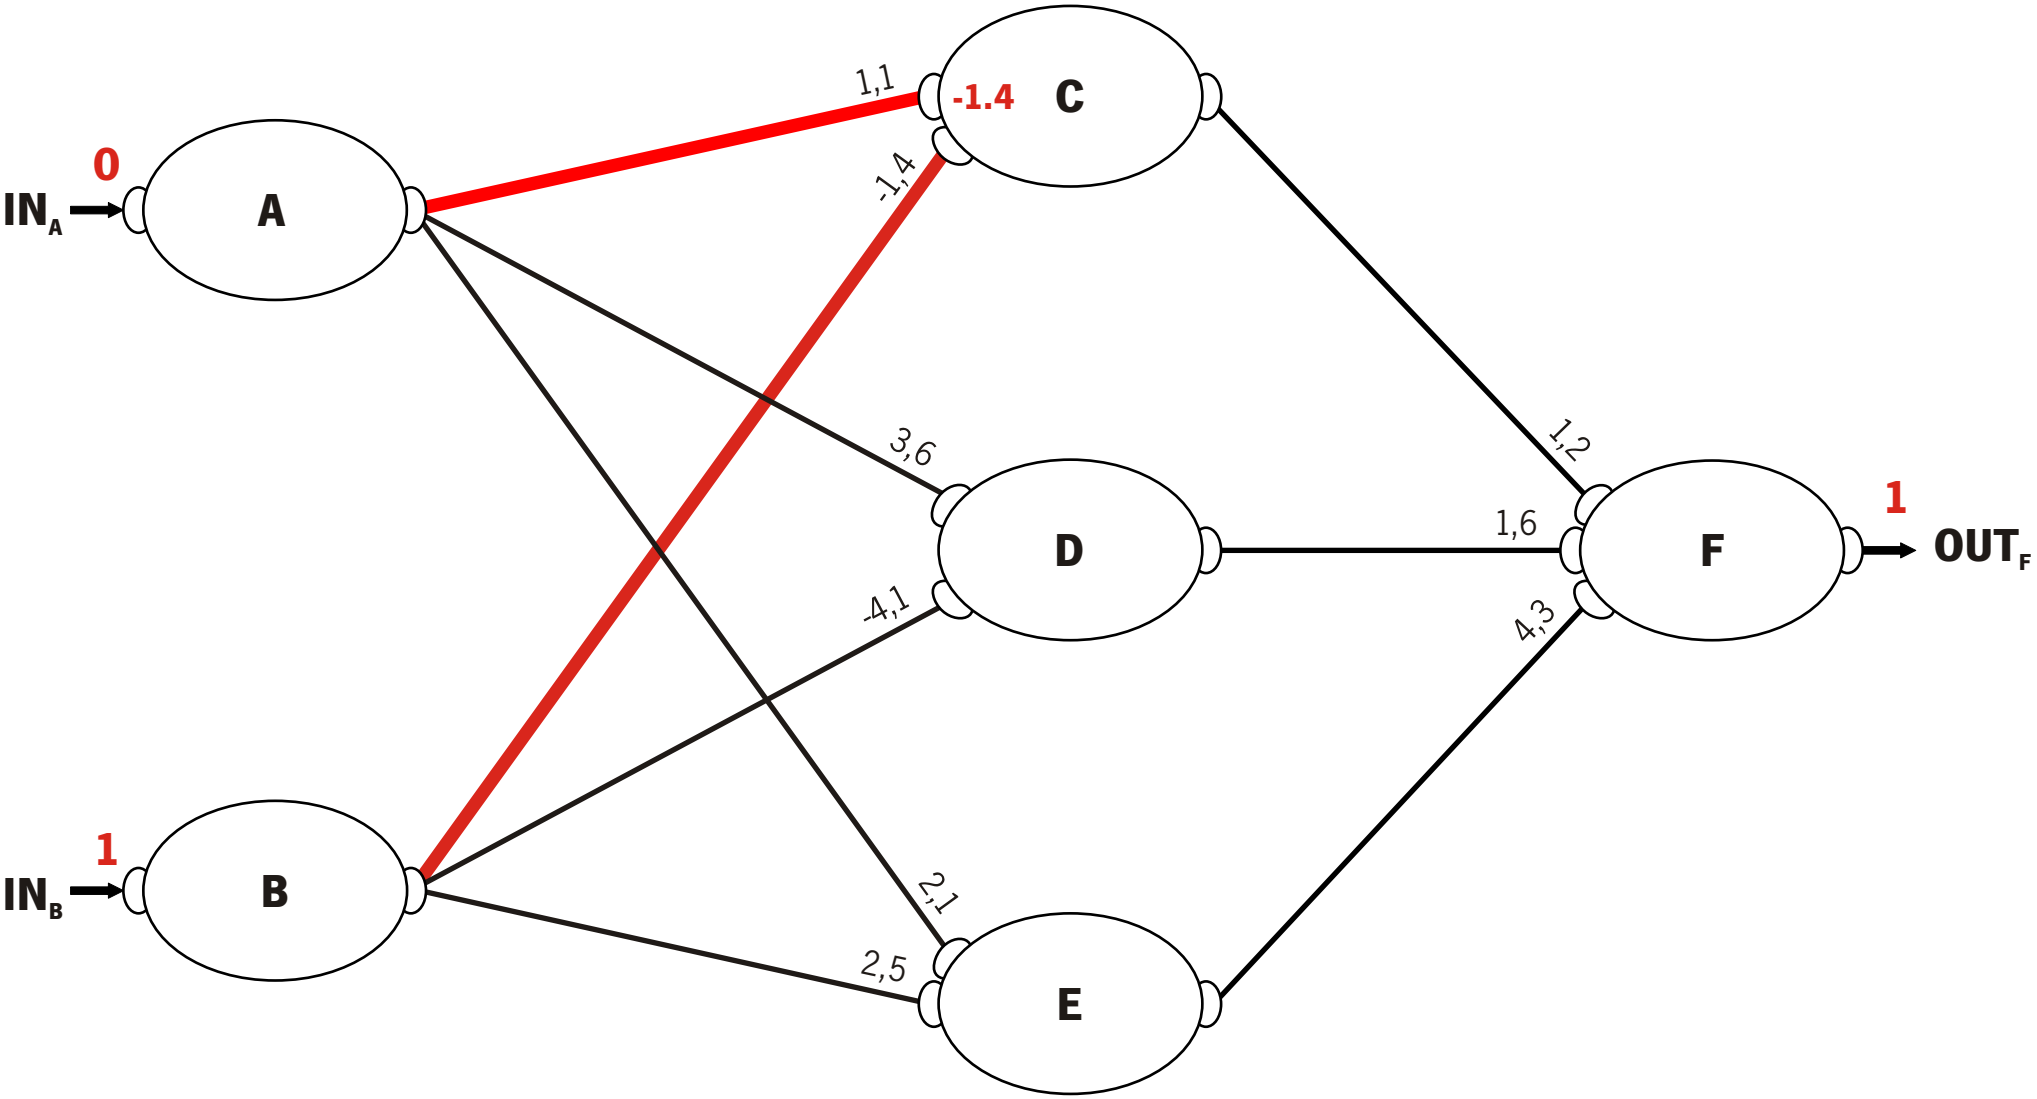

$$f_A(P,E) = \sum P \times E$$

$$f_T(A) = A$$

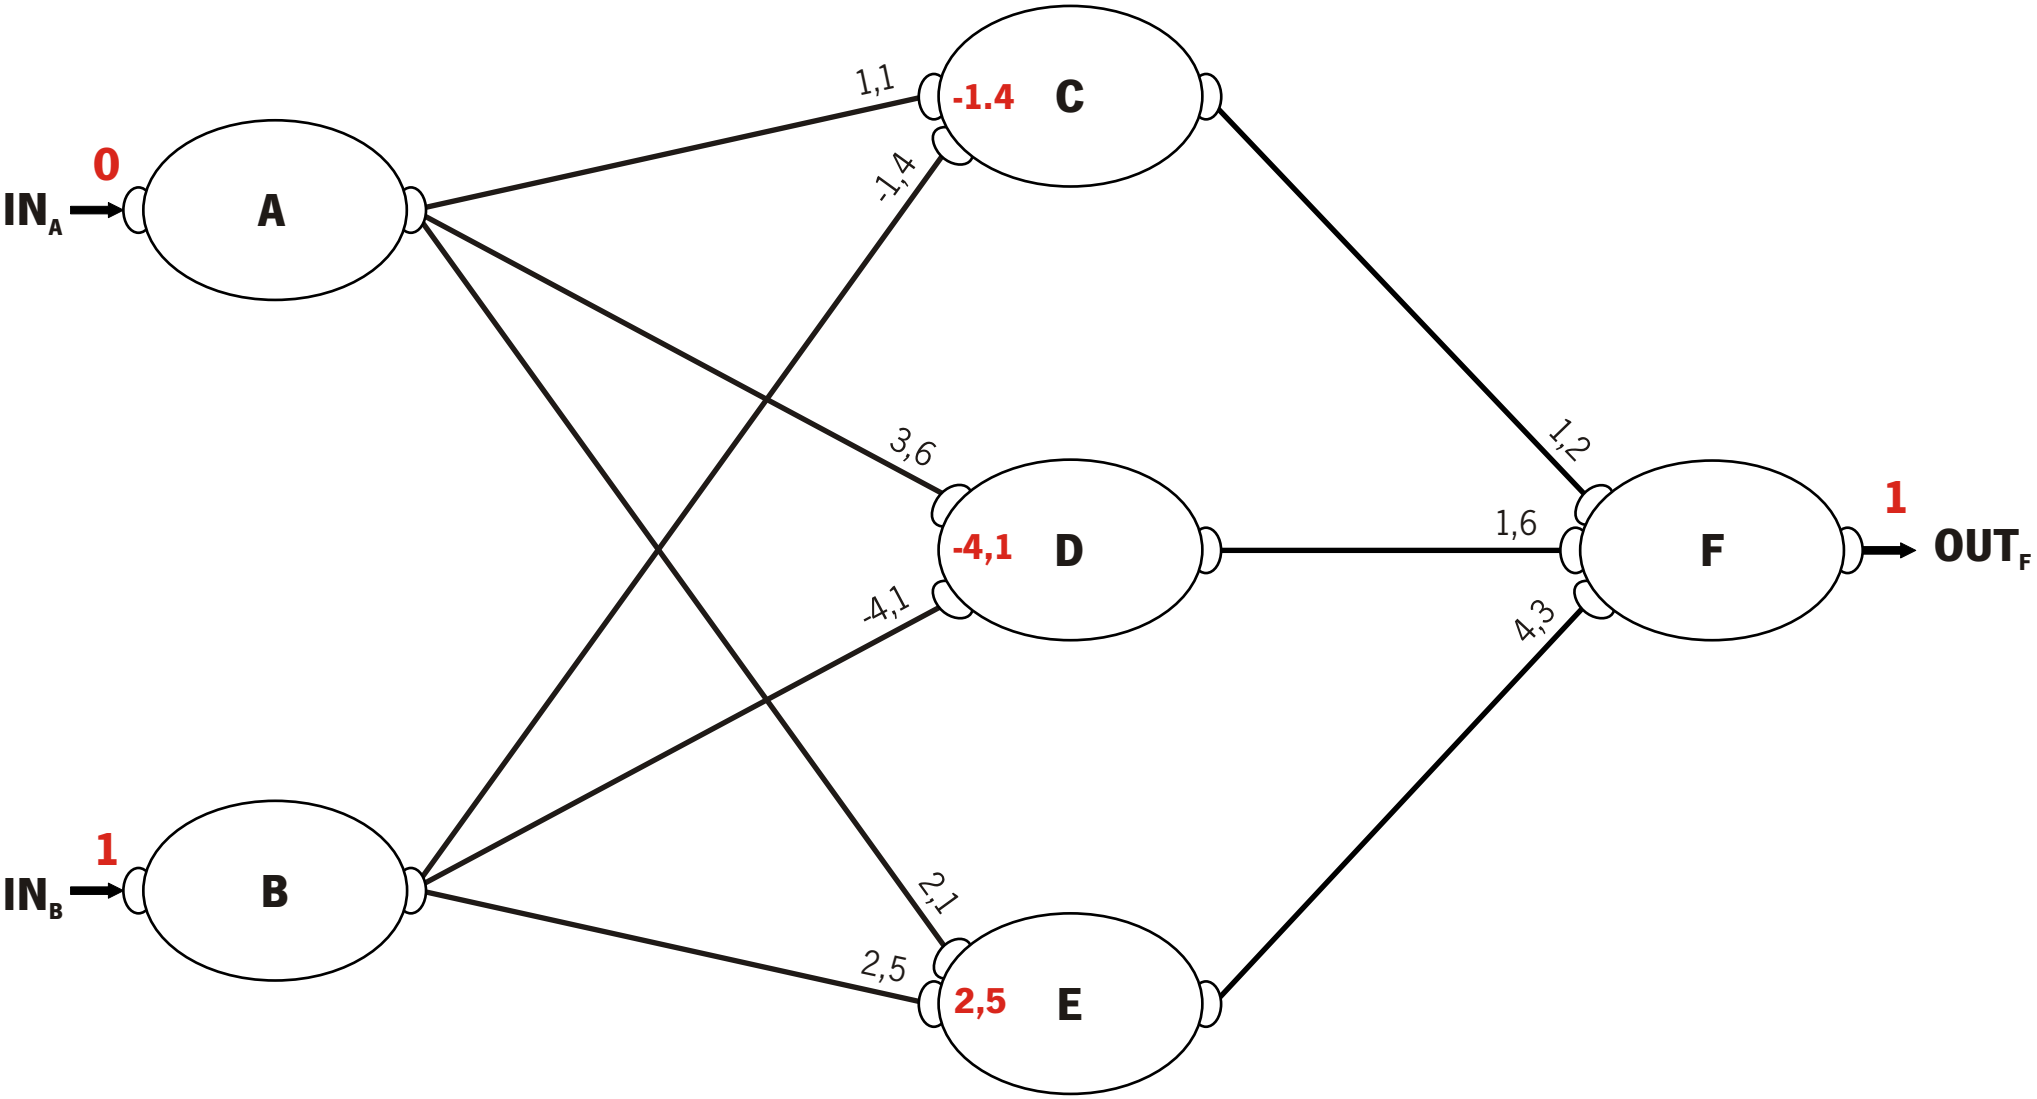

$$f_A(P,E) = \sum P \times E$$

$$f_T(A) = A$$

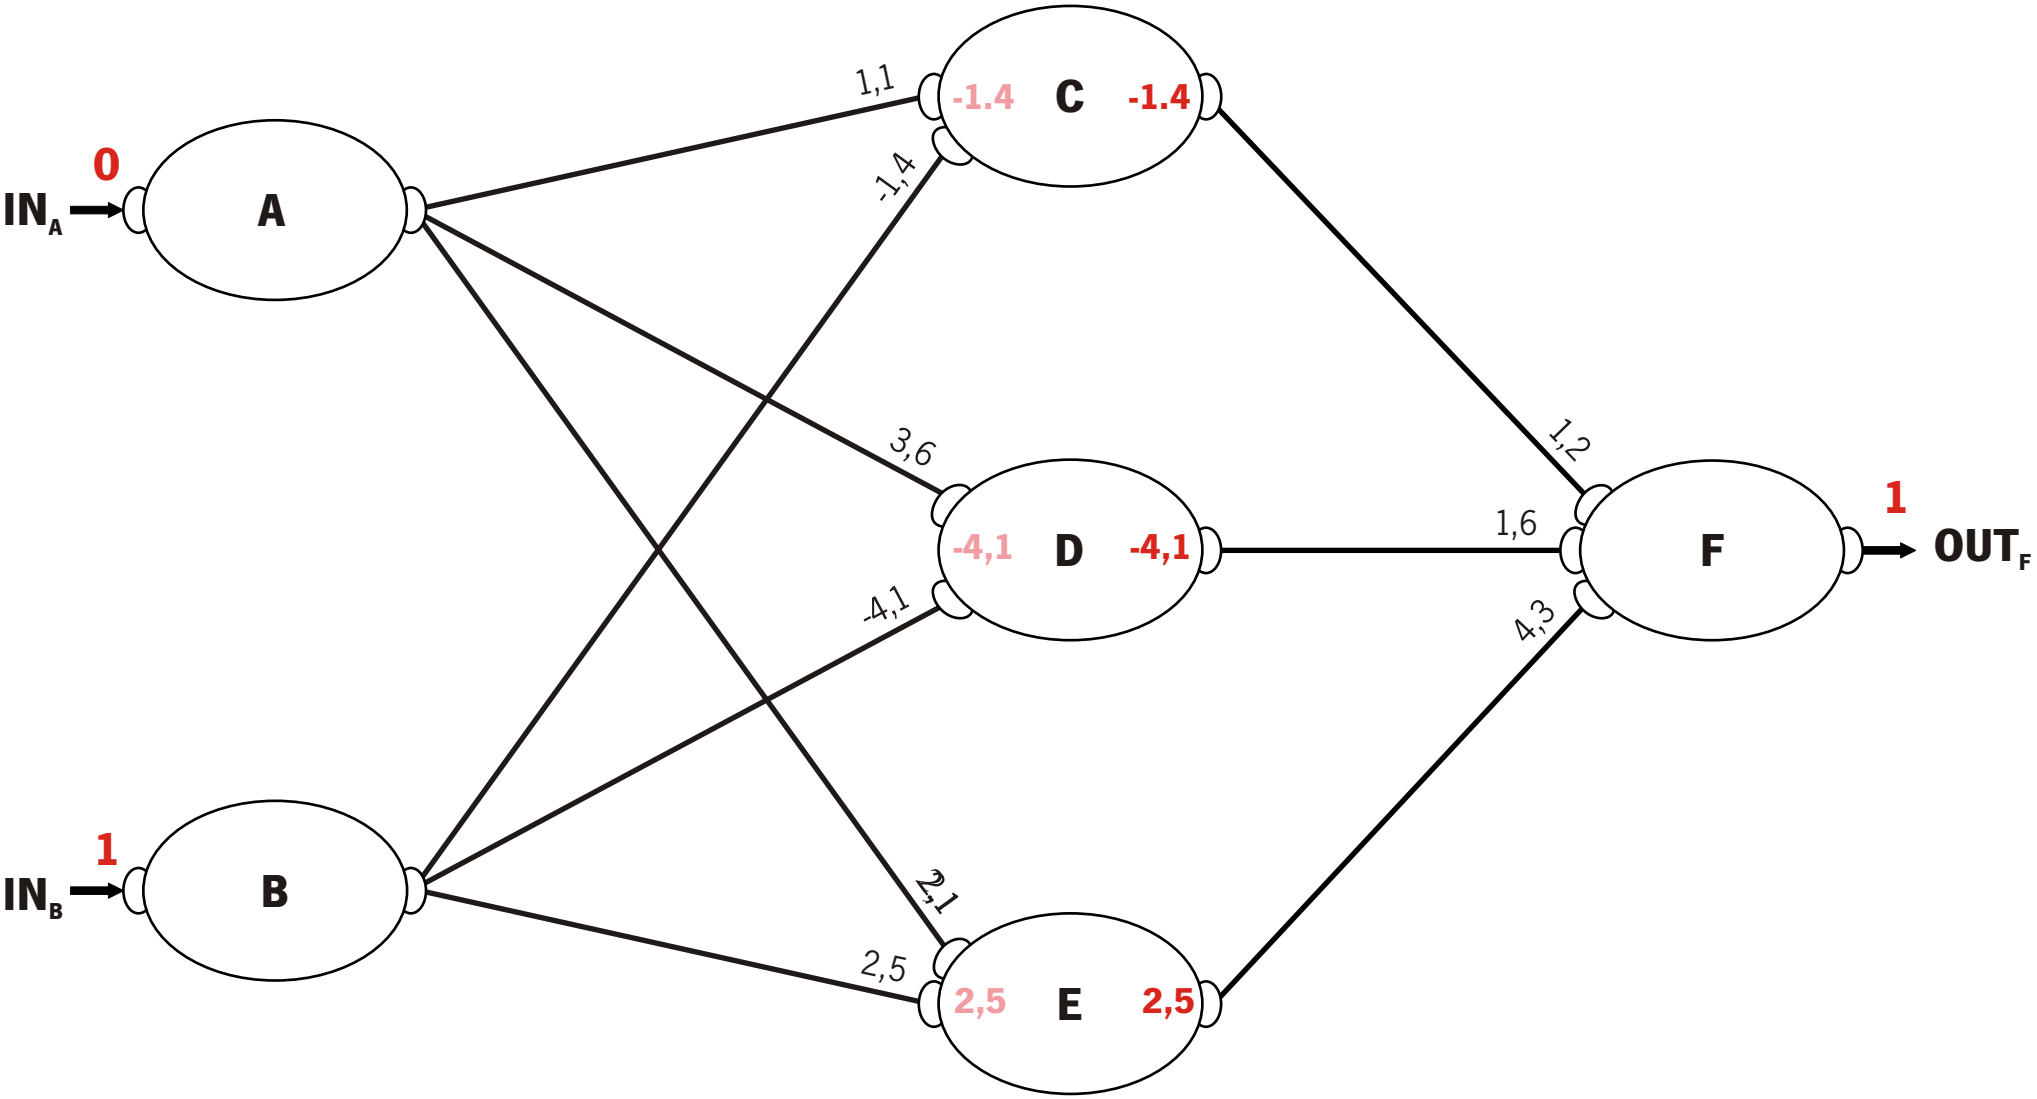

$$f_A(P,E) = \sum P \times E$$

$$f_T(A) = A$$

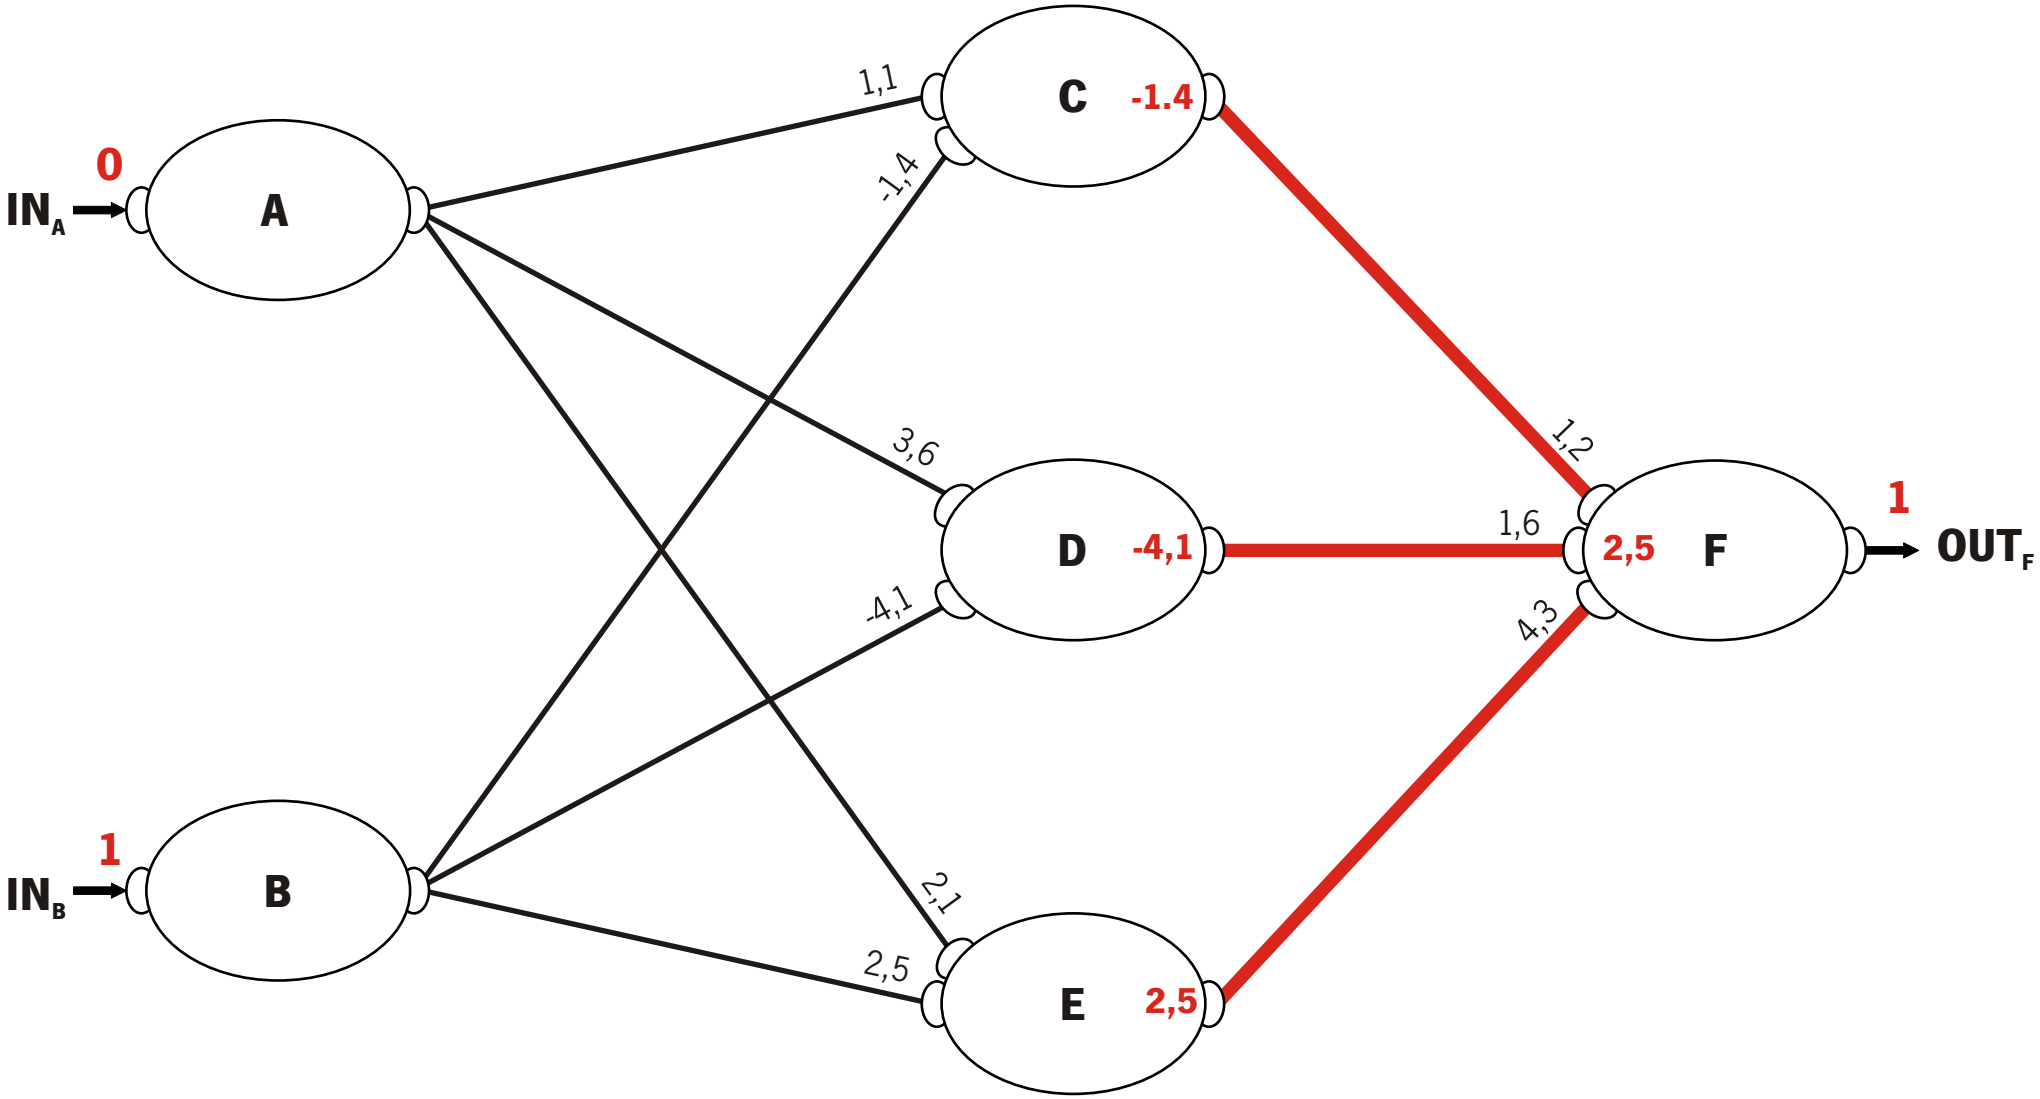

$$f_A(P,E) = \sum P \times E$$

$$f_T(A) = A$$

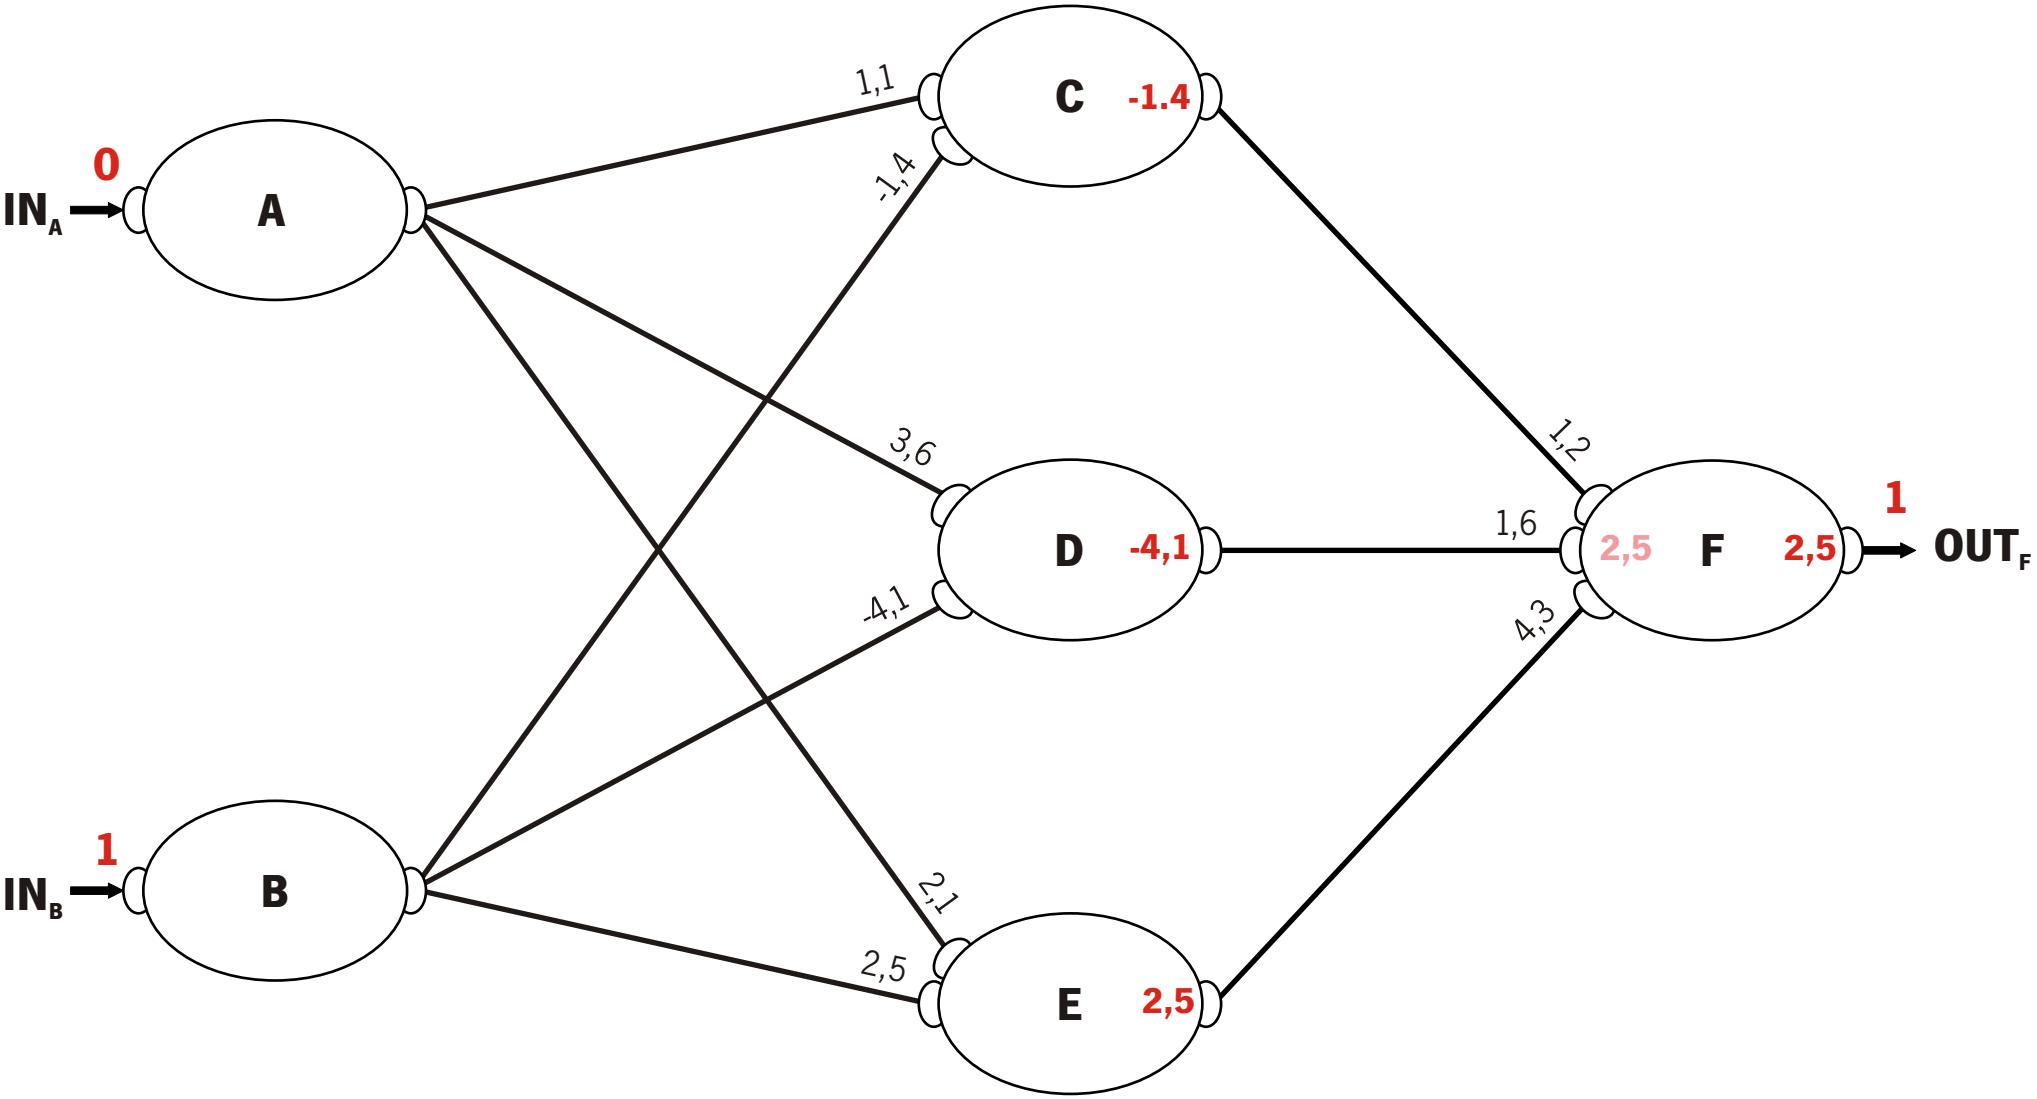

$$f_A(P,E) = \sum P \times E$$

$$f_T(A) = A$$

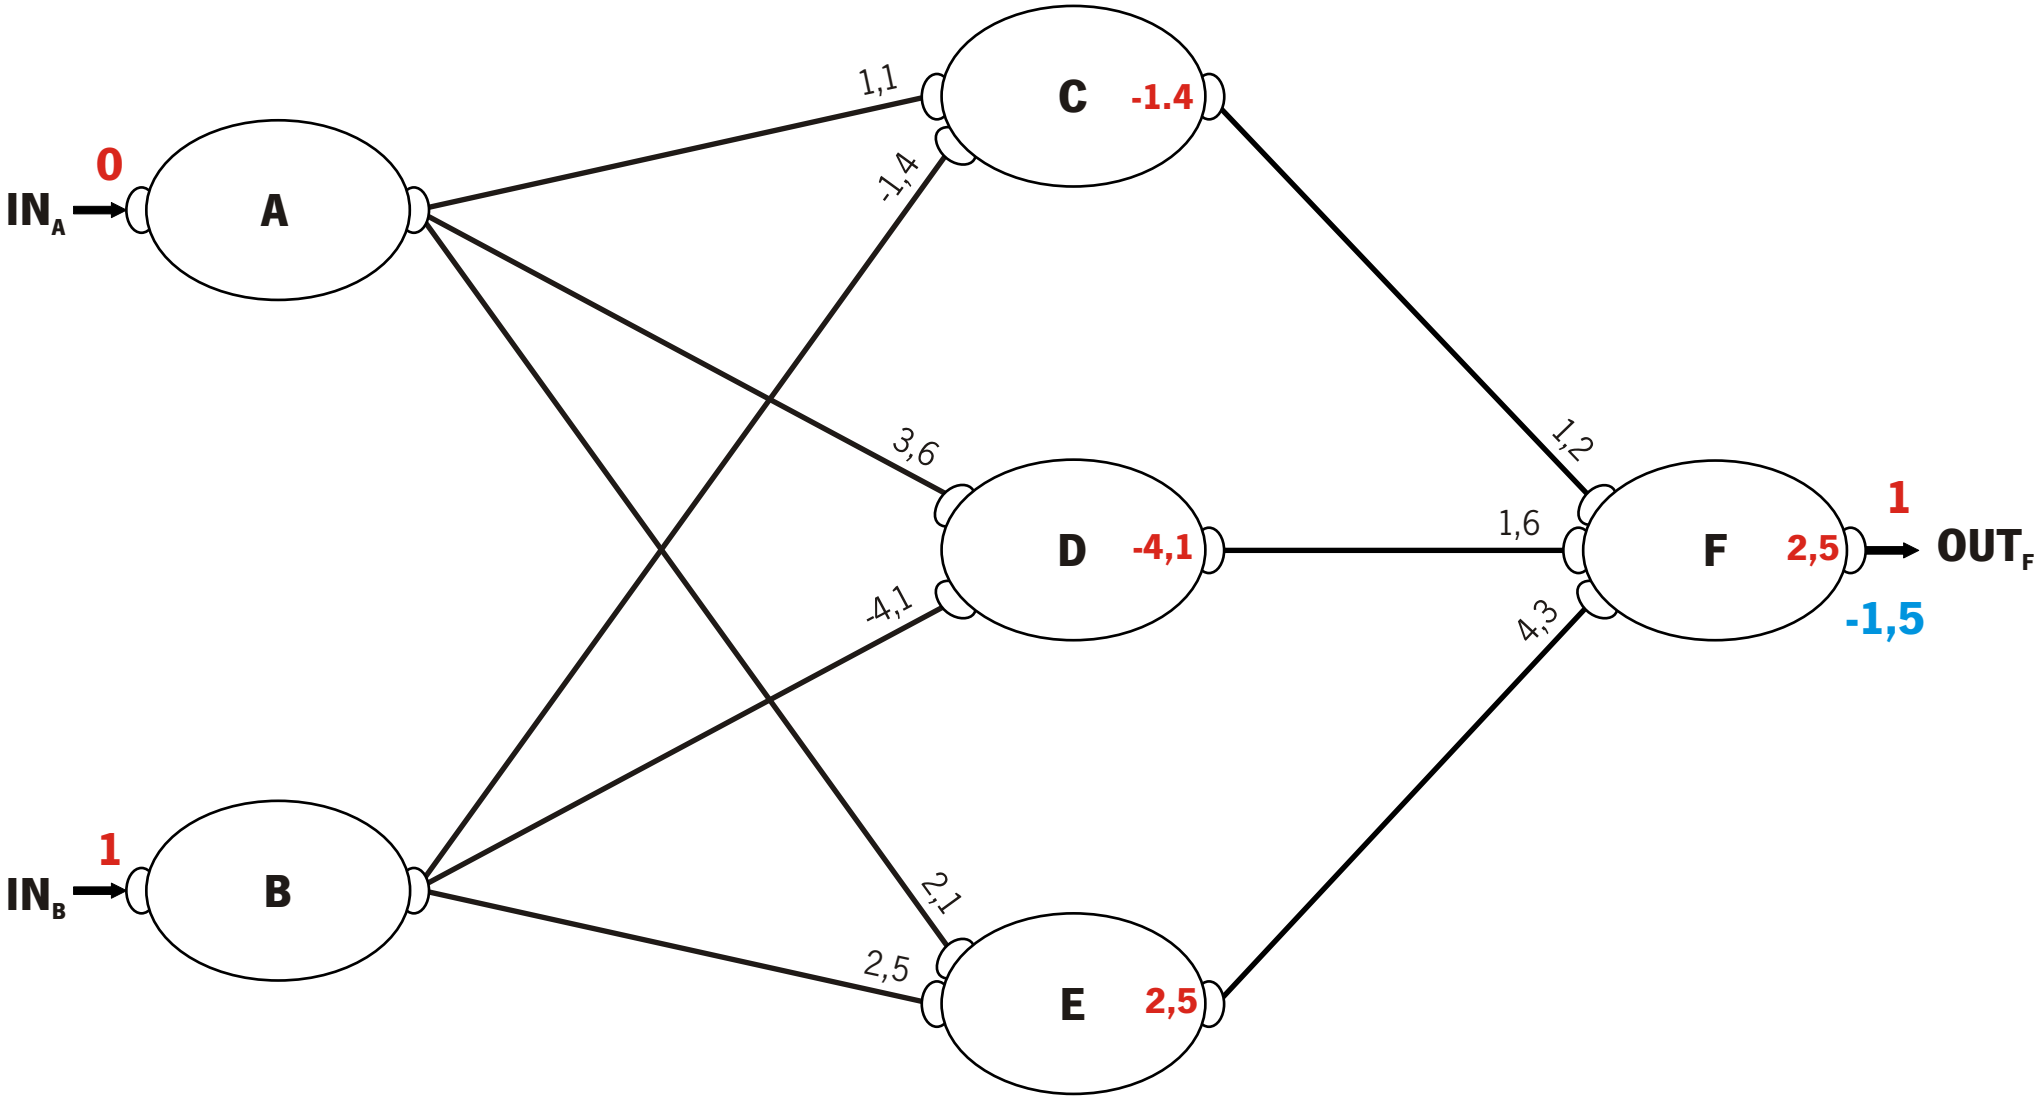

$$\mathcal{E} = OUT_{\mathcal{D}} - OUT_{C}$$

$$\mathcal{E}_{\leftarrow} = \mathcal{E} \times P$$

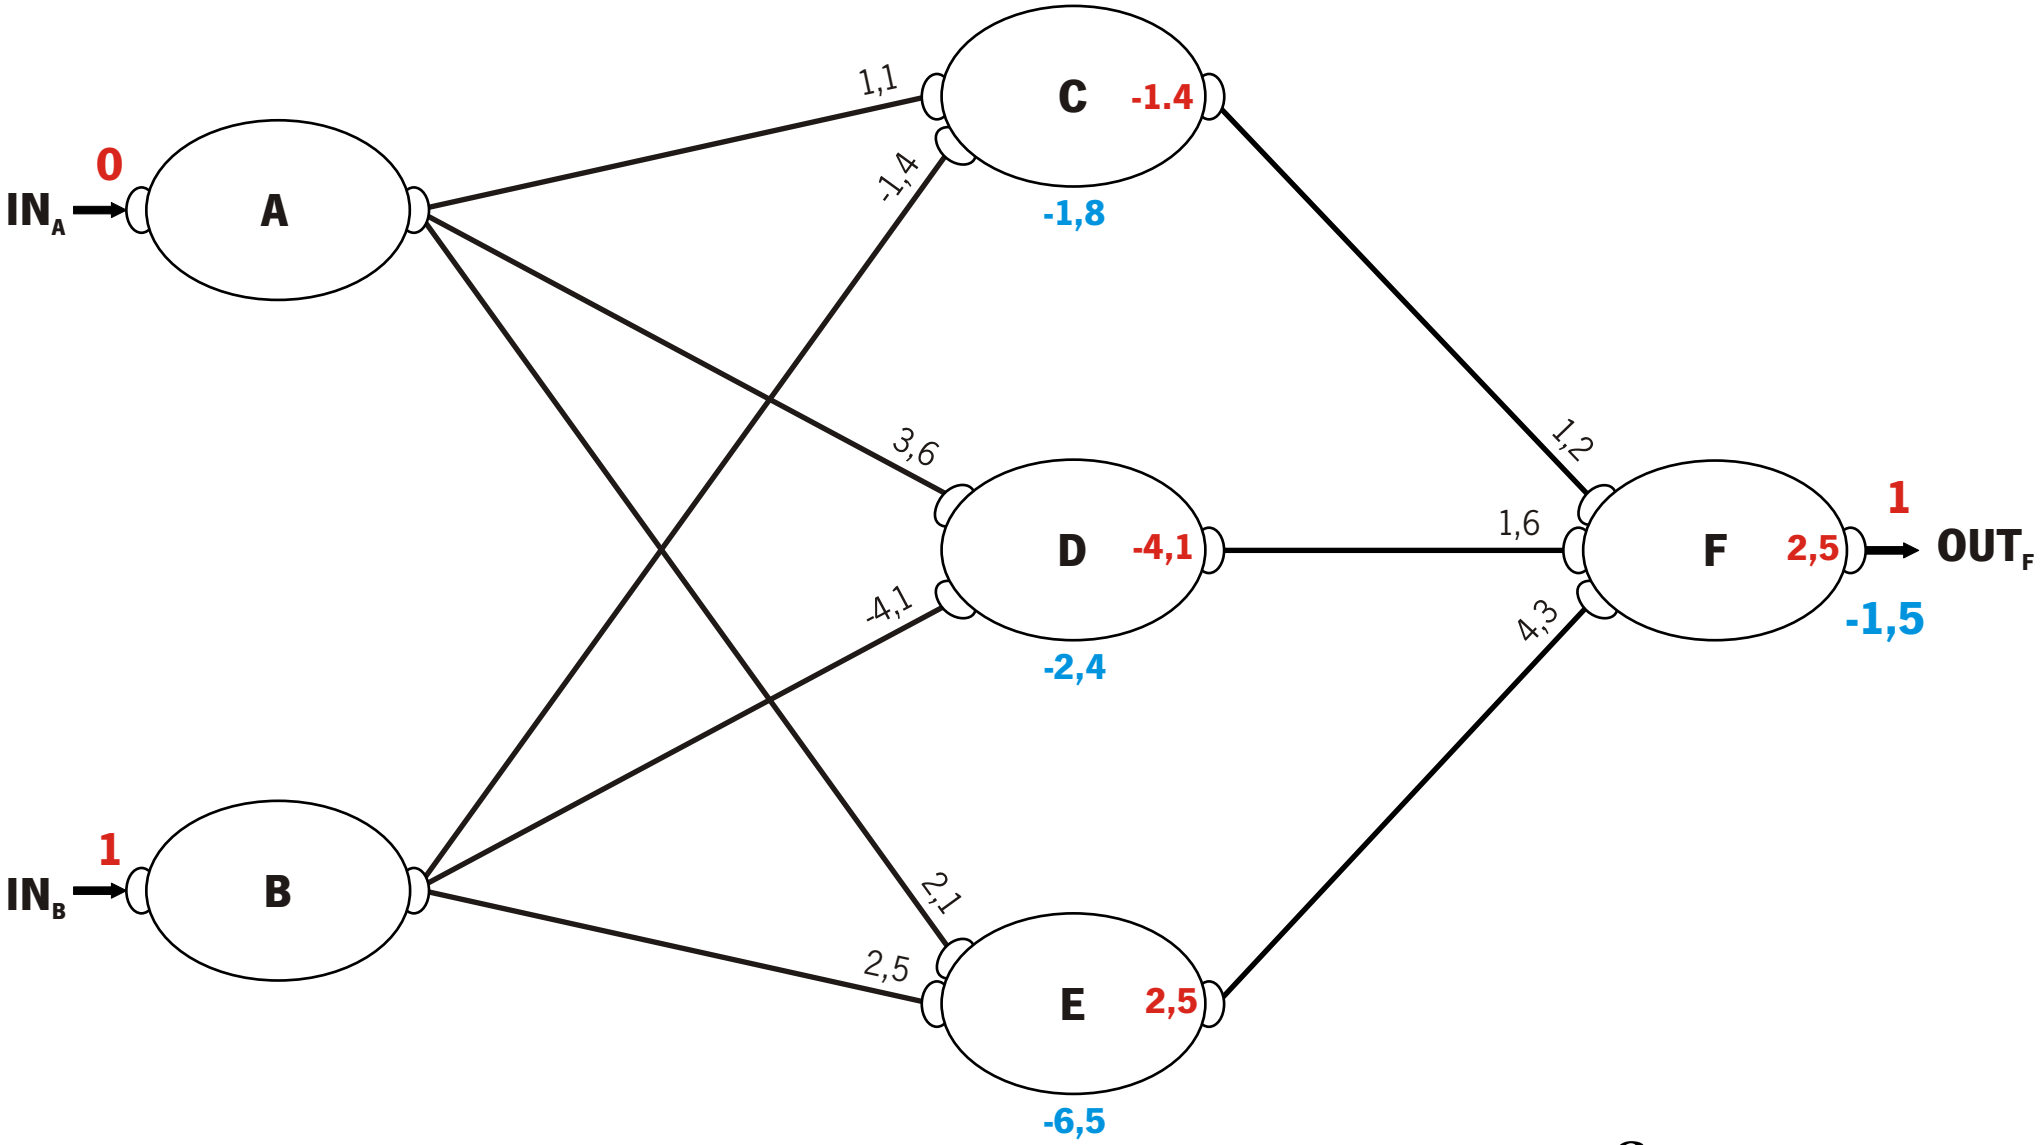

$$\mathcal{E} = OUT_{\mathcal{D}} - OUT_{C}$$

$$\mathcal{E}_{\leftarrow} = \mathcal{E} \times P$$

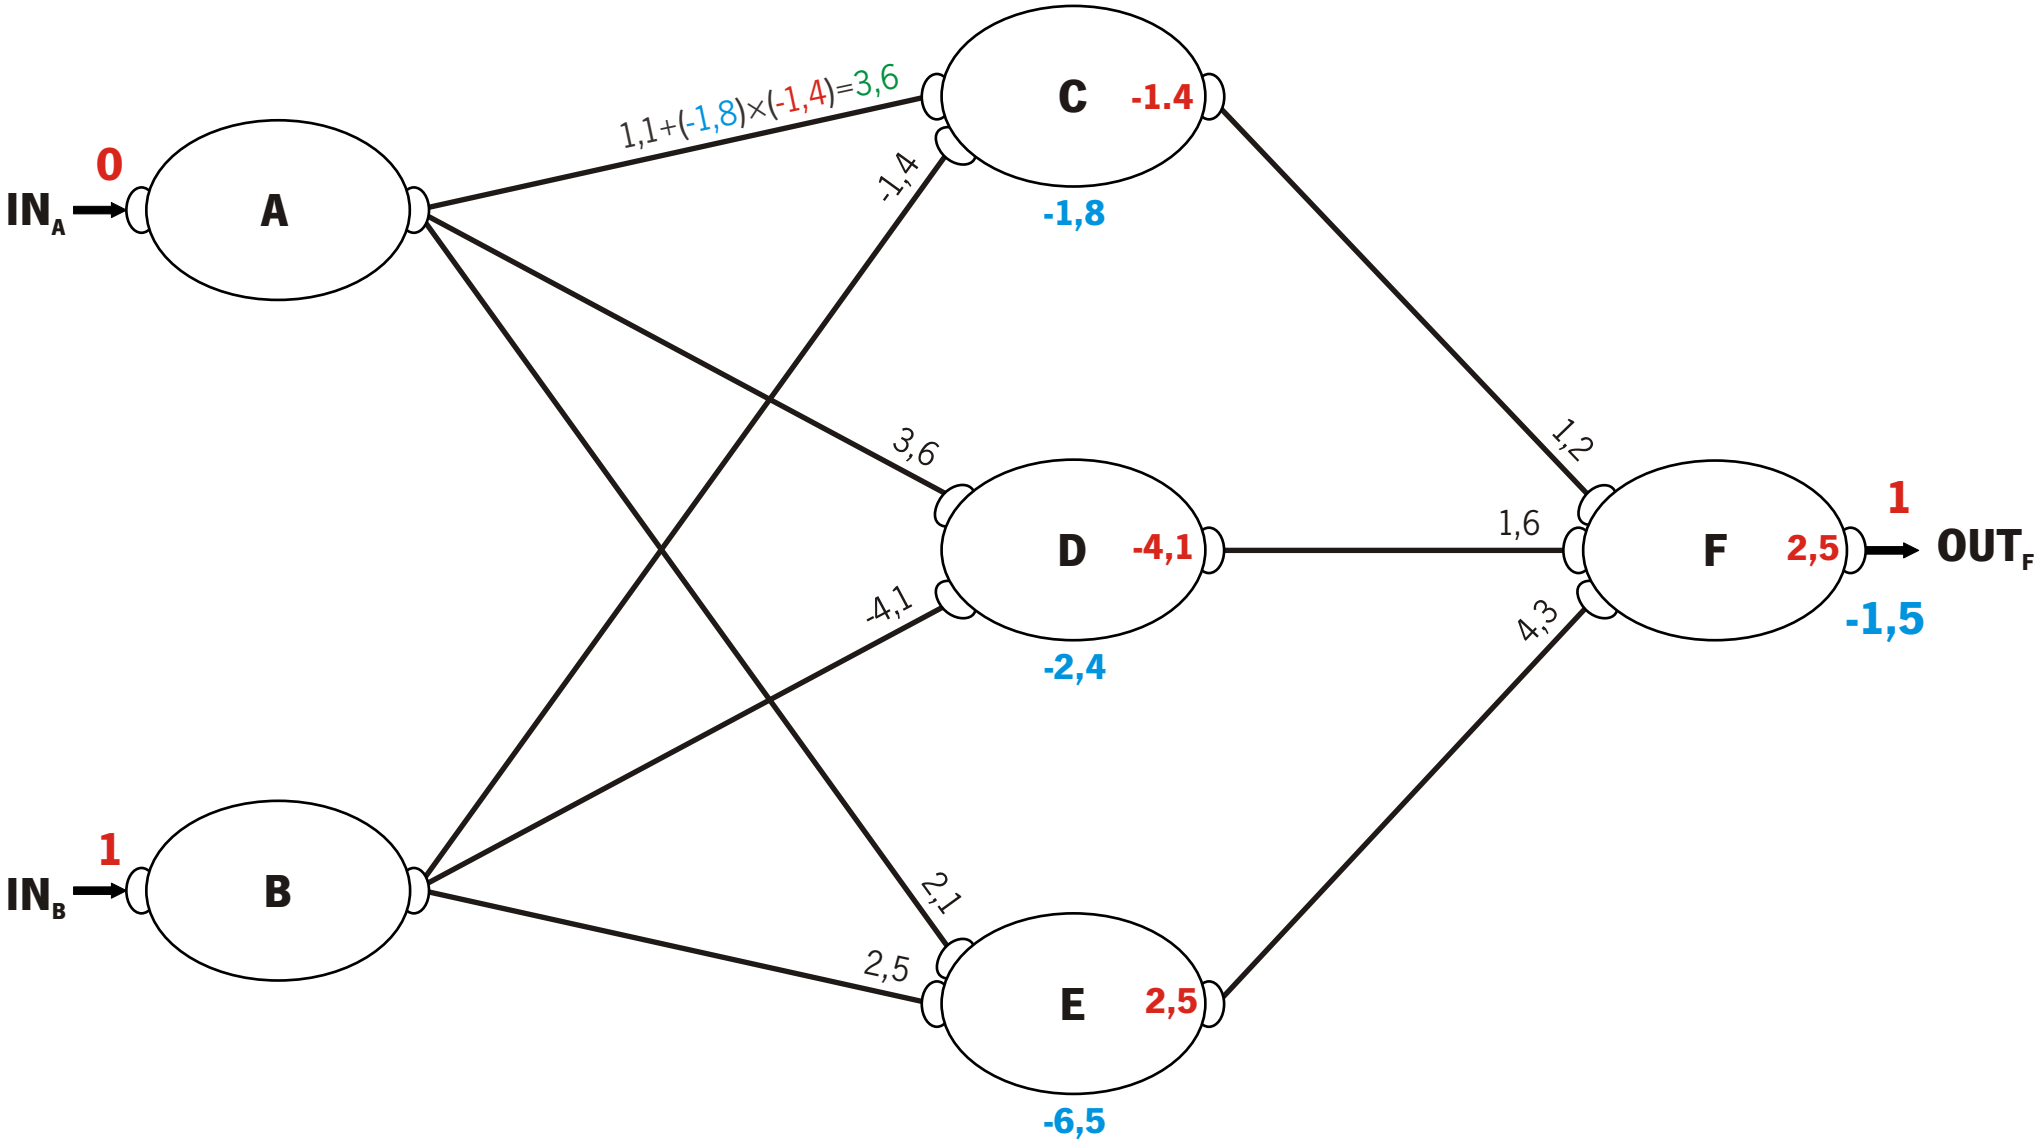

$$P_{i+1} = P_i + \varepsilon \times f_T$$

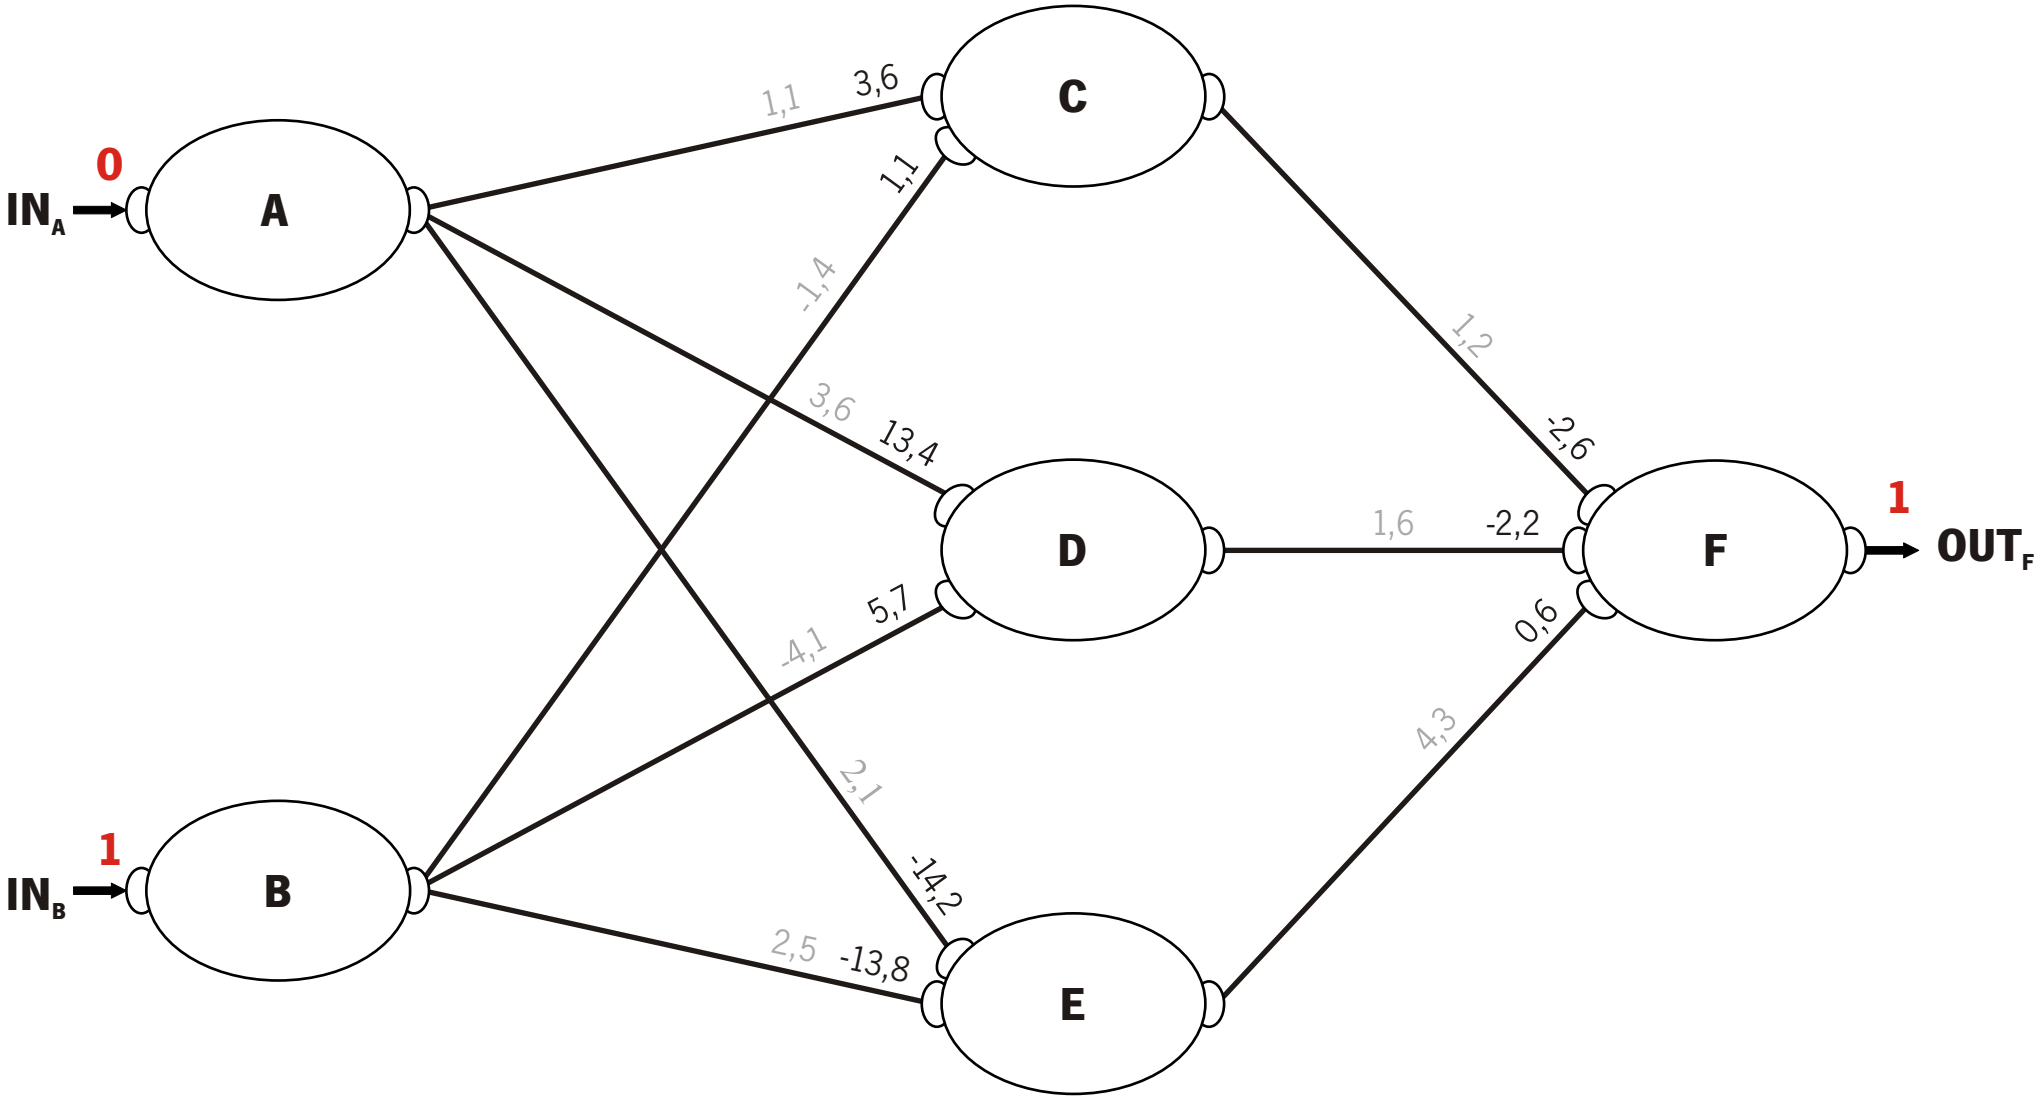

$$P_{i+1} = P_i + \varepsilon \times f_T$$

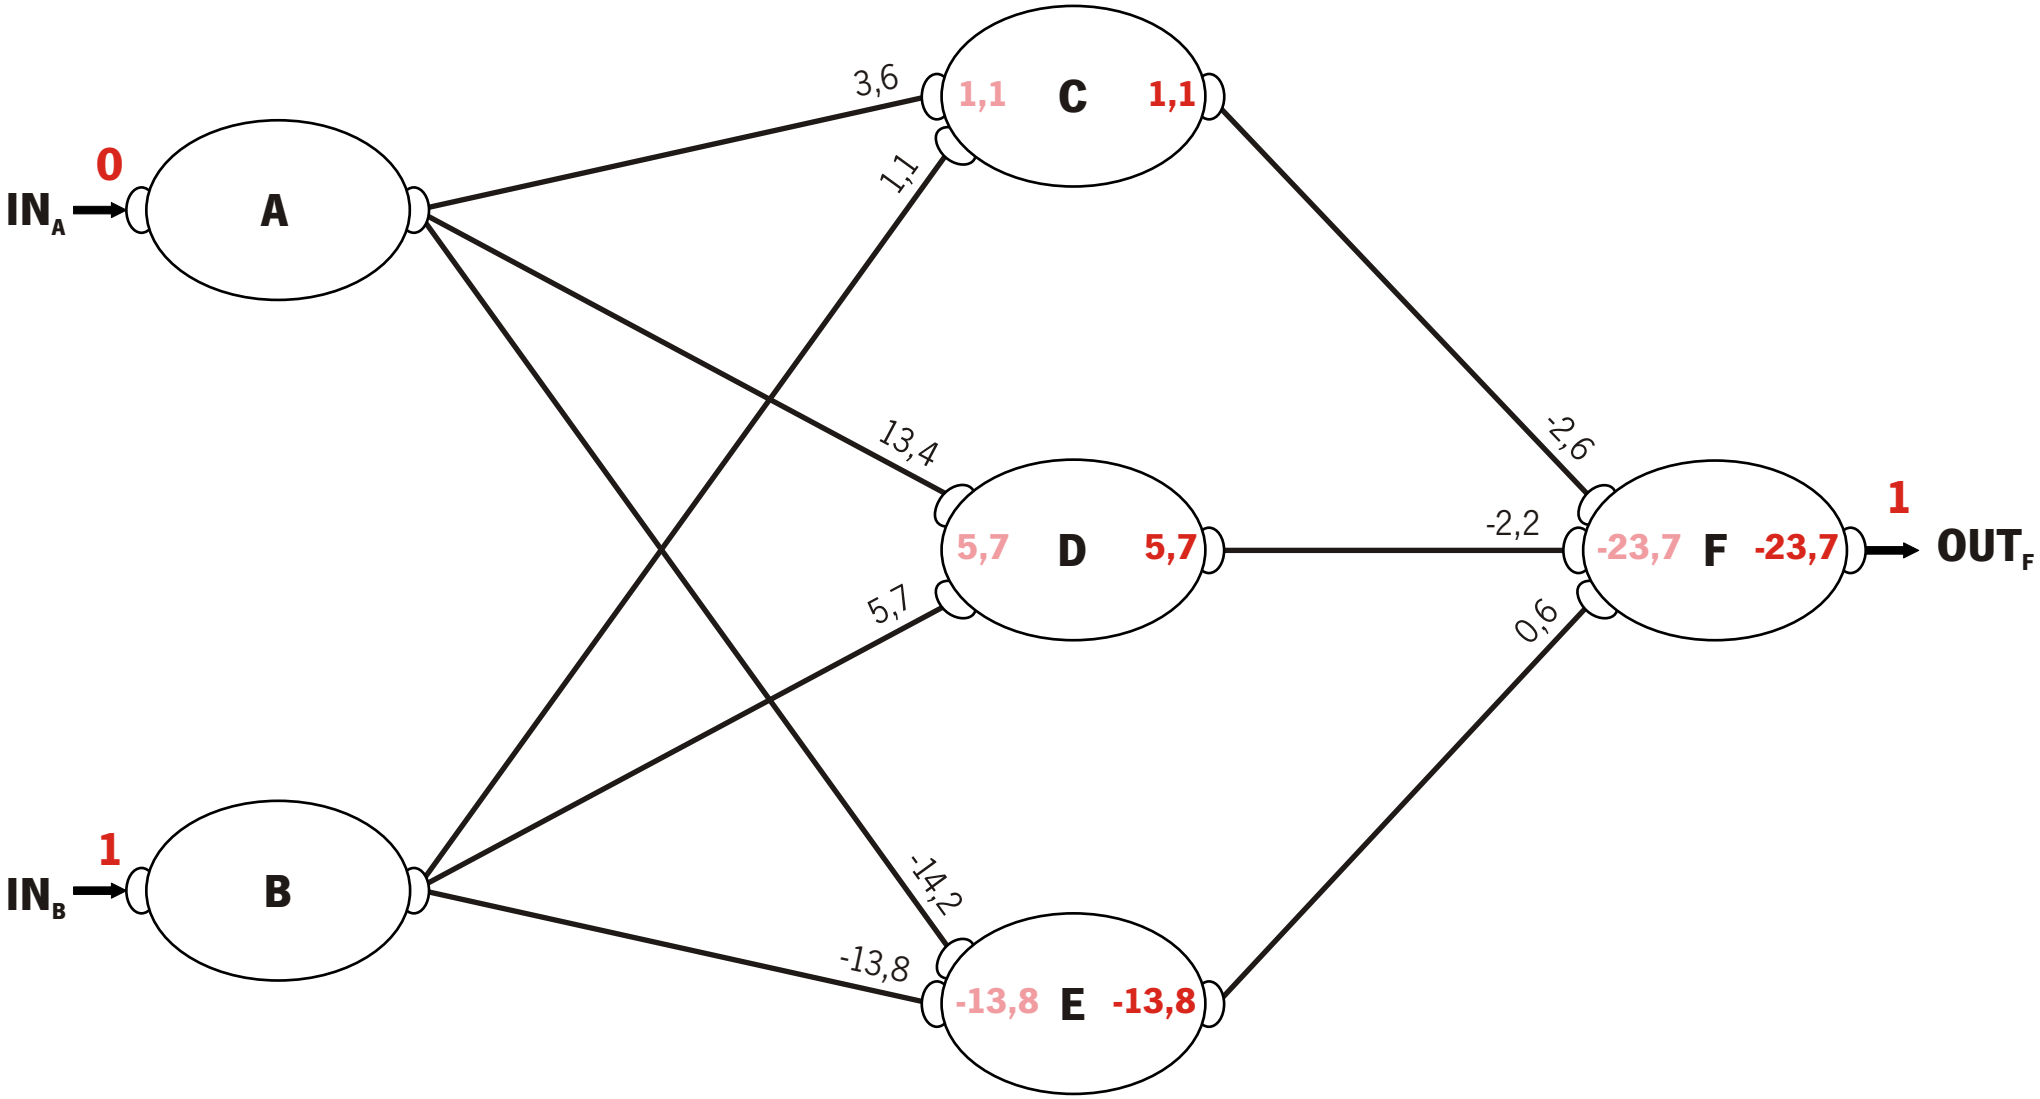

$$f_A(P,E) = \sum P \times E$$

$$f_T(A) = A$$

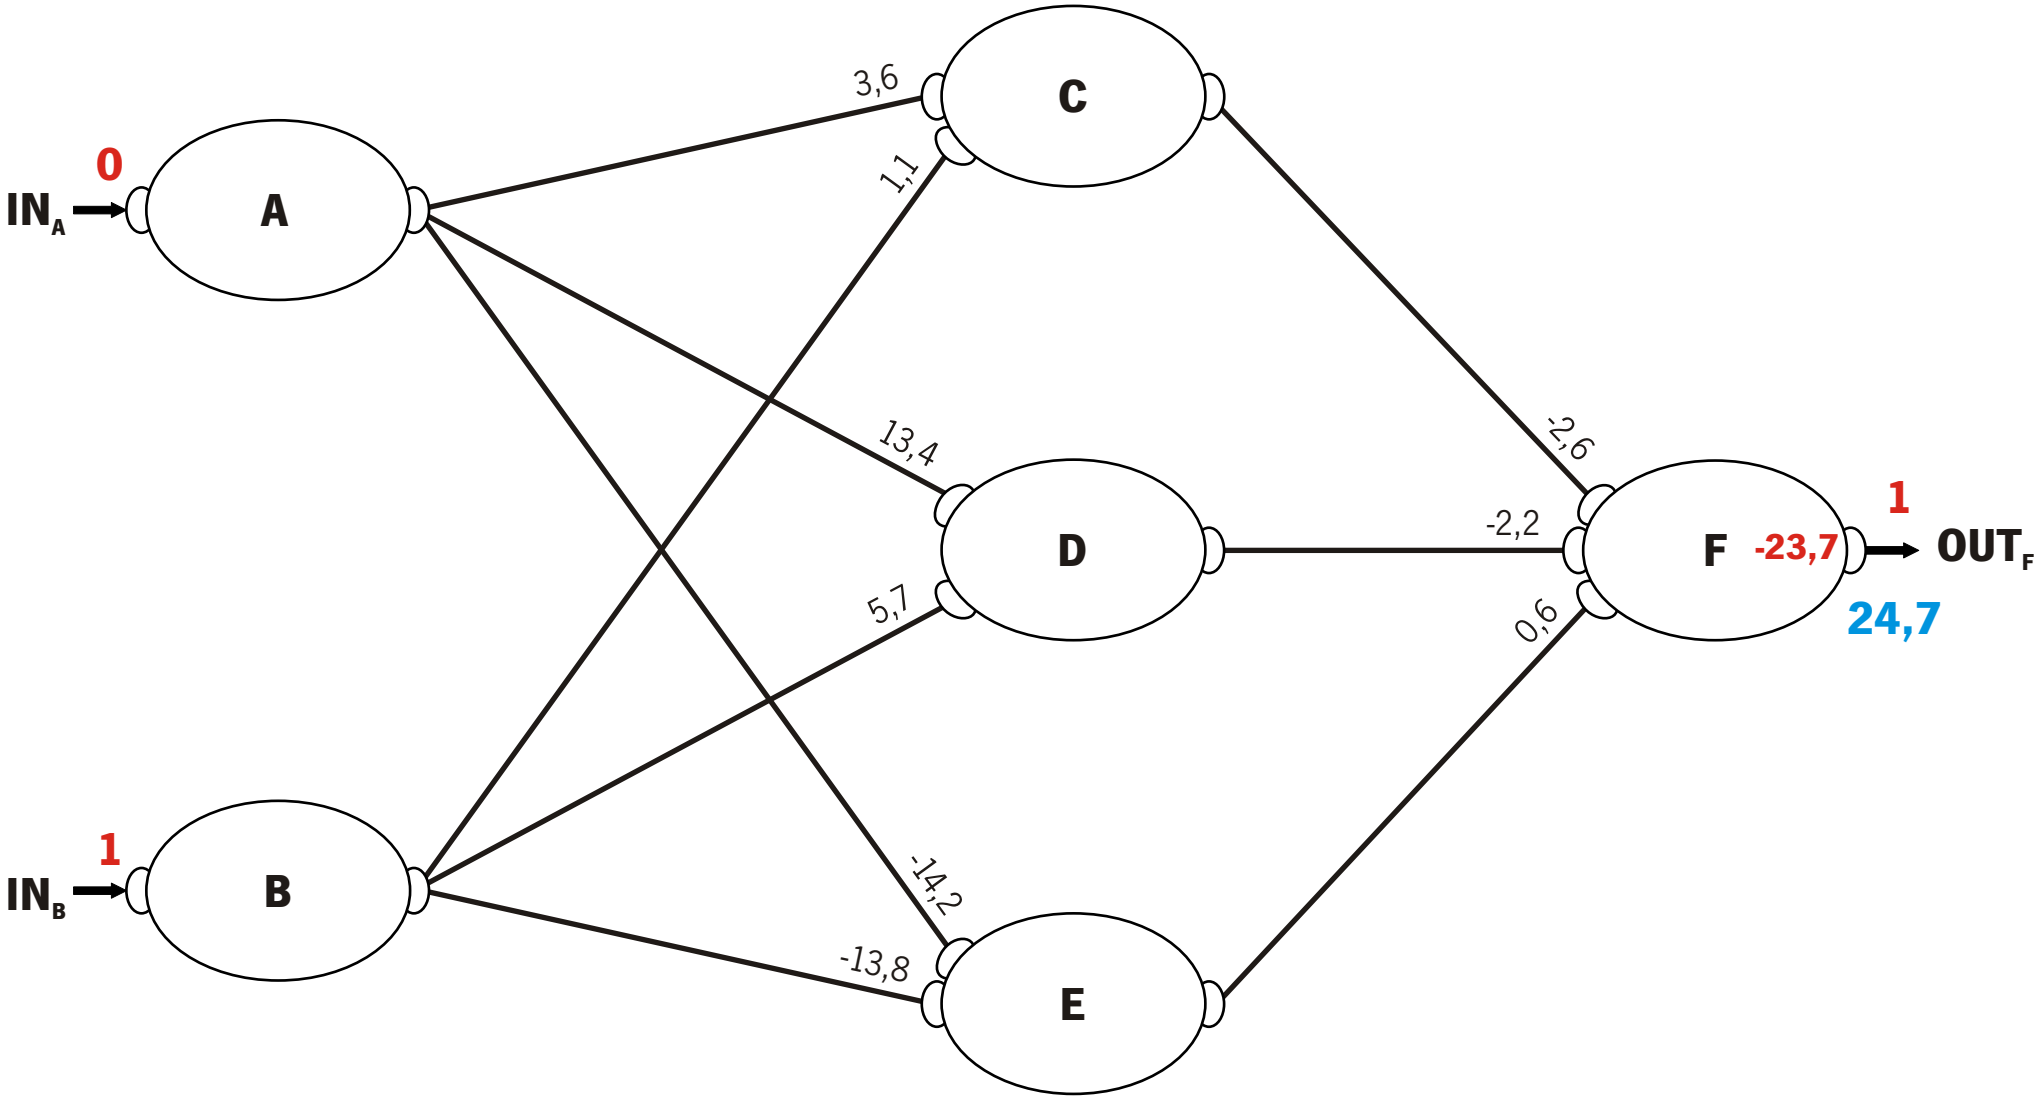
0
IN_A
A
1
IN_B
B
C
D
E
F
3,6
1,1
13,4
5,7
-14,2
-13,8
-2,6
-2,2
0,6
-23,7
1
OUT_F
24,7

ISLab
Synthetic Intelligence Lab

Treino de RNAs

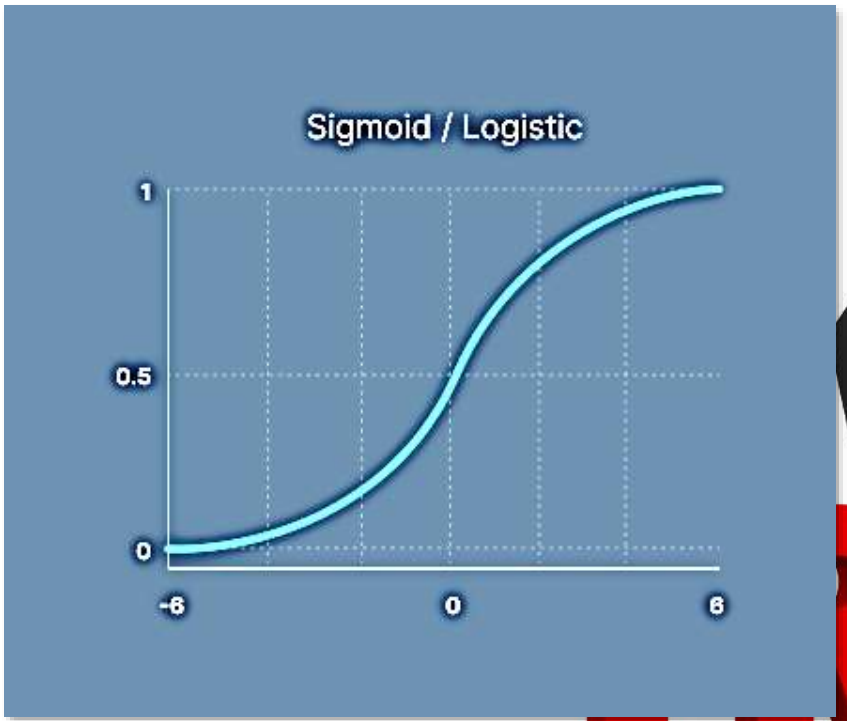

RNA

Universidade do Minho

Cesar Analide, Paulo Novais, José Neves

RNA - Treino Sigmoid

(1)


RNA

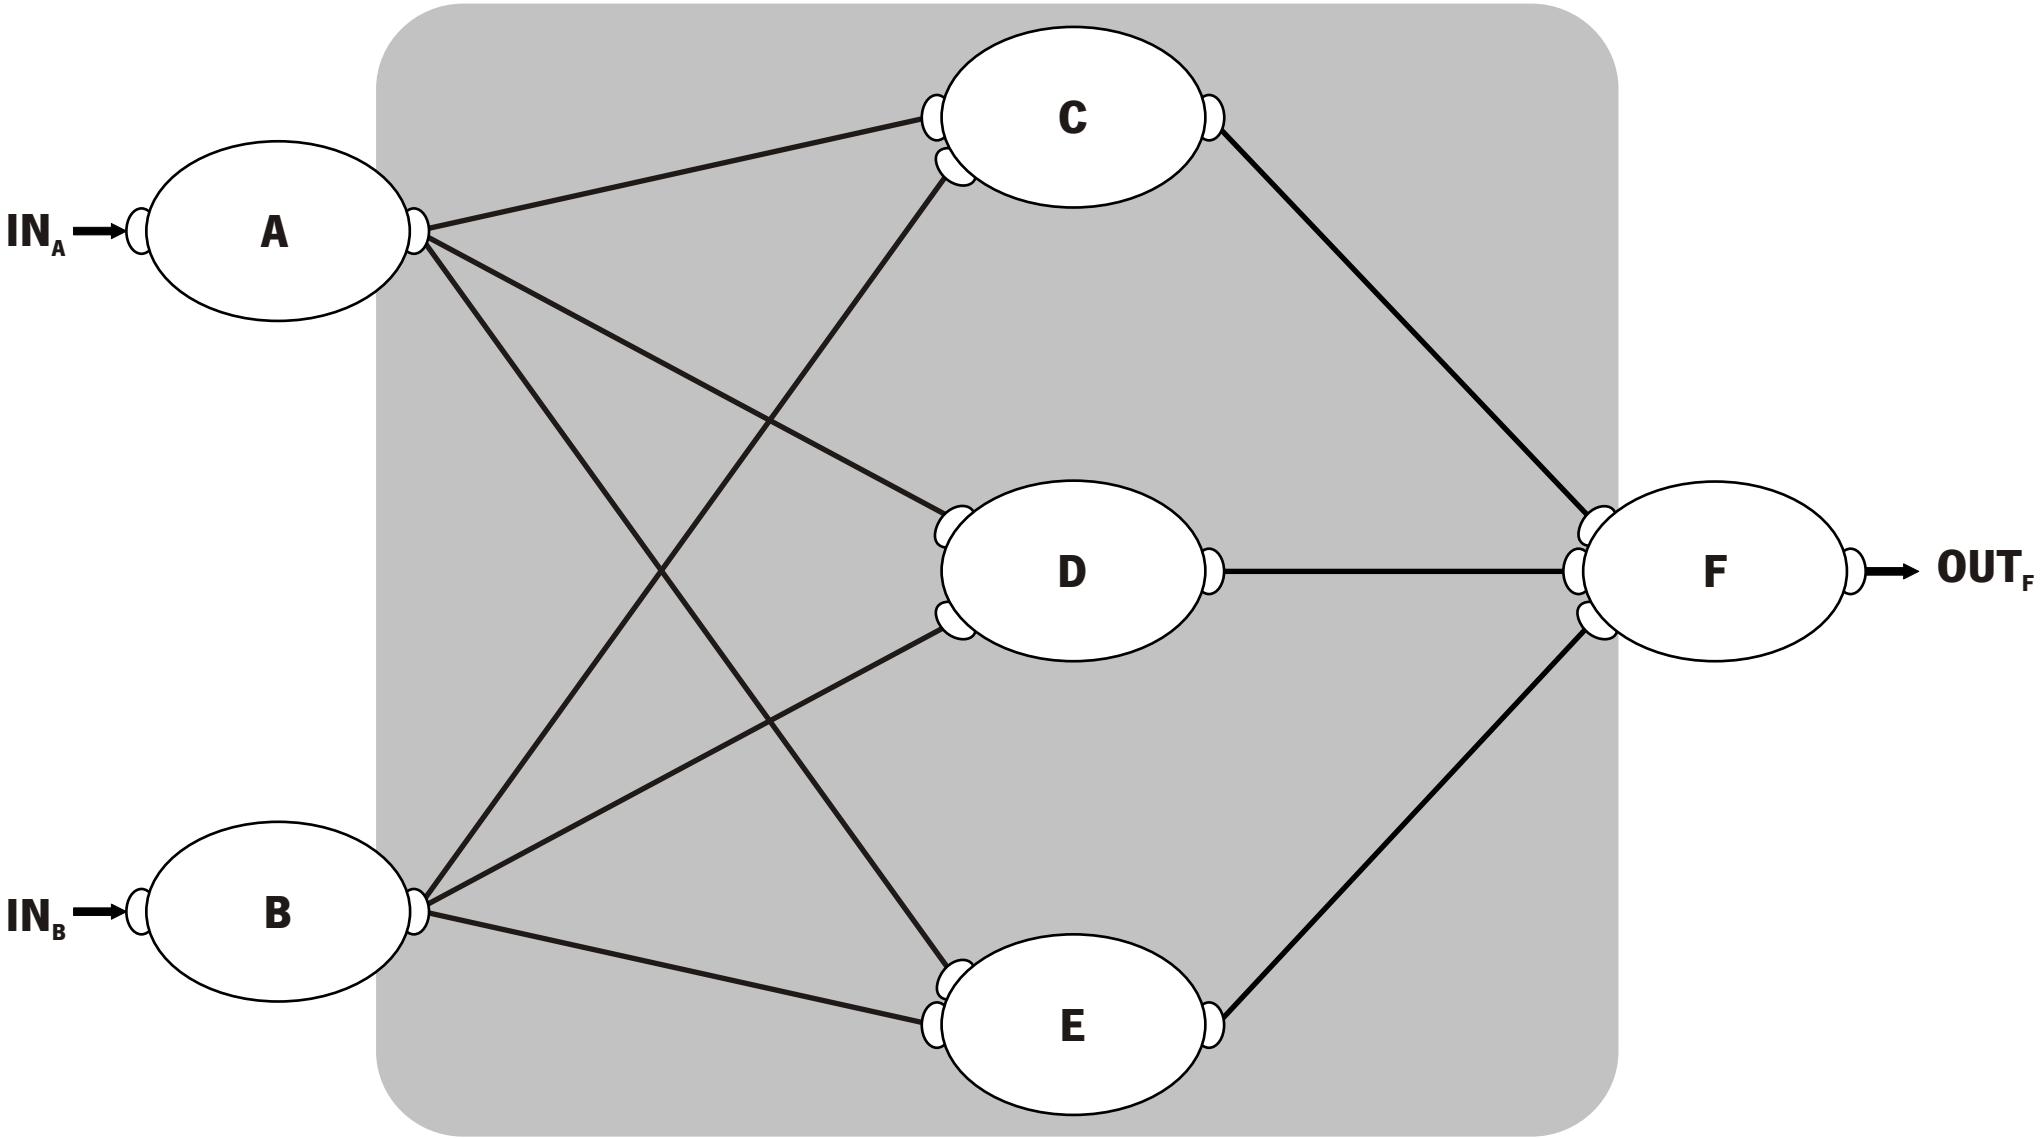
IN_A
A
C
IN_B
B
D
E
F
OUT_F

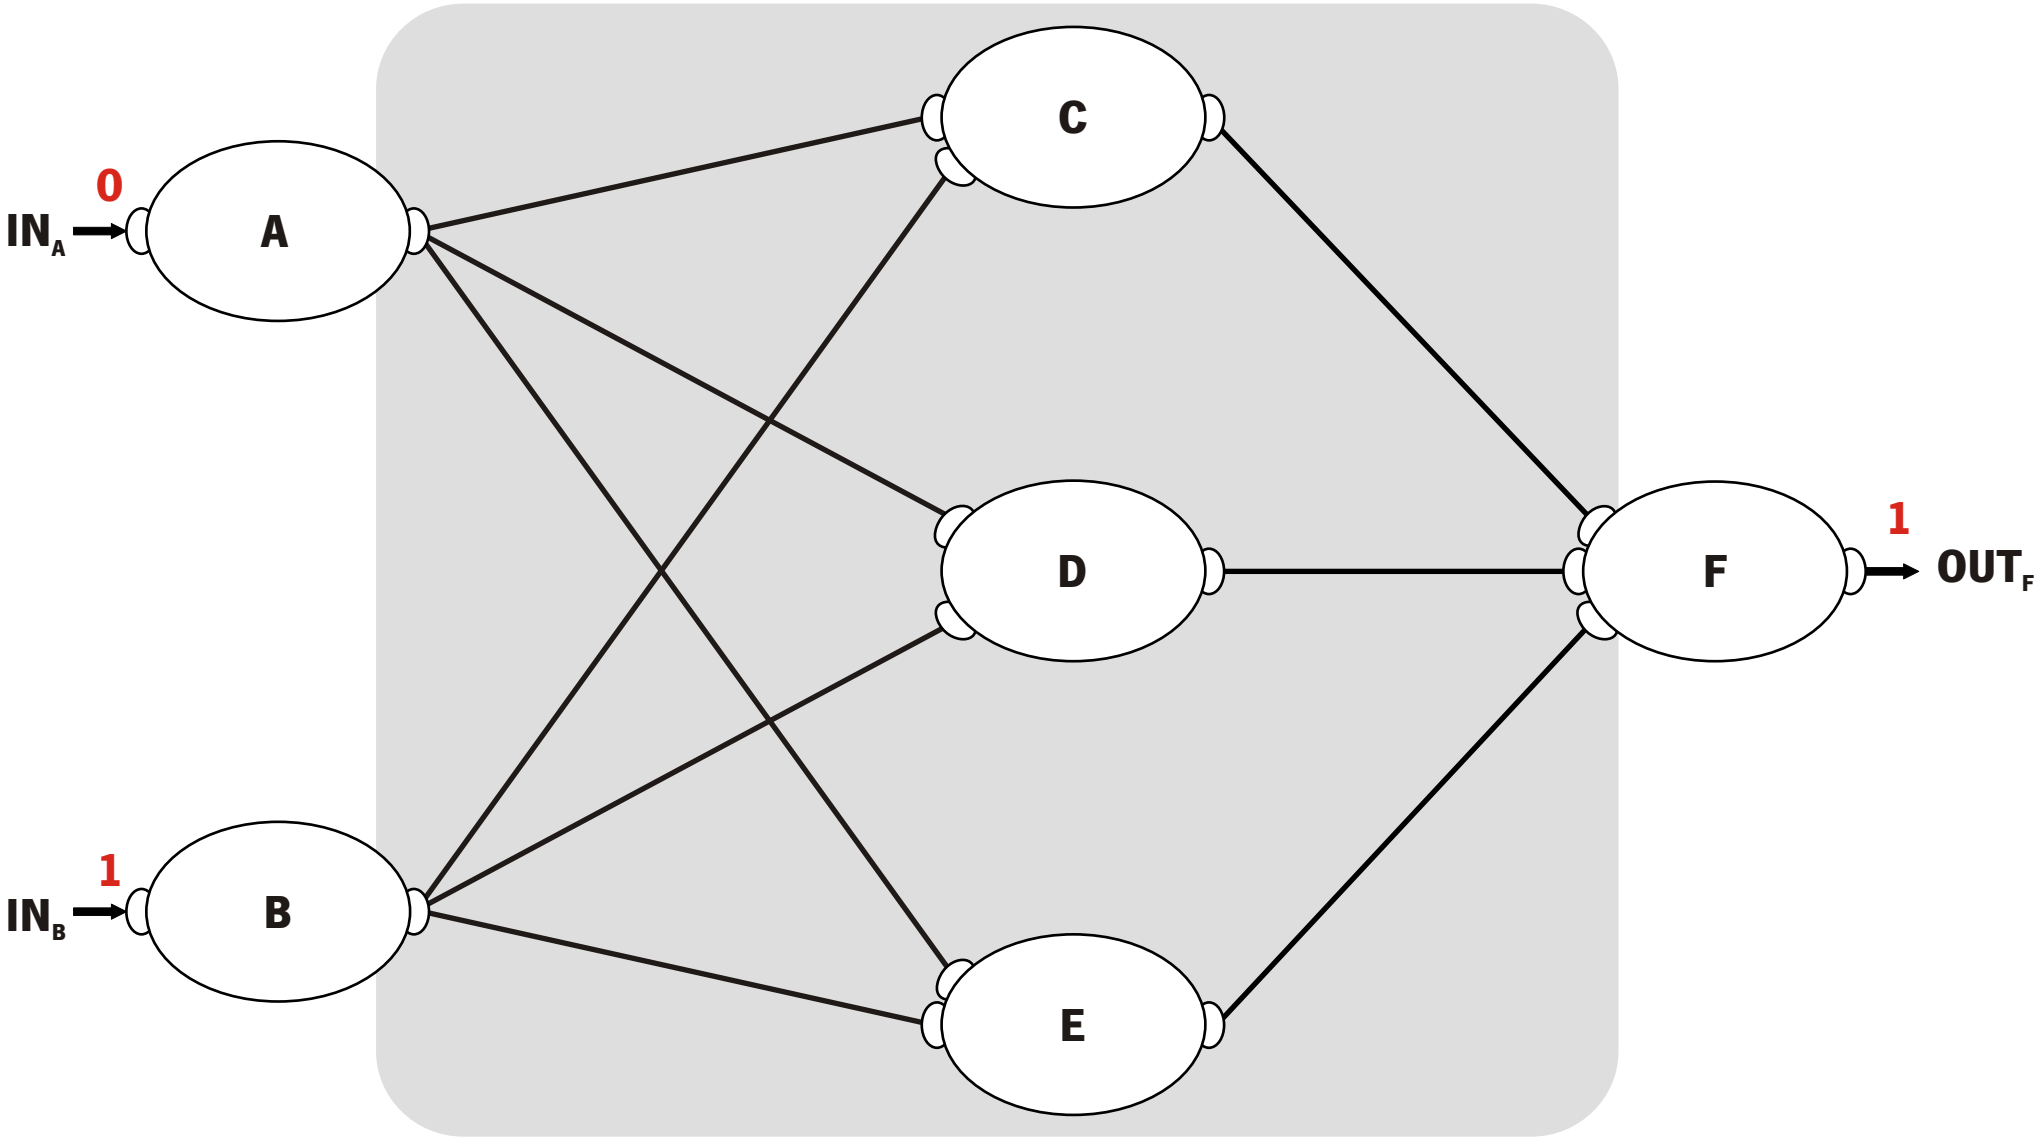
0
IN_A
A
1
IN_B
B
C
D
E
F
1
OUT_F

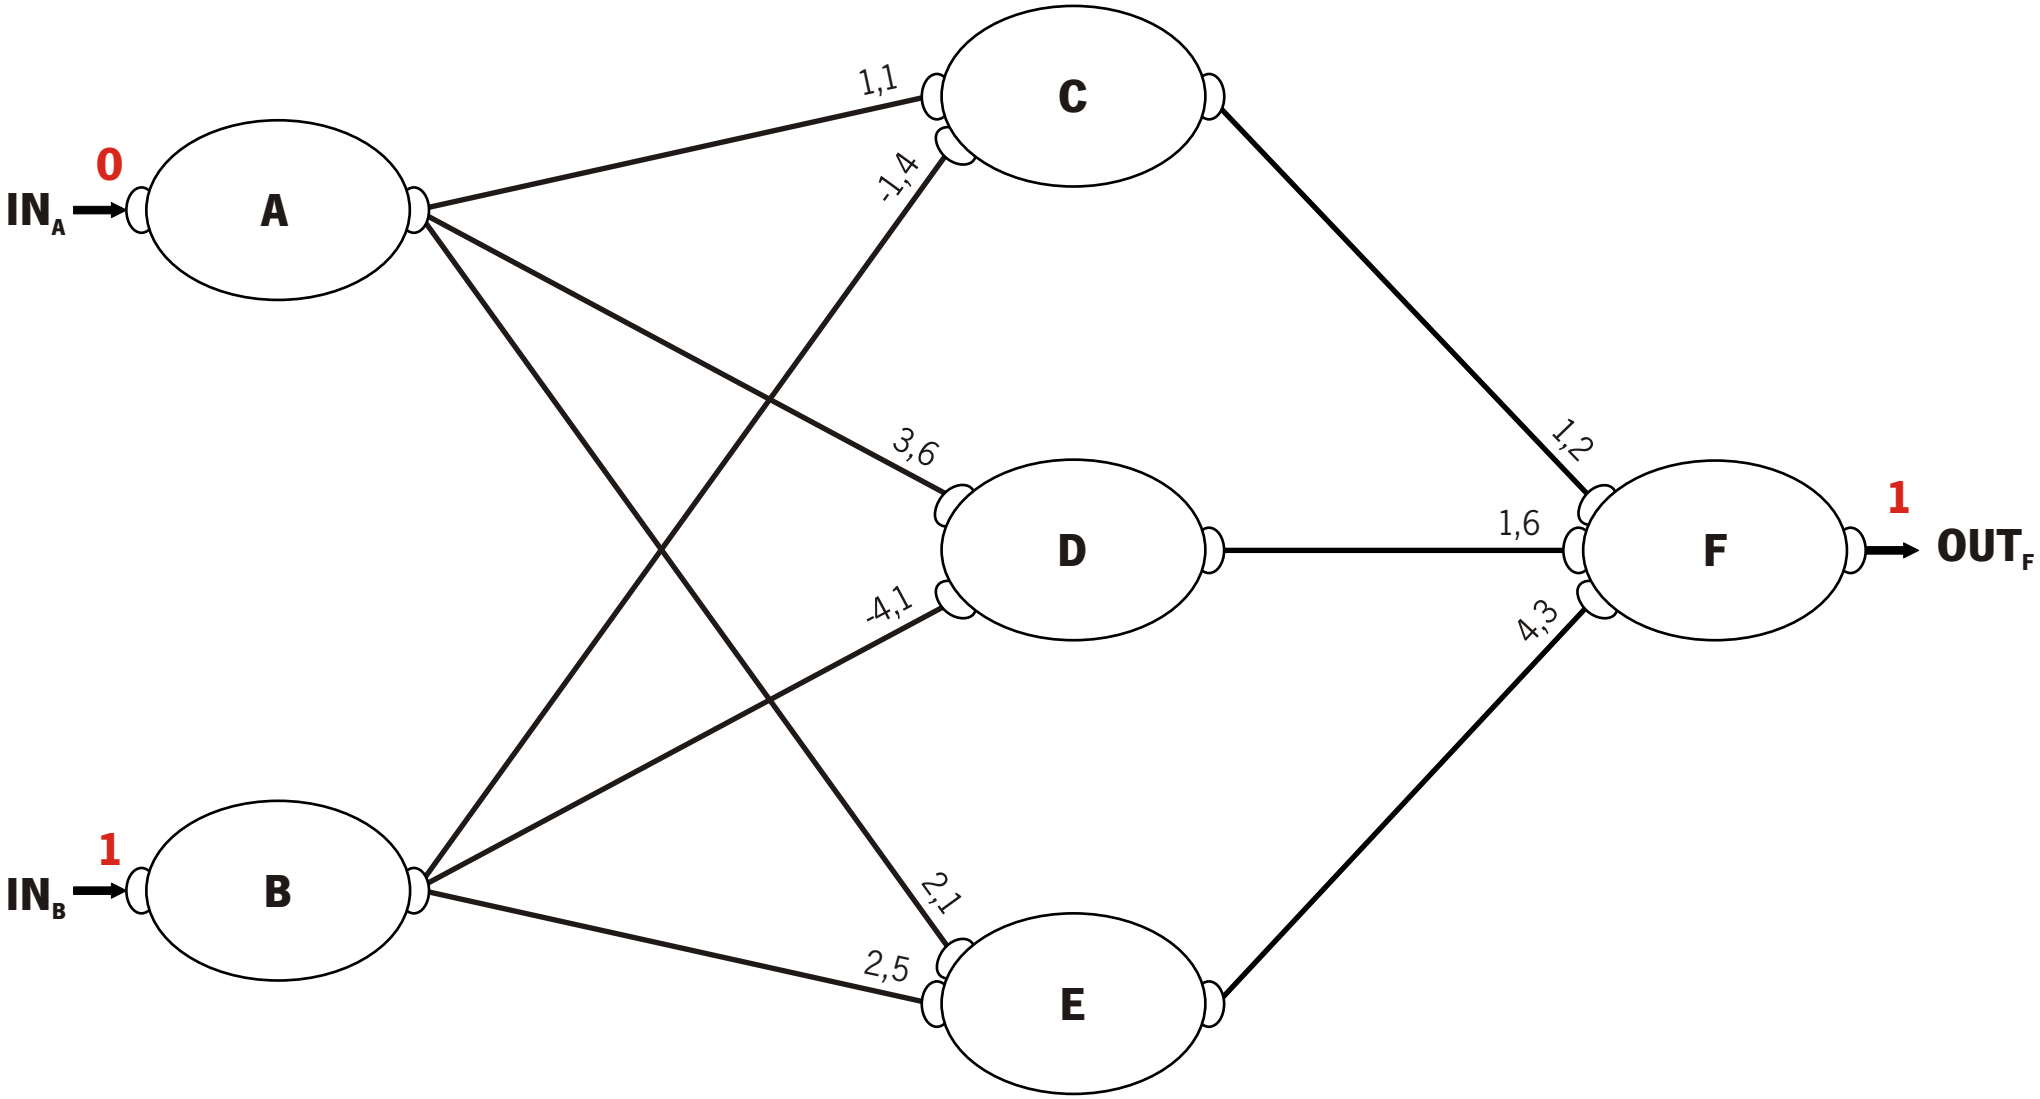

$$f_A(P,E) = \sum P \times E$$

$$f_T(A) = \frac{1}{1 + e^{-A}}$$

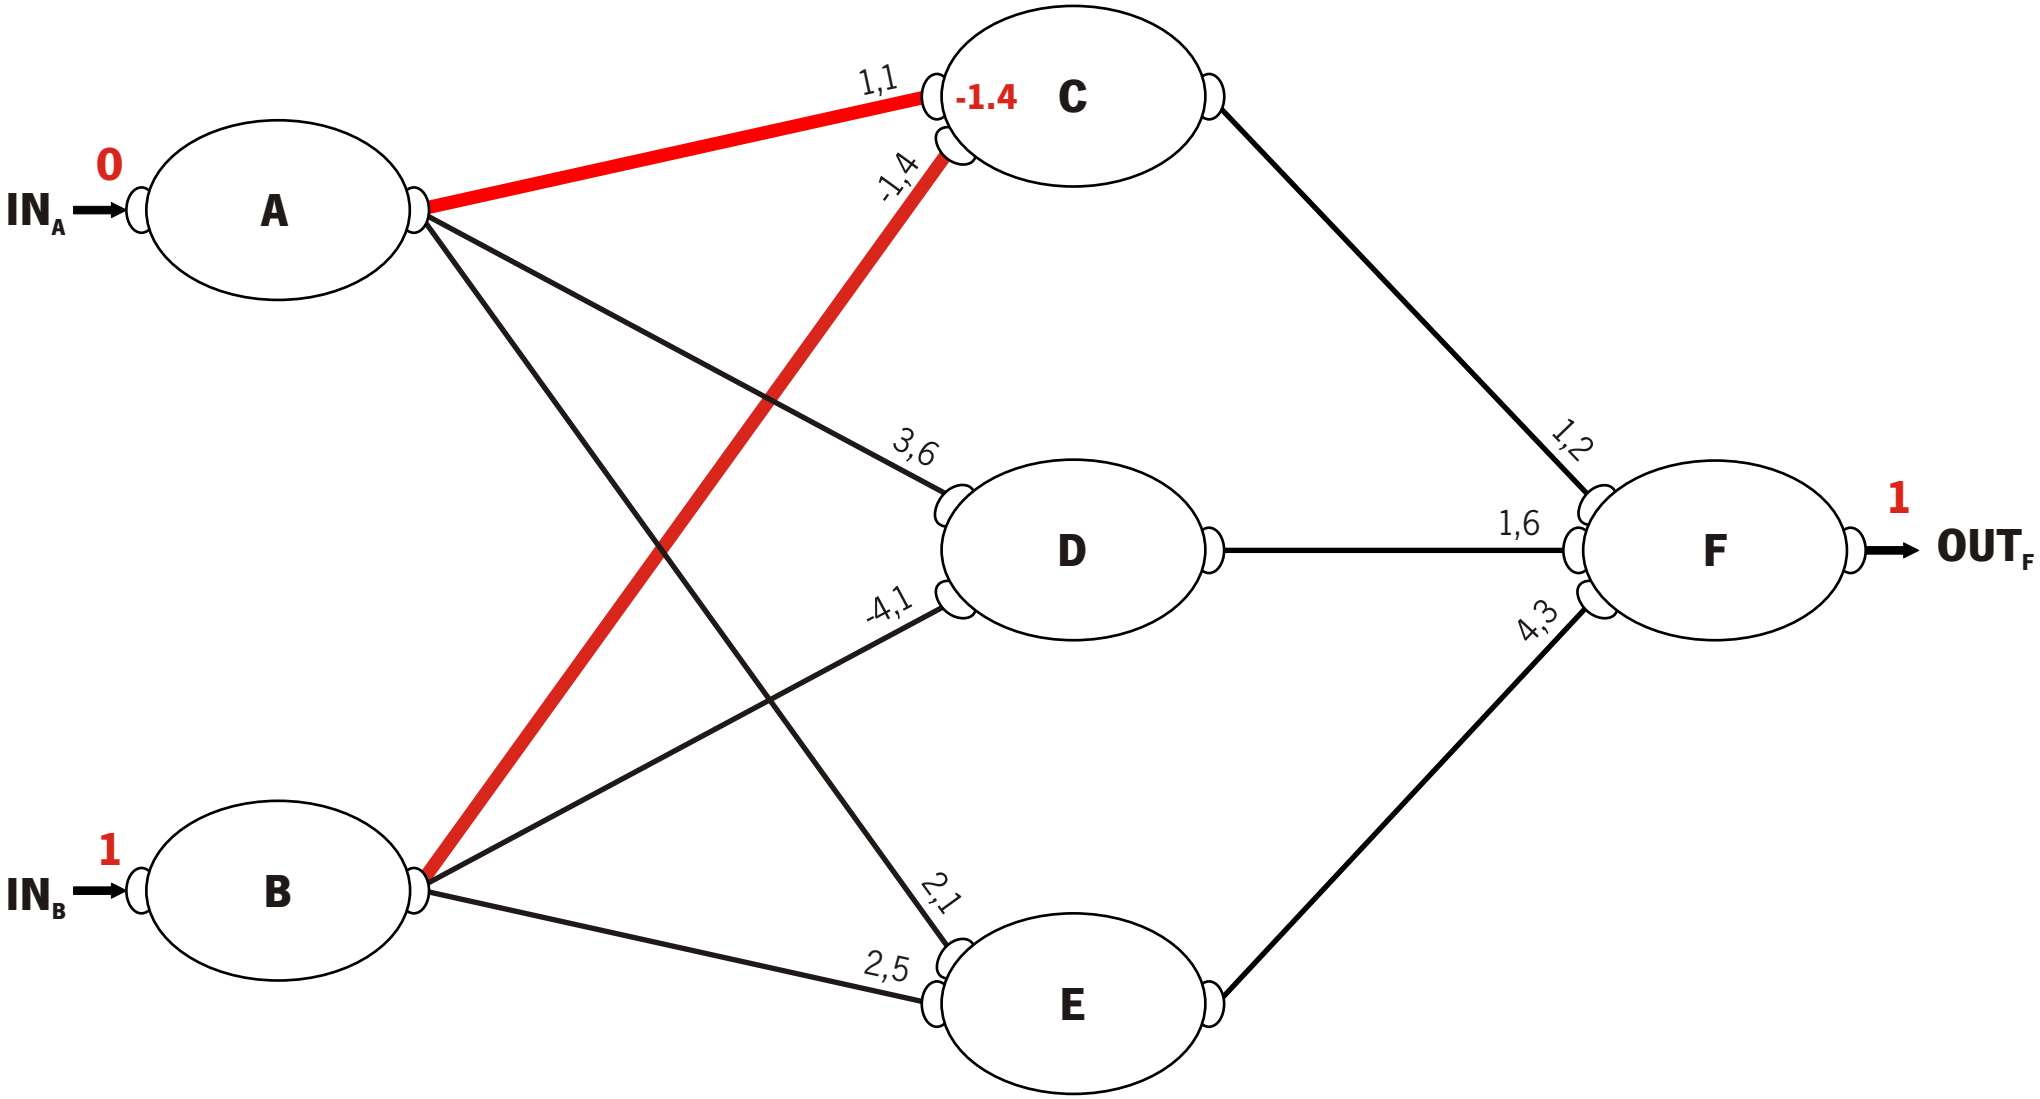

$$f_A(P,E) = \sum P \times E$$

$$f_T(A) = \frac{1}{1 + e^{-A}}$$

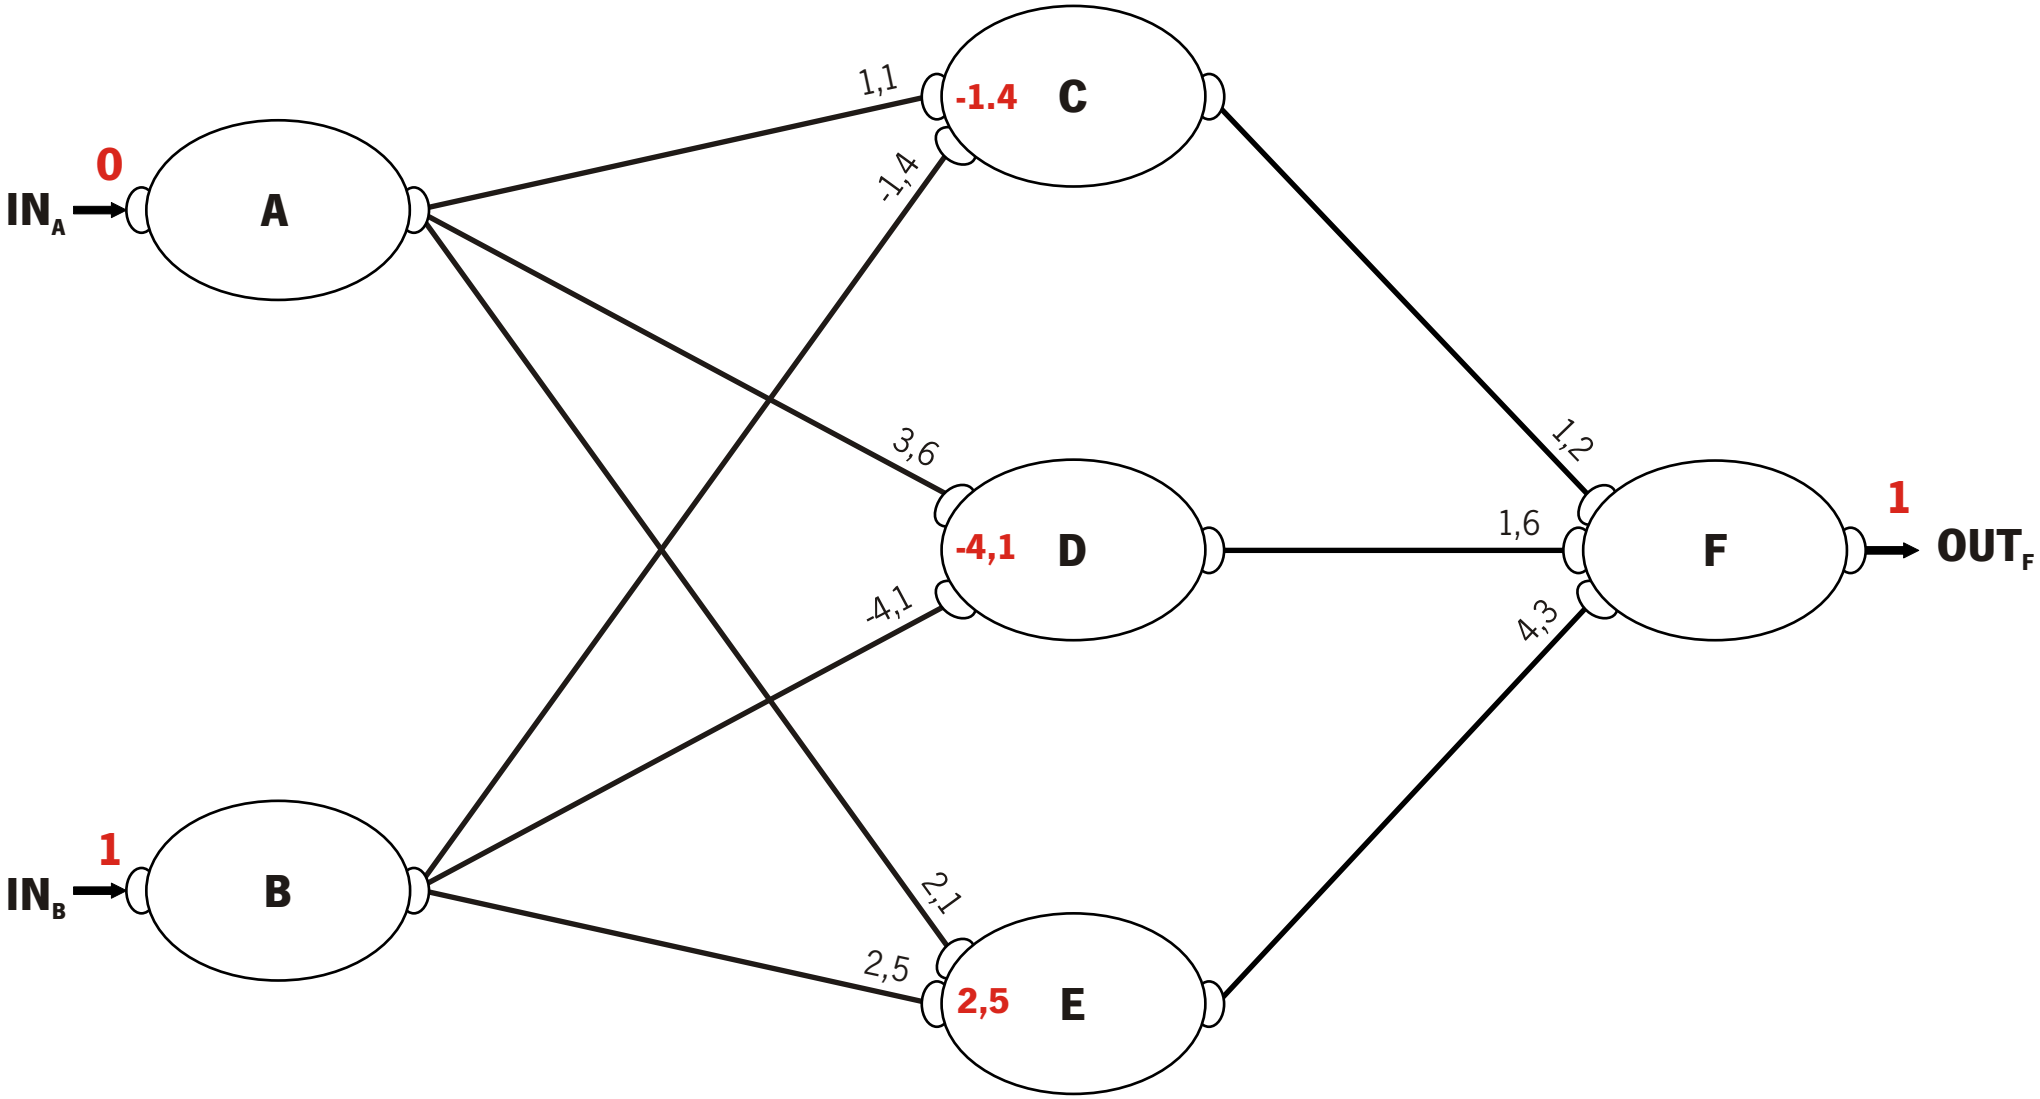

$$f_A(P,E) = \sum P \times E$$

$$f_T(A) = \frac{1}{1 + e^{-A}}$$

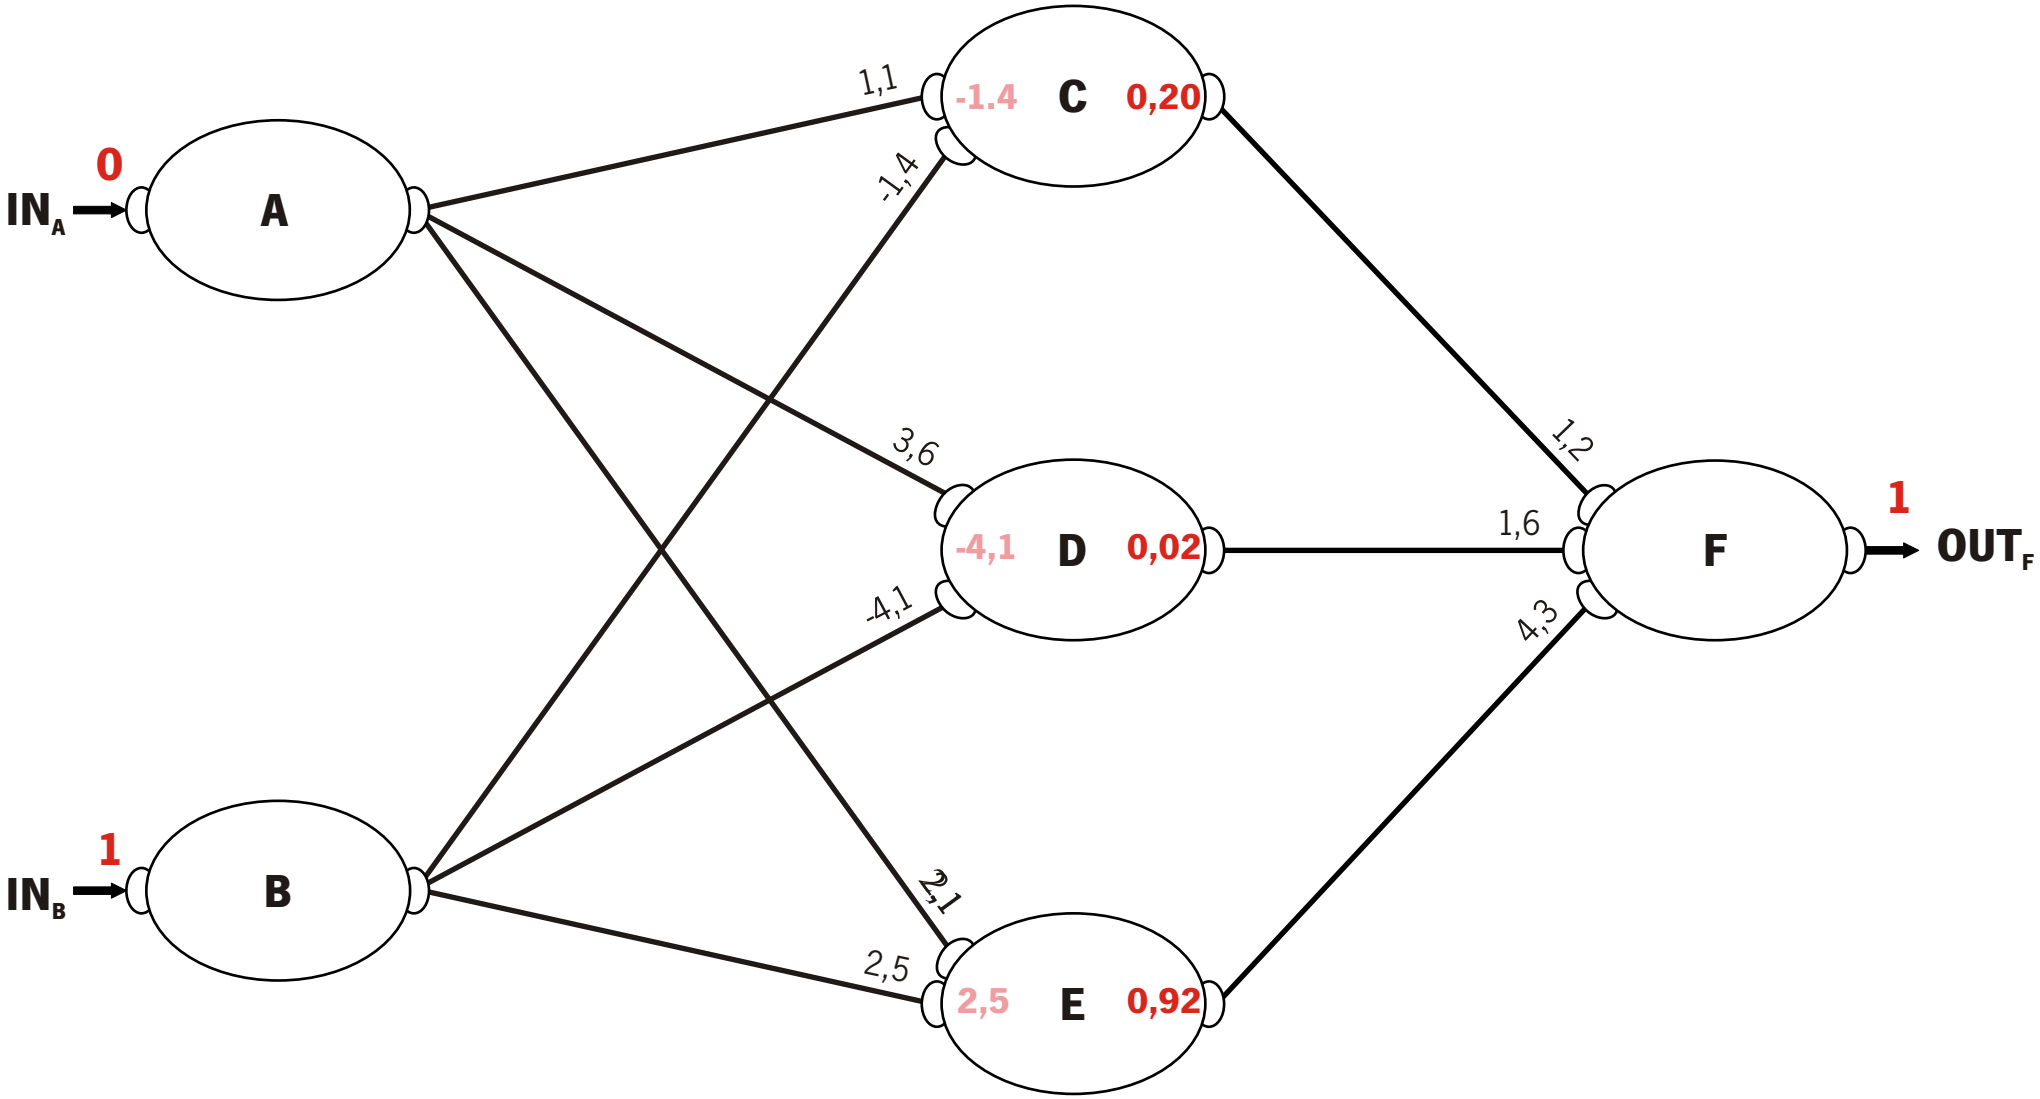

$$f_A(P,E) = \sum P \times E$$

$$f_T(A) = \frac{1}{1 + e^{-A}}$$

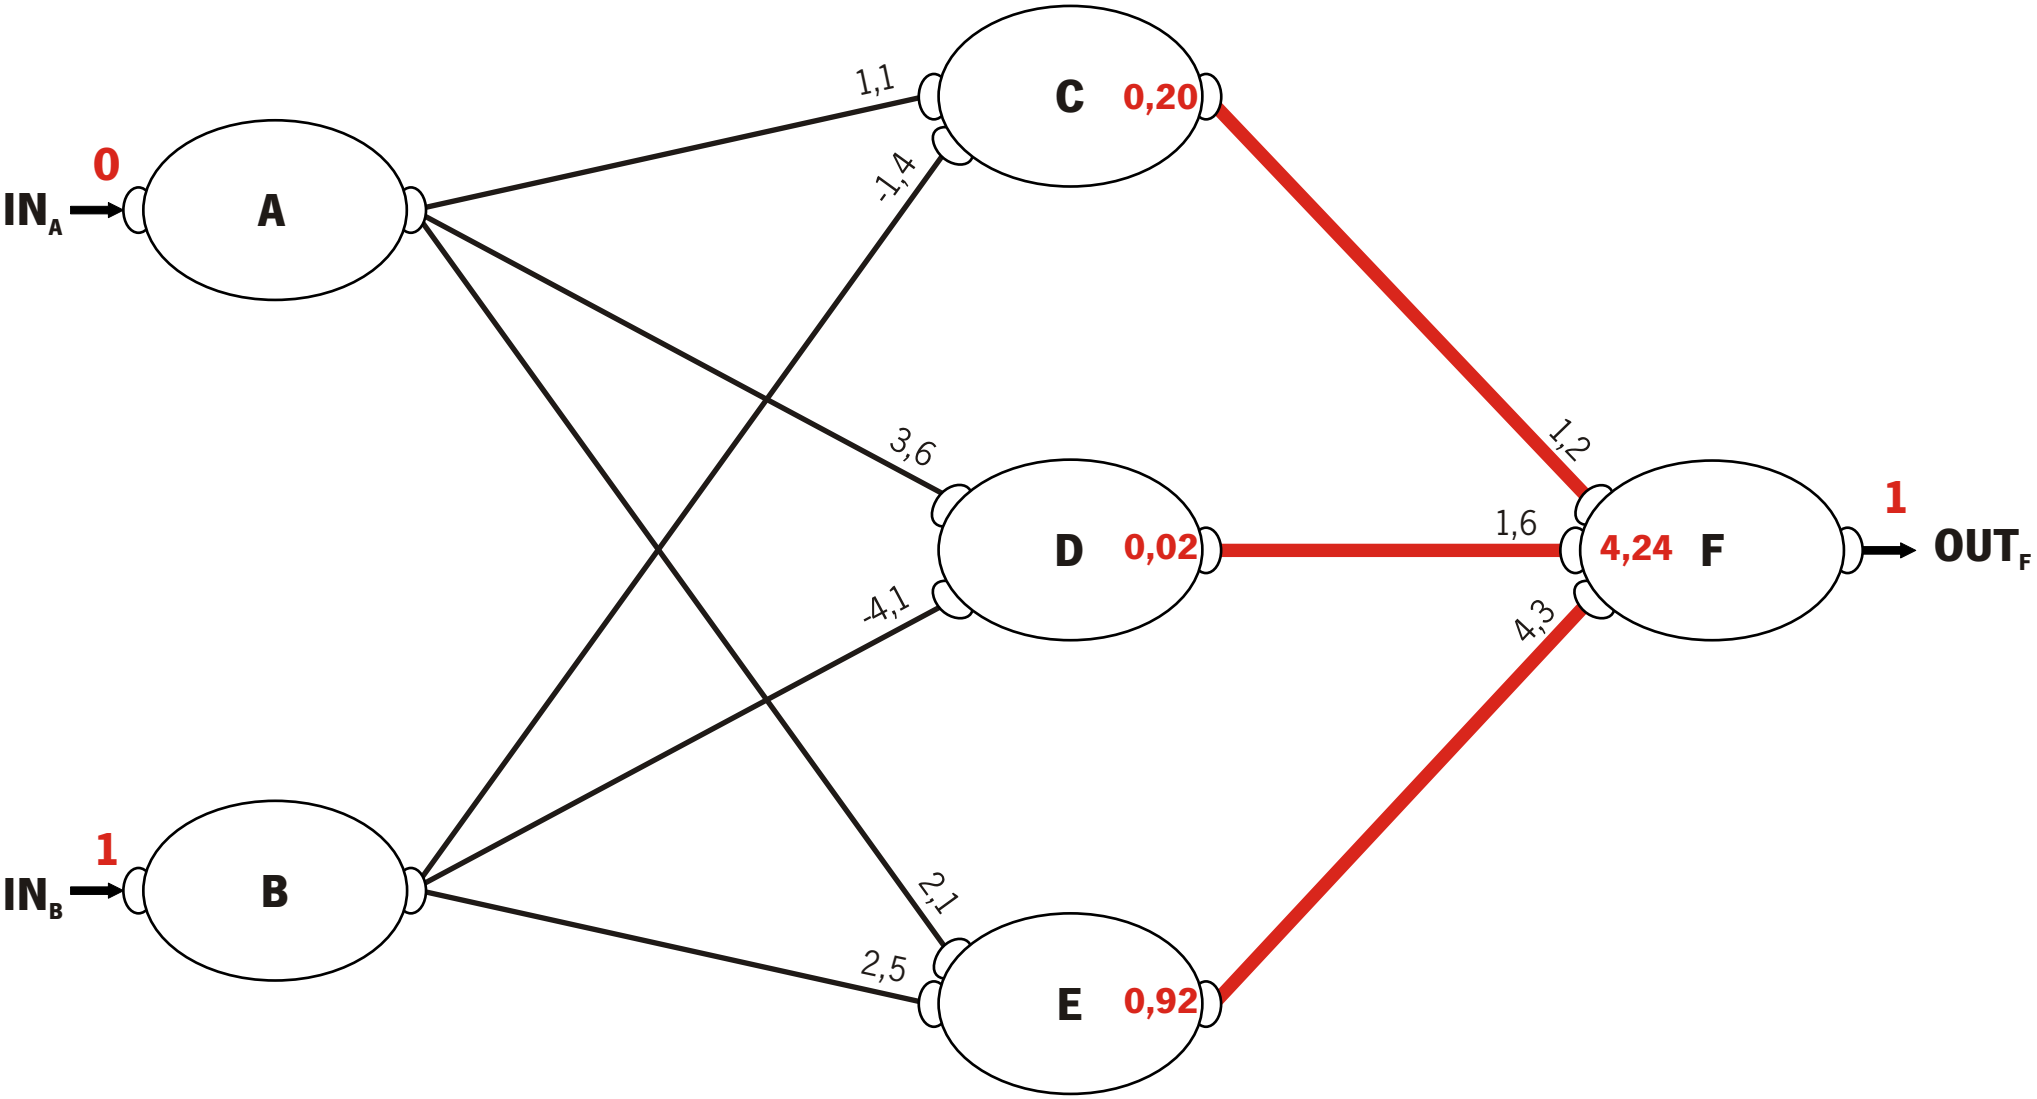

$$f_A(P,E) = \sum P \times E$$

$$f_T(A) = \frac{1}{1 + e^{-A}}$$

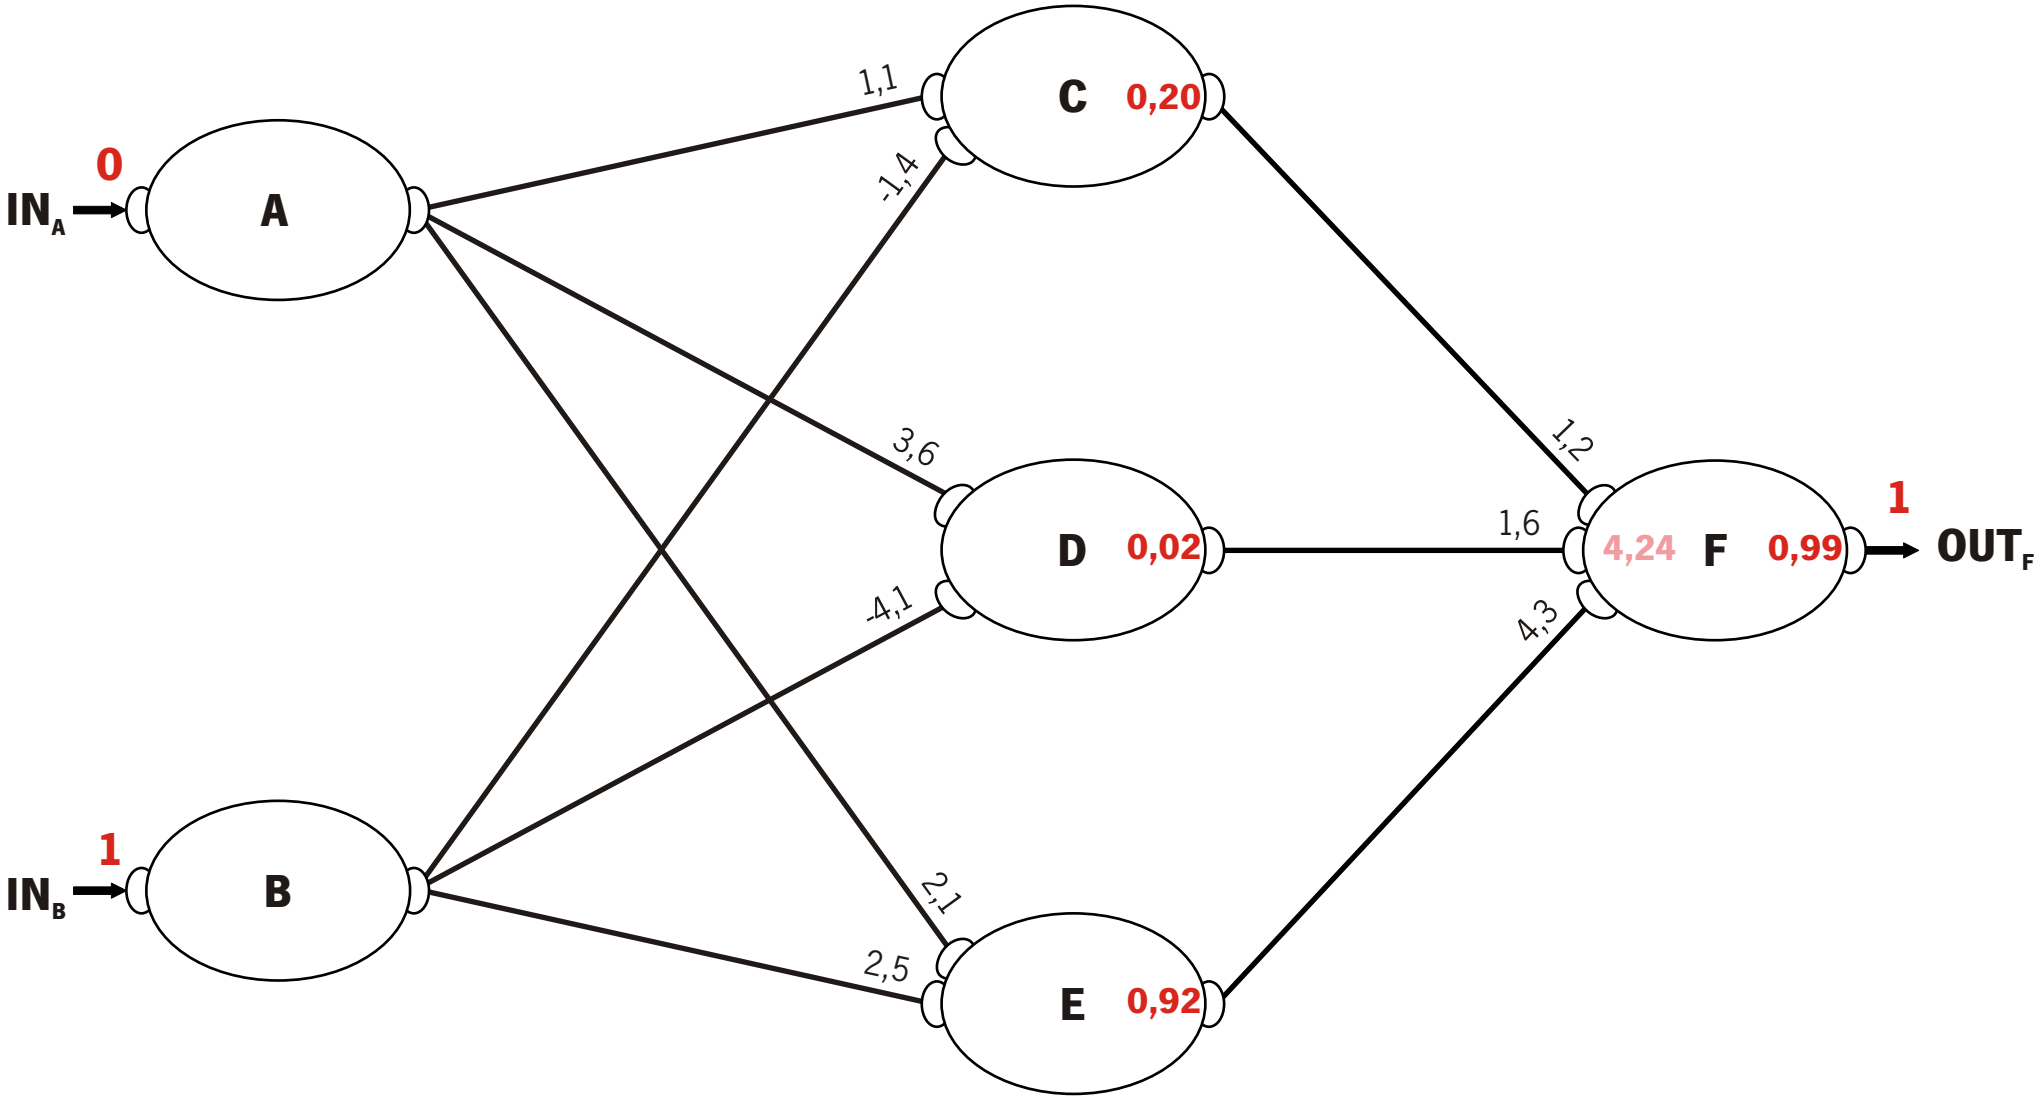

$$f_A(P,E) = \sum P \times E$$

$$f_T(A) = \frac{1}{1 + e^{-A}}$$

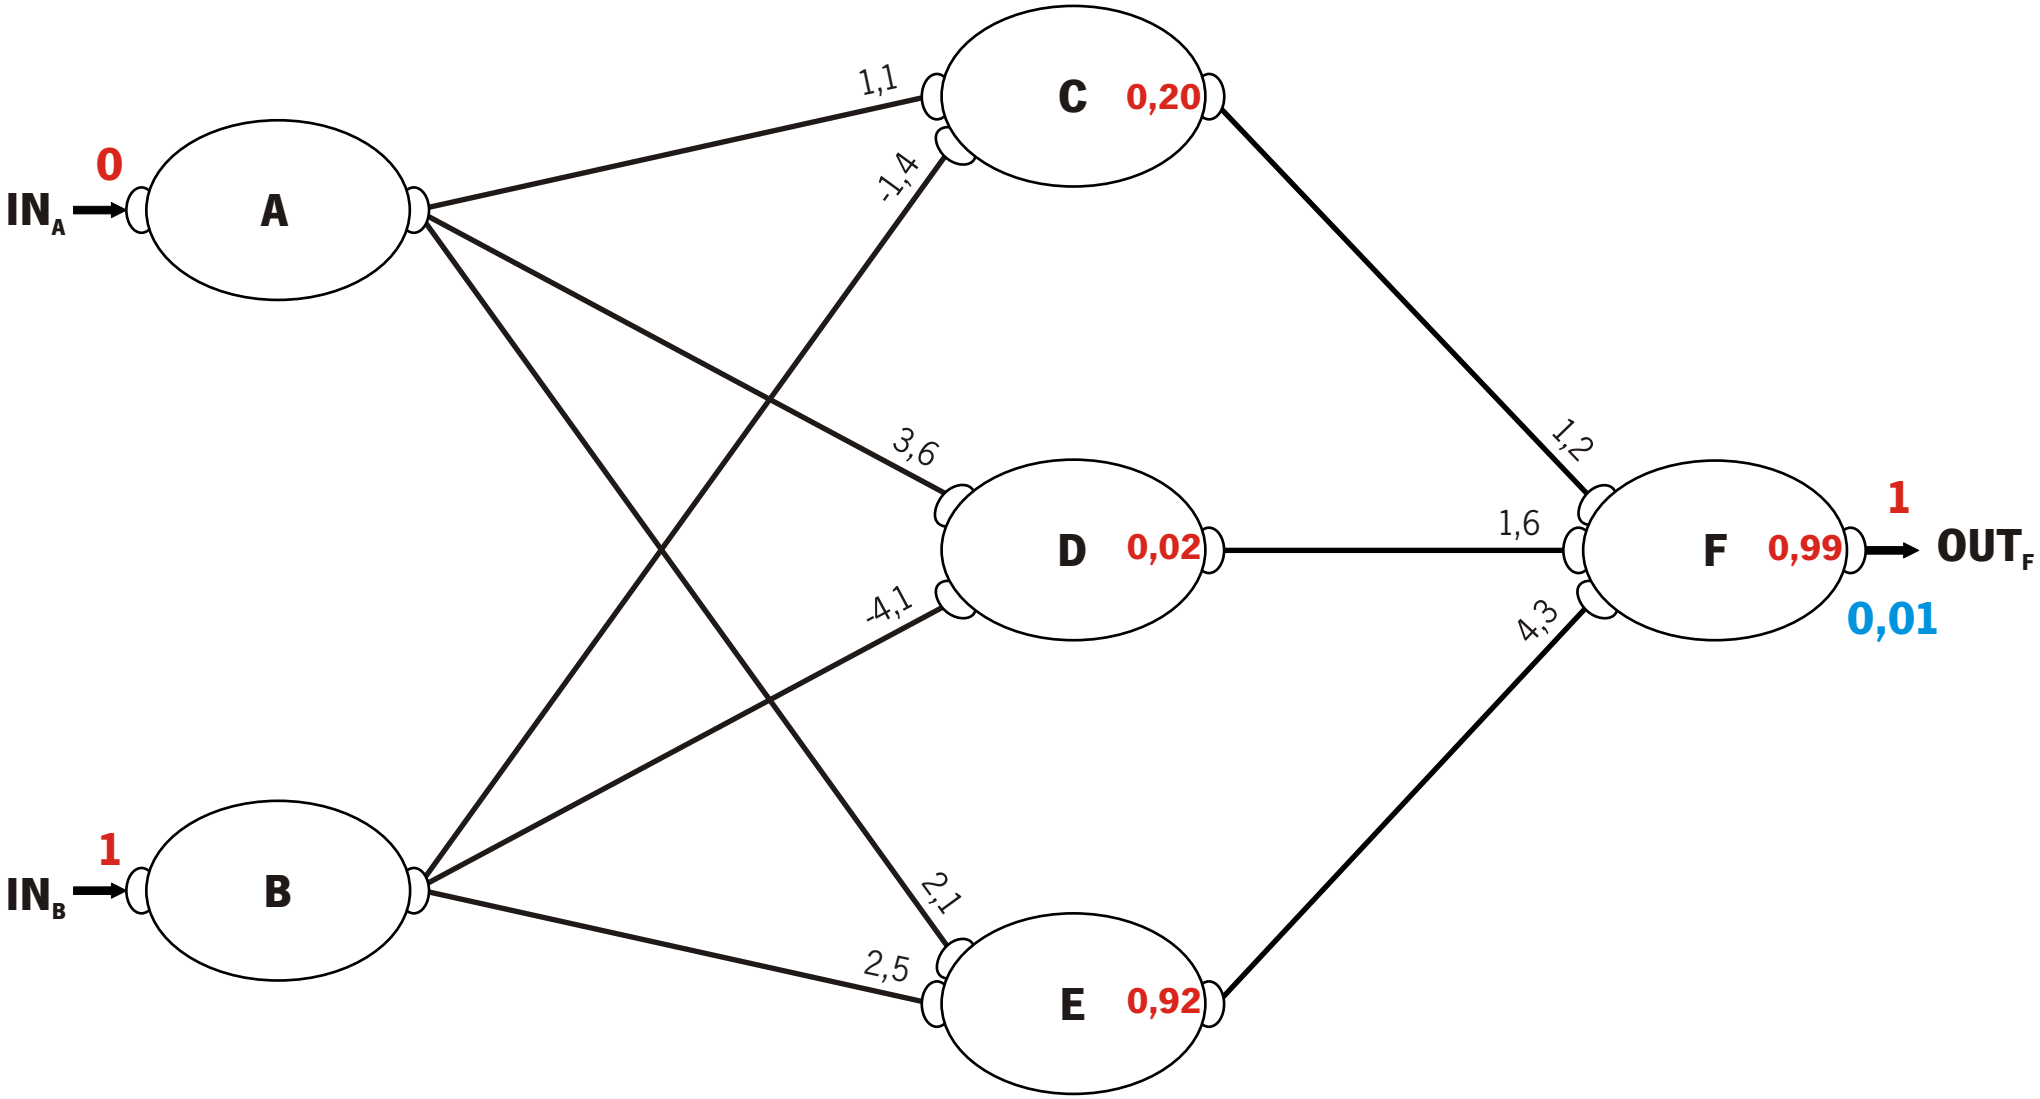

$$\varepsilon = OUT_{\mathcal{D}} - OUT_{C}$$

$$\varepsilon_{\leftarrow} = \varepsilon \times P$$

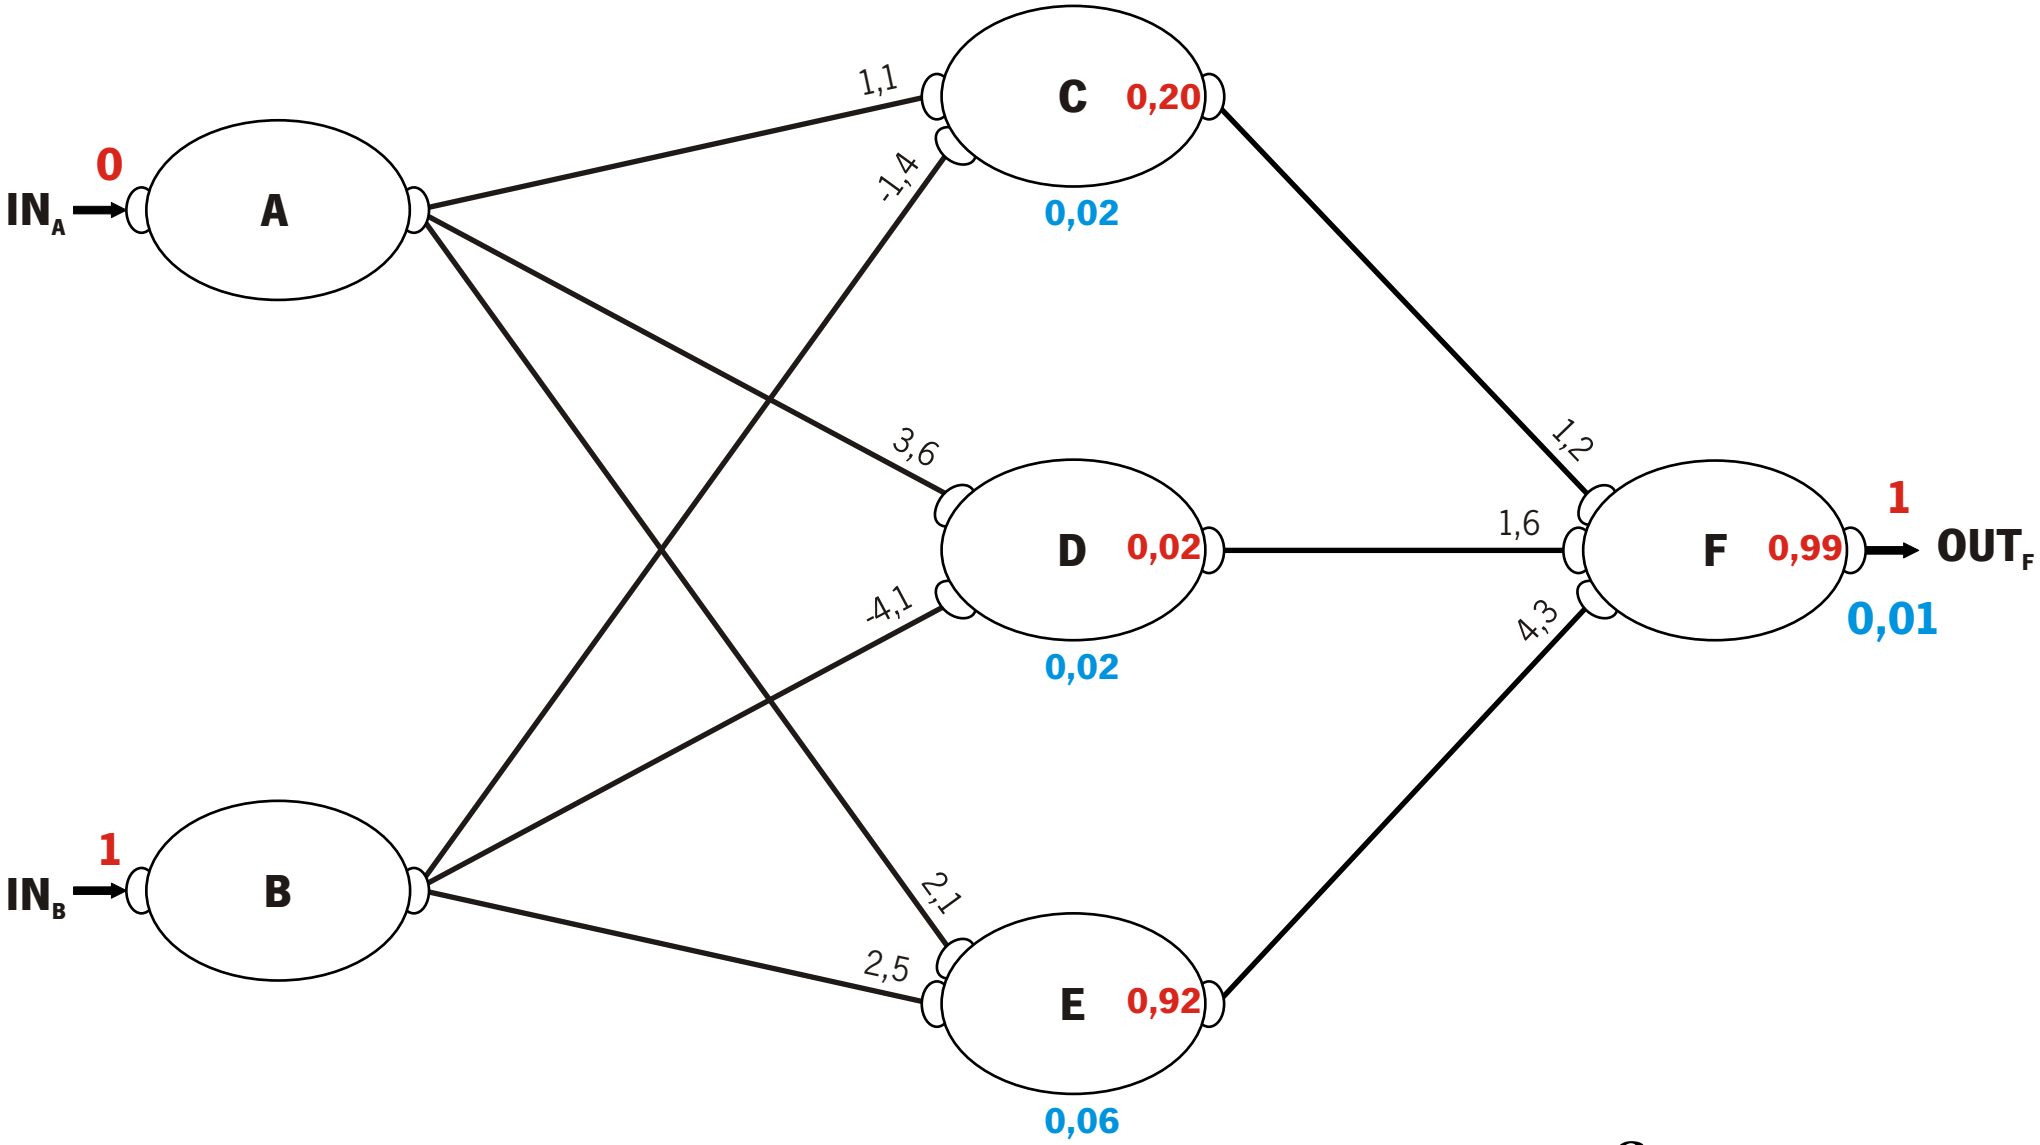

$$\varepsilon = OUT_{\mathcal{D}} - OUT_{C}$$

$$\varepsilon_{\leftarrow} = \varepsilon \times P$$

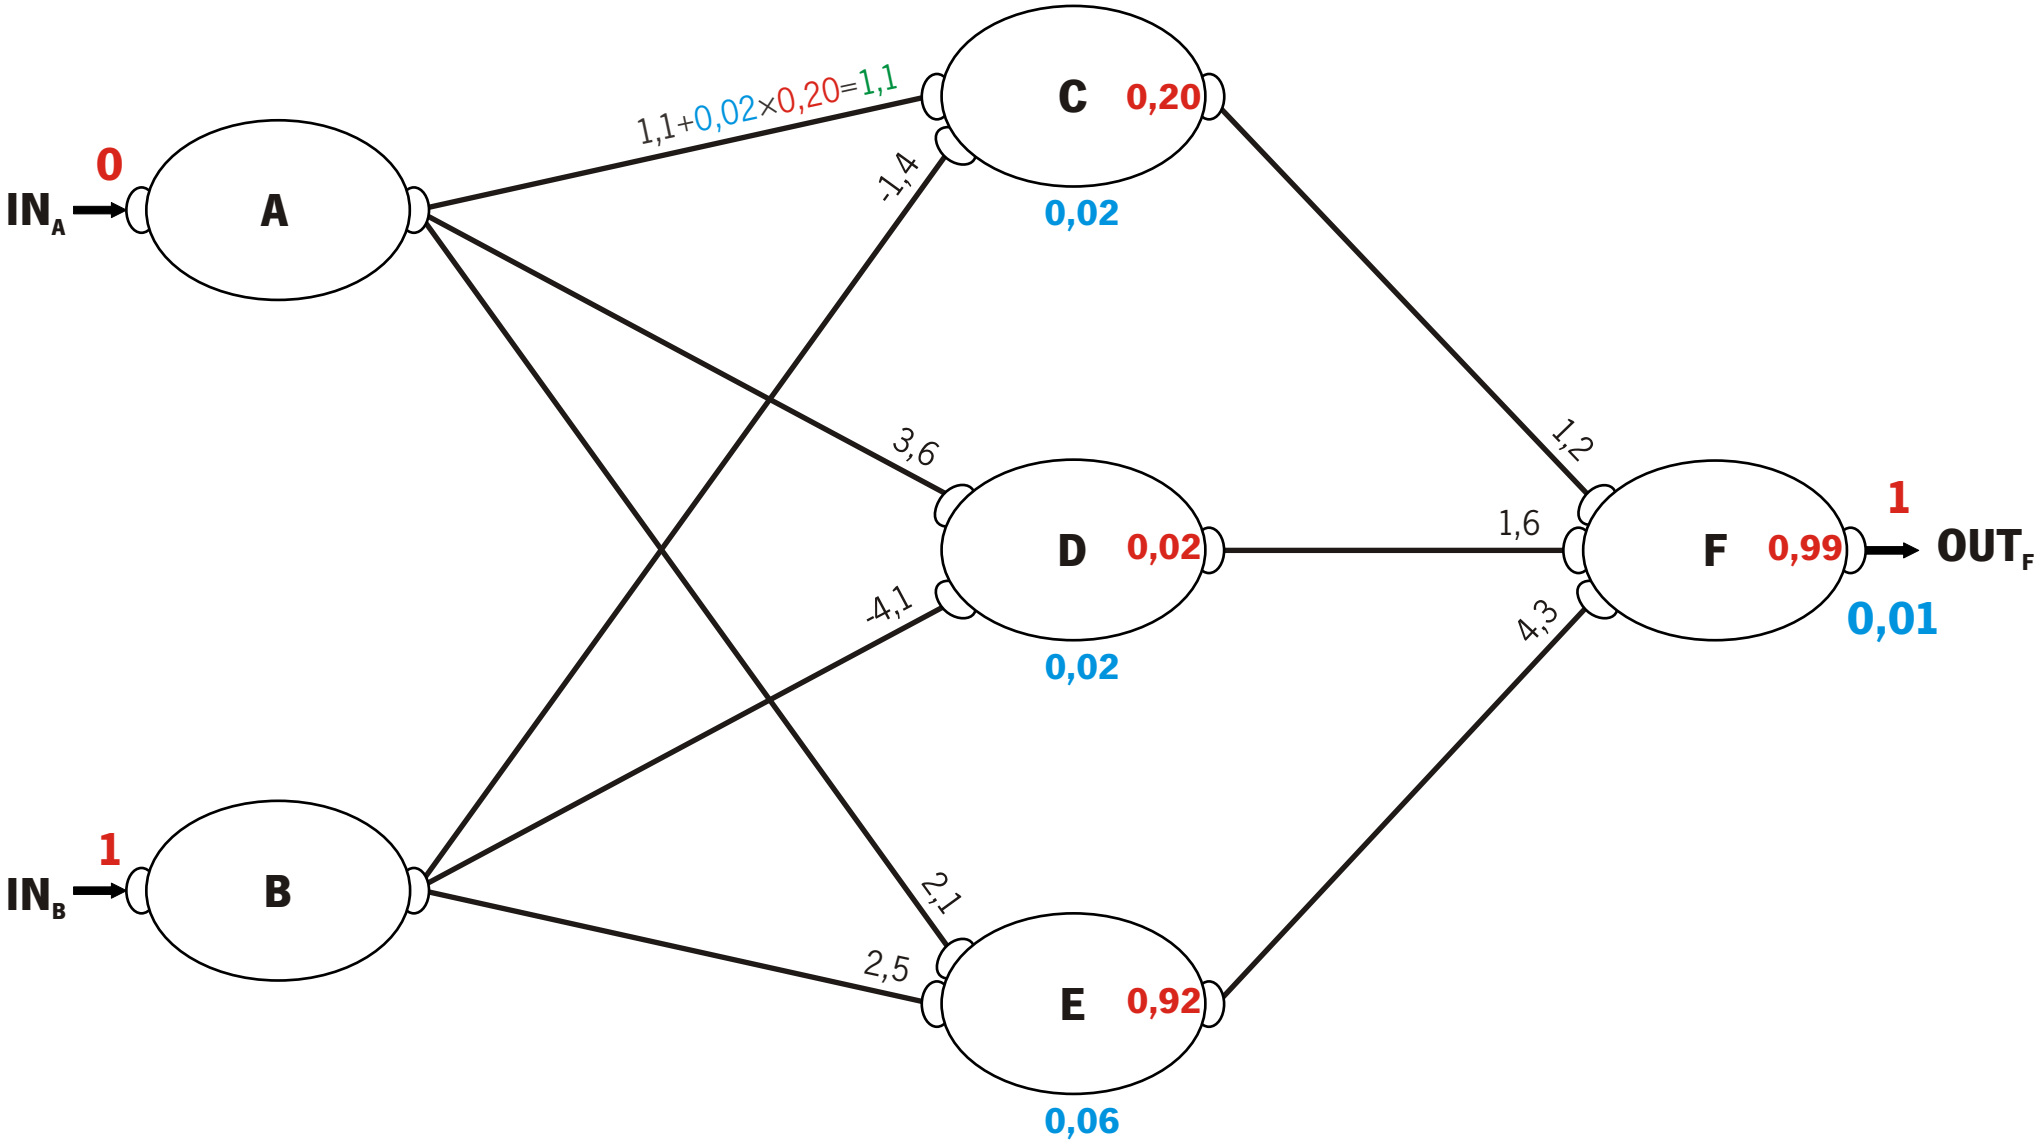

$$P_{i+1} = P_i + \varepsilon \times f_T$$

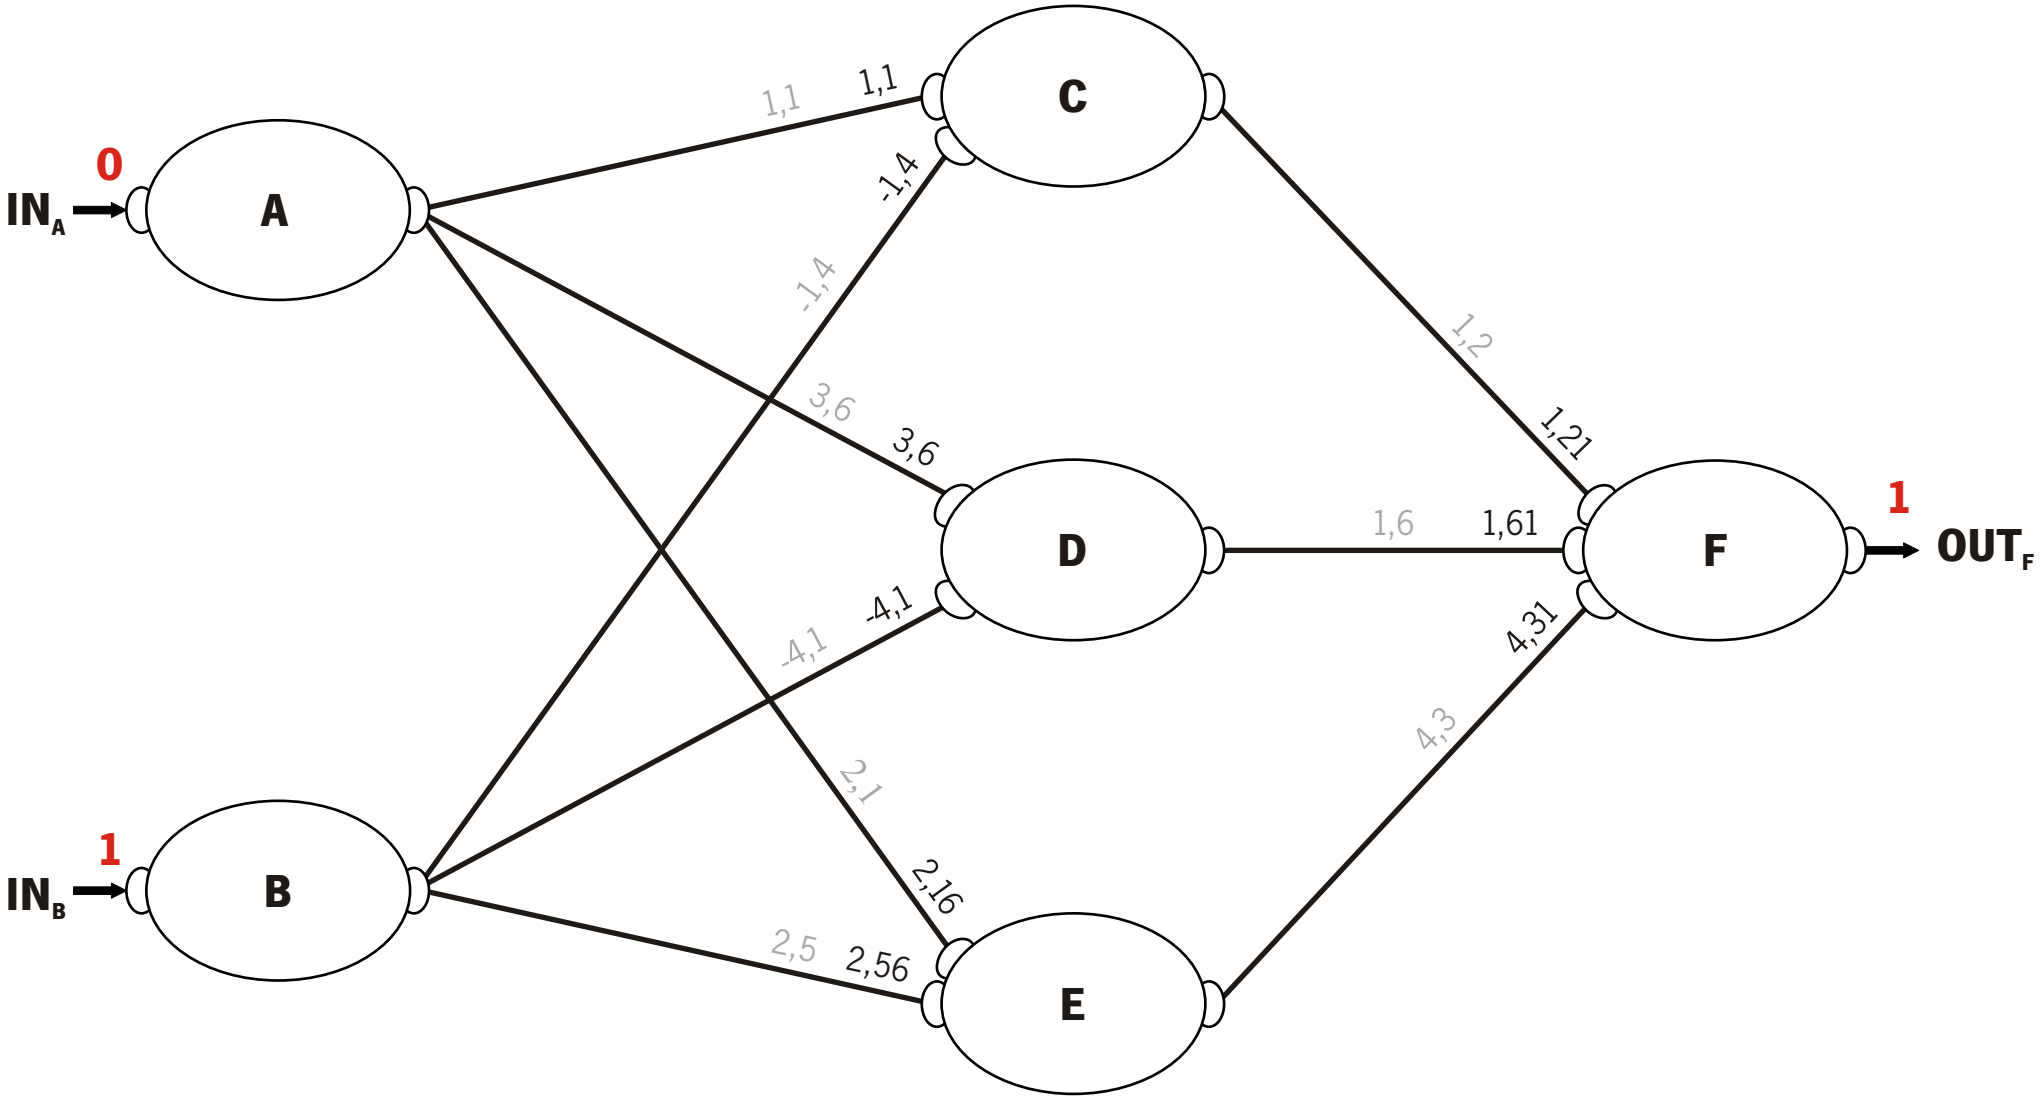

$$P_{i+1} = P_i + \varepsilon \times f_T$$

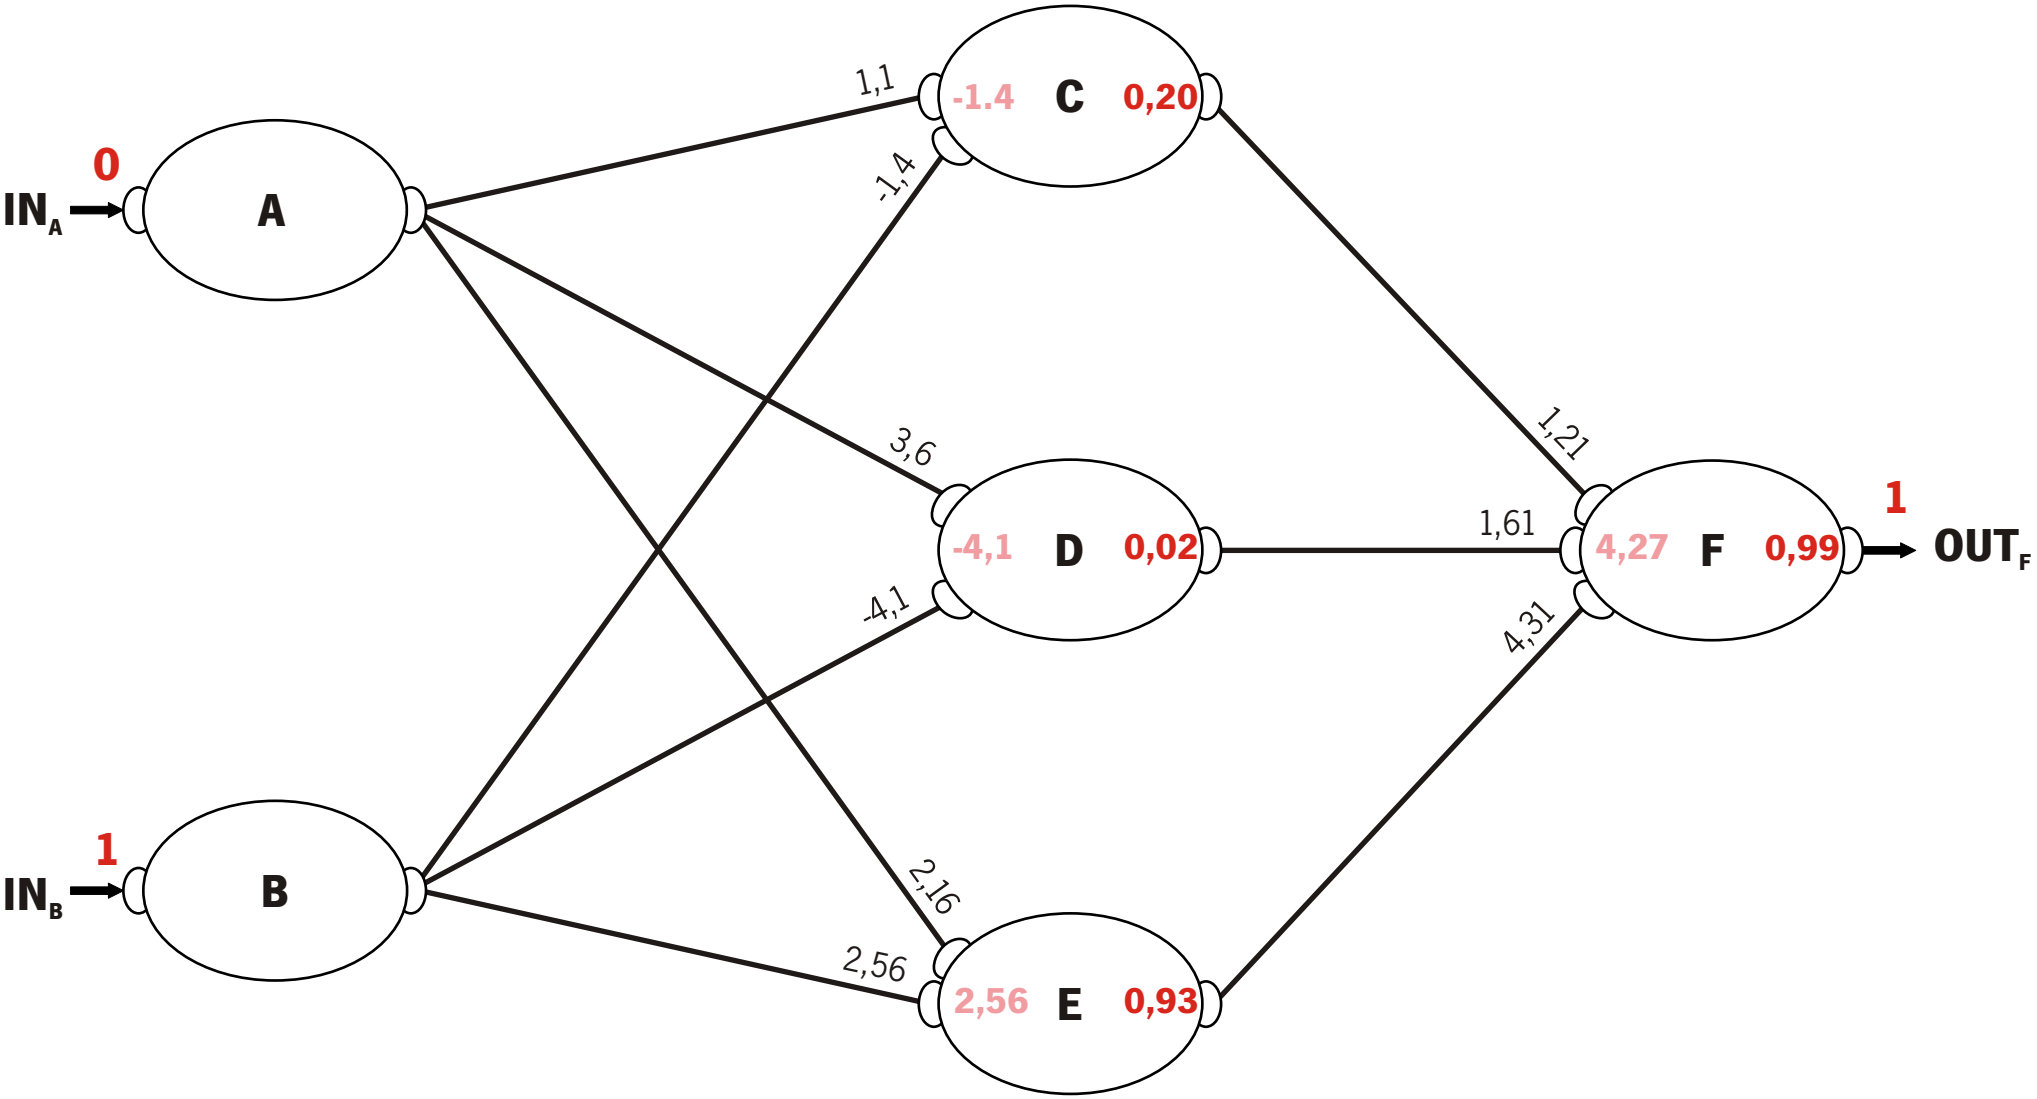

$$f_A(P,E) = \sum P \times E$$

$$f_T(A) = \frac{1}{1 + e^{-A}}$$

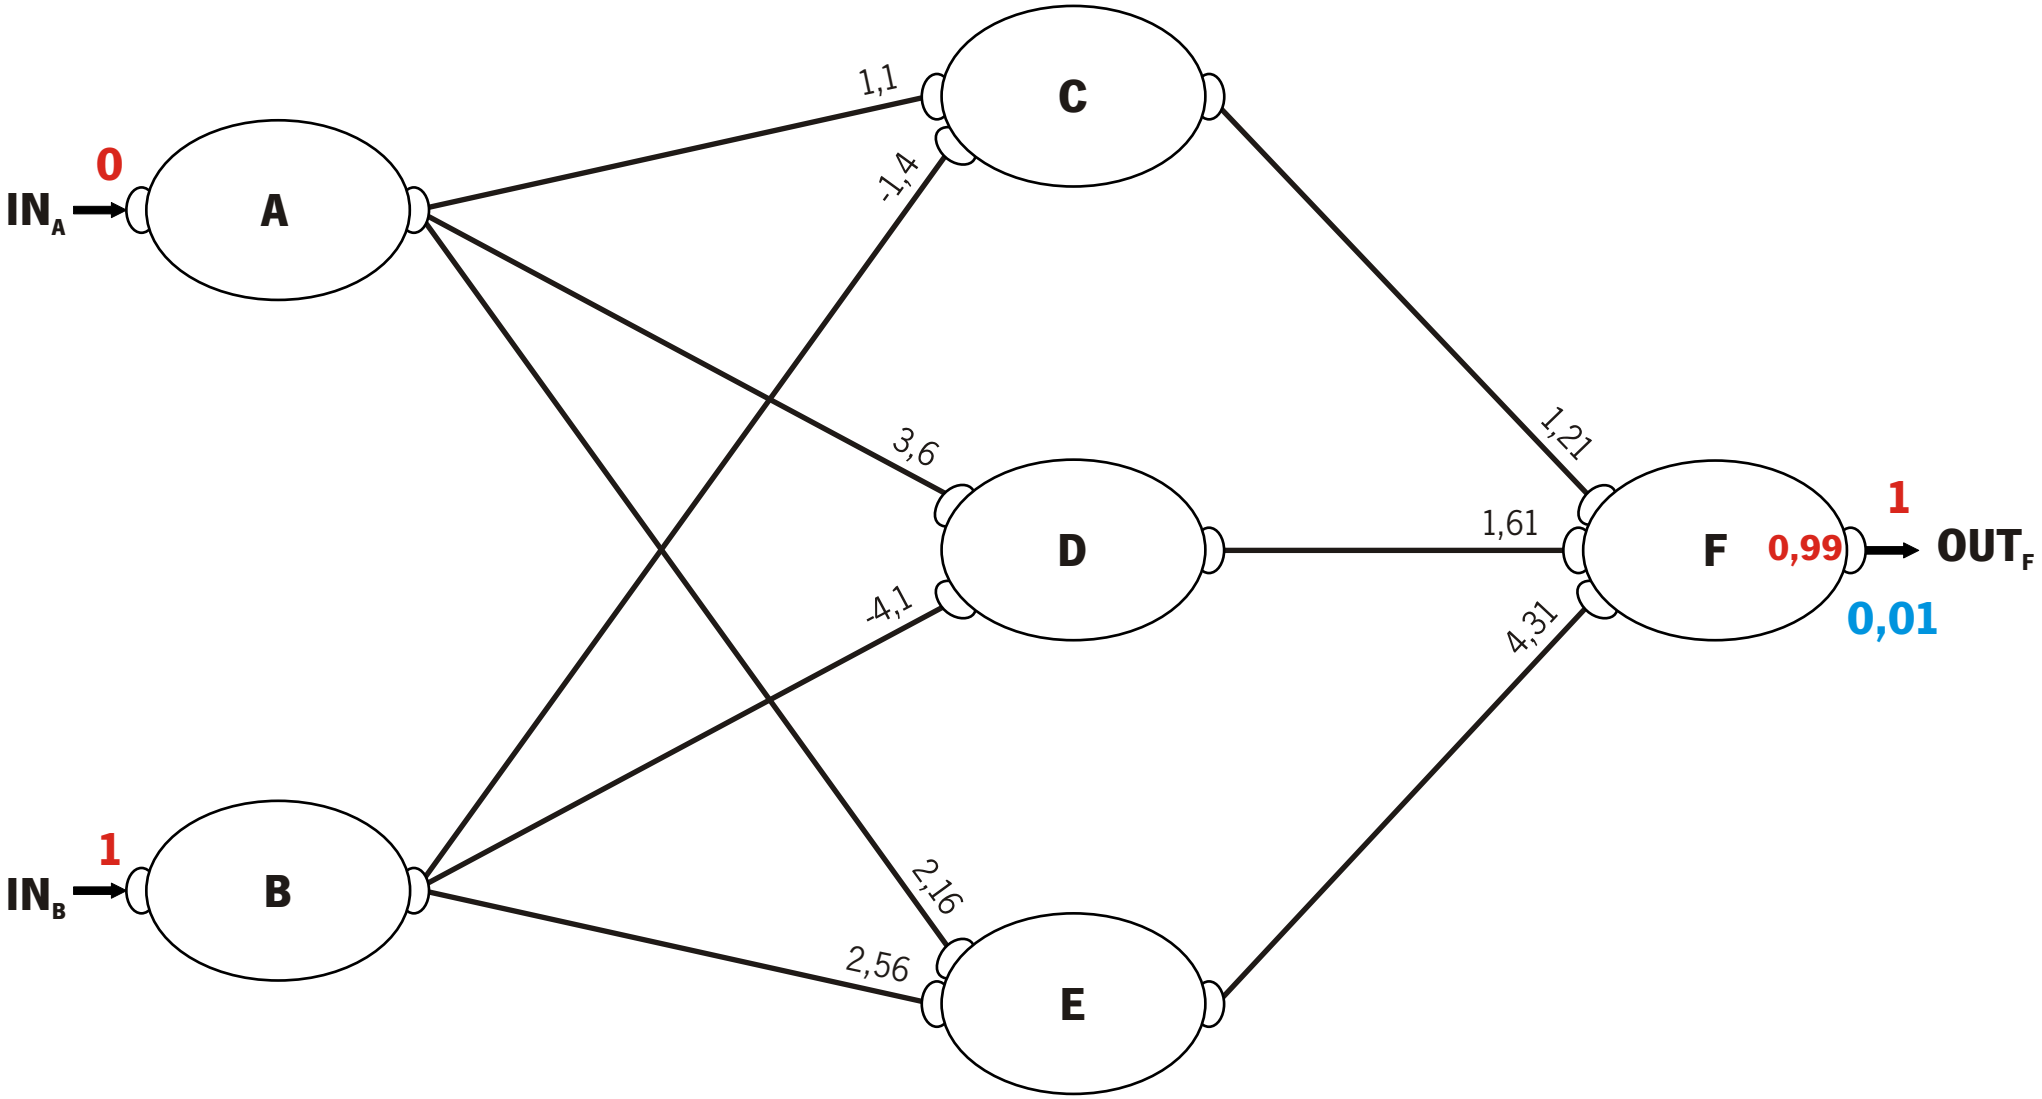

Universidade do Minho