

# Exploração de dados com KNIME

LEI/MiEI @ 2022/2023, 2º sem [ADI^3]



## **Agenda**

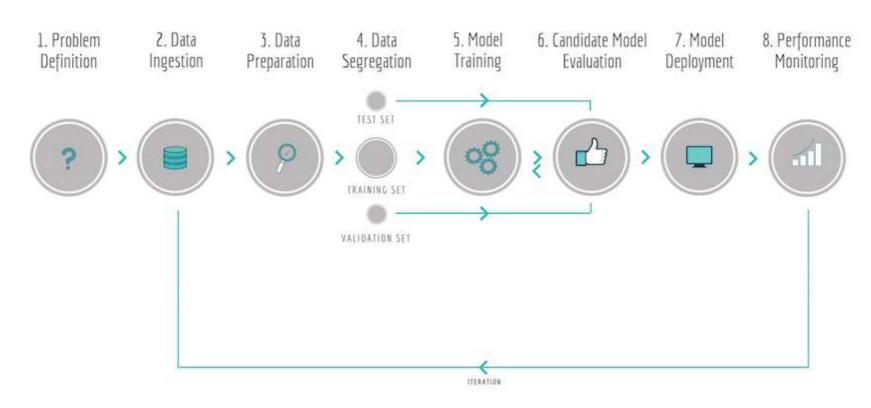
#### KNIME

- Bons hábitos
- Metanodos
- o Ingestão de dados
- Partição de dados
- Qualidade dos dados
- Exploração de dados
- Experimentação (hands on)





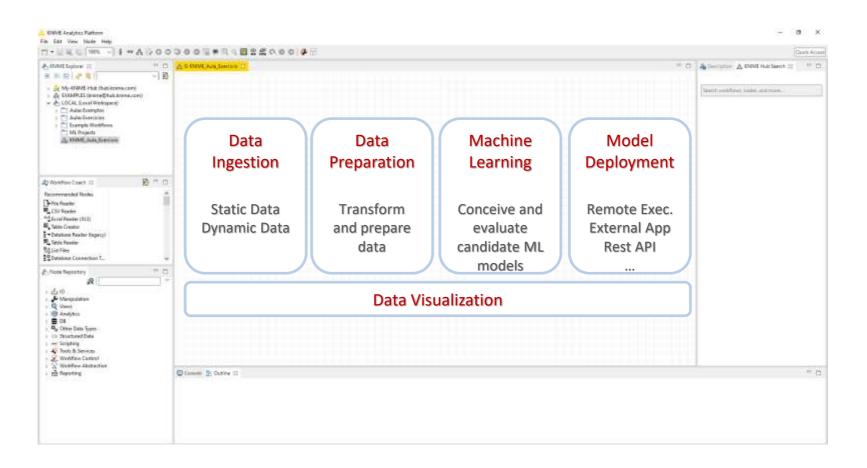
## **A Machine Learning Pipeline**



(https://towardsdatascience.com/architecting-a-machine-learning-pipeline-a847f094d1c7)

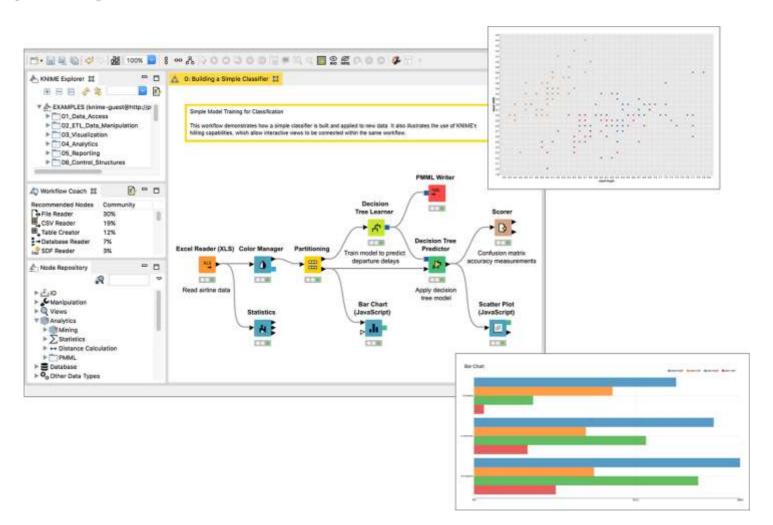


## Fluxo de Trabalho Típico @ Knime









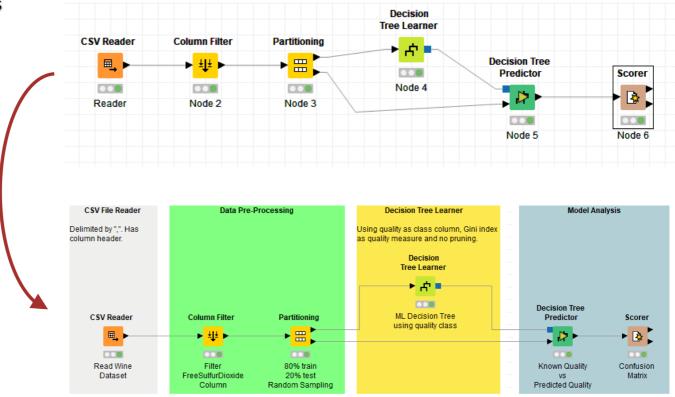


#### Bons hábitos

Dar novos nomes aos nodos

Adicionar anotações

Utilizar metanodos





- Um metanodo é um nodo com outros nodos dentro!
- Usar metanodos para organizar o trabalho!

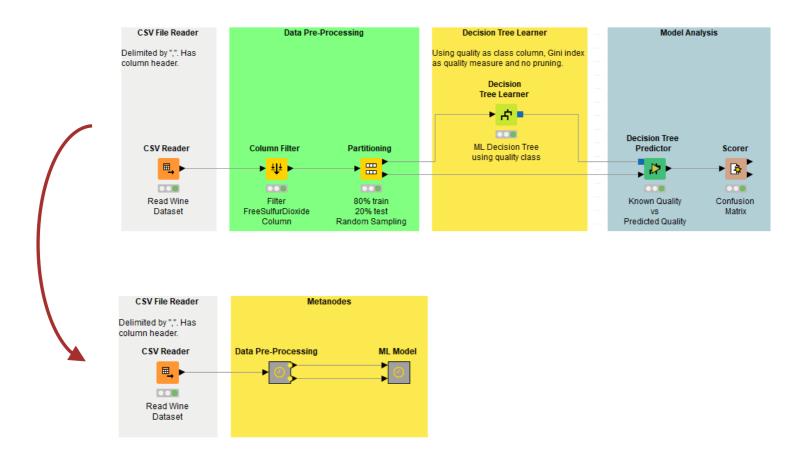




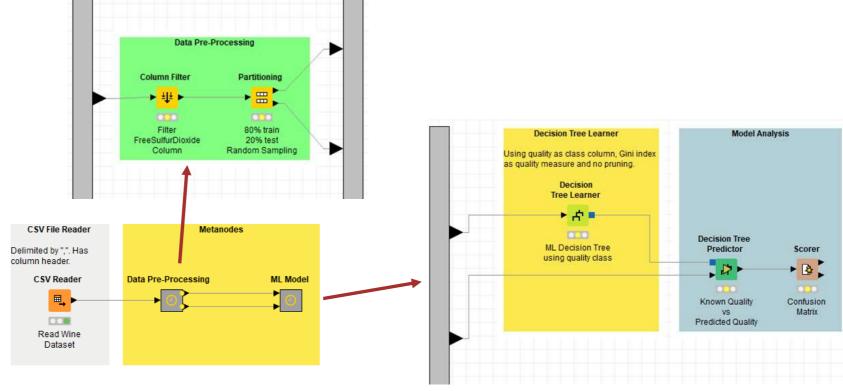
- Um metanodo é um nodo com outros nodos dentro!
- Usar metanodos para organizar o trabalho!





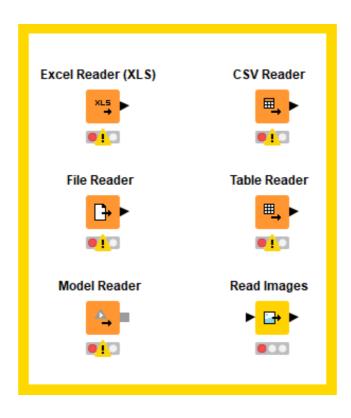








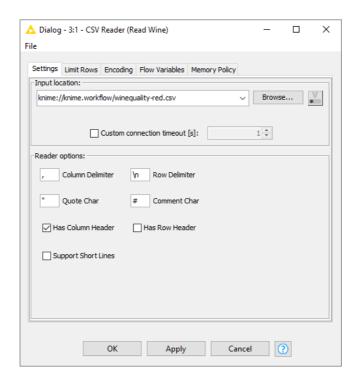
# **Ingestão de dados KNIME Data Readers**





## Ingestão de dados KNIME Data Readers







#### File Reader





#### A Dialog - 3:9 - File Reader Settings Flow Variables Memory Policy Enter ASCII data file location: (press Enter' to update preview) Browne... knime://knime.workflow/winequality-red.csv Preserve user settings for new location Rescan Basic Settings Tread row IDs Column delimiter: Advanced... read column headers gnore spaces and tabs Ava-style comments Single line comment: Preview Click column header to change column properties (\* = name/type user settings) D fixed a... D voletile ... D citric and D residual... D chlorides D free sul... D to 134 0.7 11 0.88 67 0.098 Row2 7.8 0.76 2.3 0.092 15 54 0.04 0.28 0.56 1.9 0.075 60 0.7 34 1.9 0.075 0.075 40 0.6 0.06 0.069 59 Row7 7.3 0.65 1.2 0.065 21 18 0:58 0.02 0.073 0.5 0.36 0.071 102 0.58 0.08 1.8 65 0.097 Row11 0.5 0.36 6.1 0.071 102 0.615 Row12 199 7.8 0.61 0.29 1.6 0.114 29 8.9 0.62 0.18 3.8 0.175 Row14 145 Row15 8.9 0.62 0.19 3.9 0.17 51 148 Row 16 0.28 0.56 1.8 0.092 103 0.56 0.29 1.7 56 0.368 7.4 0.59 0.08 4.4 0.085 29 Row19 7.9 0.32 0.51 1.8 0.341 56 Row20 0.22 0.48 1.8 0.077 60 Row21 0.39 0.31 2.3 71 0.082 Row22 0.43 0.21 1.6 37 0.106 67 Row23 8.5 0.49 0.11 0.084 Row24 0.4 2.4 40. 6.9 0.14 0.085 Cancel (2)

## Ingestão de dados KNIME Data Readers



#### Excel Reader (XLS)



#### Dialog - 2:7 - Excel Reader (XLS) (Read Calls data) XLS Reader Settings Flow Variables Memory Policy Select file to read: U Browse ... krime://knime.workflow/CallsData.xls Adjust Settings: 5 0 Select the sheet to read: <first sheet with data> Connect timeout [s]: Table contains column names in row number: 1 (Ross numbers start with 1. Mouse over header to see row number.) Row IDs: (a) Generate RowIDs (index incrementing, starting with RowID) (index as per sheet content, skipped rows will increment index) Table contains row IDs in column: A Make my Elsurage Select the columns and rows to read: Read entire data sheet, or ... read columns from: A and read rows from [1] Tip: Mouse over the column and row headers in the "File Content" tab to identify cell coordinates On evaluation error: (a) Brosert an error patterns: #XL\_EVAL\_ERROR # ( ) Insert a missing cell More Options: Skip empty columns Reevaluate formulas (leave unchecked if uncertain; see node description for details) Skip hidden columns Disable Preview (does not compute the output table structure) Skip empty rows Preview File Content Preview with current settings: CalsData.xls [ChumDataset] refresh Row ID I Wal M ... D Day Mins D Eve Mins D Night Mins D Int Mins 1 CustSe... | Day Calls | D Day Ch... I Eve € 265.1 197.4 244.7 110 45.07 161.6 195.5 254.4 27,47 183 243.4 12.2 41.38 121.2 152.6 114 130 299.4 61.9 196.9 71 50.9 10.1 166.7 148.3 186.9 28.34 223.4 220.6 203.9 6.3 37.98 101 218.2 348.5 212.6 37.09 108 157 103.1 211.8 7.1 26.69 184.5 351.6 31.37 258.6 326.4 43.96 111 Row 10 129.1 228.5 208.8 12.7 21.95 83 Row11 187.7 163.4 196 9.1 127 31.91 148 128.8 1844 141.1 31.0 Cancel

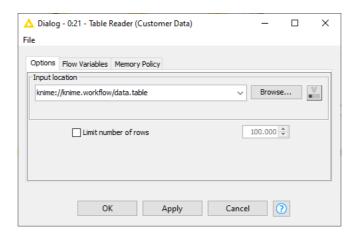
## ngestão de dados *ME Data Readers*



## Ingestão de dados KNIME Data Readers

Table Reader



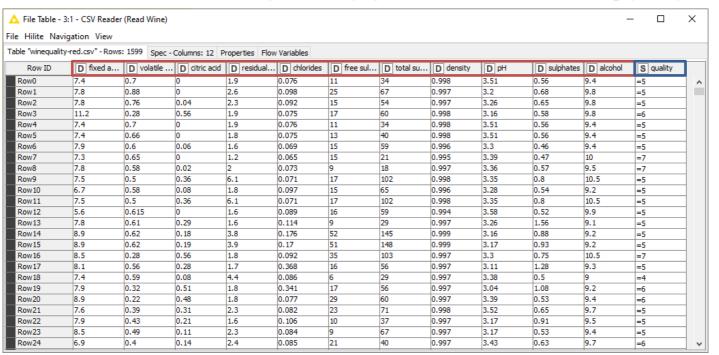




## **Dados Carregados**

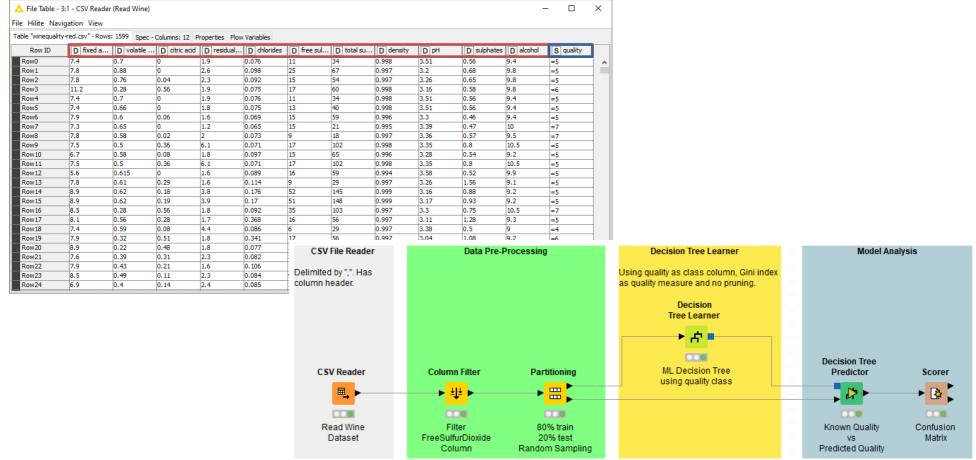
#### Input Features/Input Vector

#### Target/Class/Label





## Partição de dados





## Partição de dados

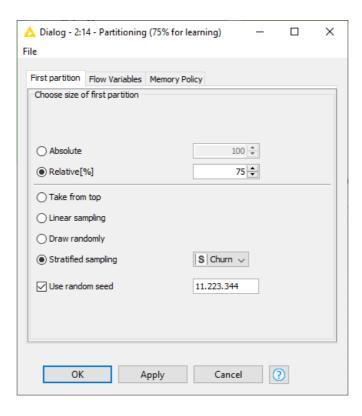
- Construção de um modelo supervisionado de ML
  - o Usar um *dataset* de treino para treinar um modelo
    - Aprendizagem
  - Usar um dataset de teste para testar o modelo
    - Avaliar o modelo com dados "não vistos" durante o treino
  - Usar um dataset de validação (aconselhável)
    - Promove uma validação sem viés de um modelo sobre o dataset de treino enquanto se afinam os hiperparâmetros





## Partição de dados







## Exploração dos dados

#### Porquê?

- o Compreender os dados e as suas características
- Analisar e avaliar a qualidade dos dados
- Perceber padrões e informações relevantes



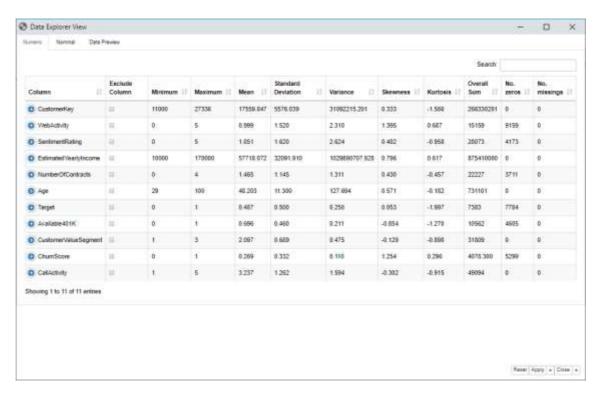
## Exploração dos dados

#### Como?

- Tendências centrais:
  - average, mode, median...
- Dispersão estatística
  - variance, standard deviation, interquartile range...
- Distribuição de probabilidades
  - · Gaussian, Uniform, Exponential...
- Correlação/Dependência
  - between pairs of features, with the dependent feature...
- Visualização de dados
  - tables, charts, boxplots, scatter plots, histograms, ...



## Exploração de dados KNIME Data Explorer Node









## Exploração de dados KNIME Data Explorer Node

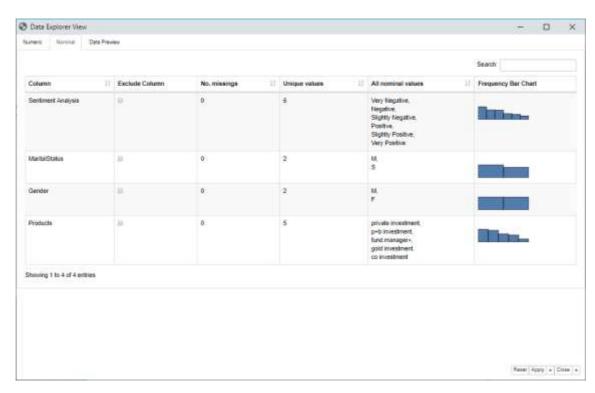








## Exploração de dados KNIME Data Explorer Node

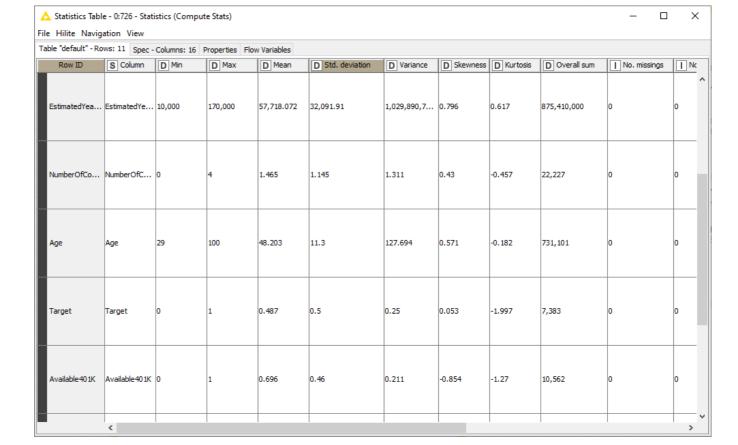








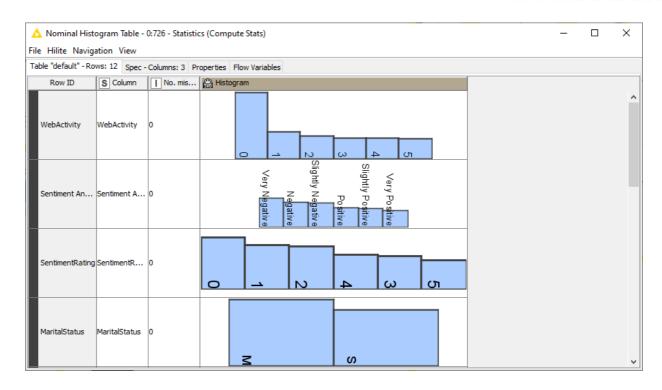
## Exploração de dados KNIME Statistics Node

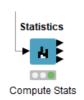






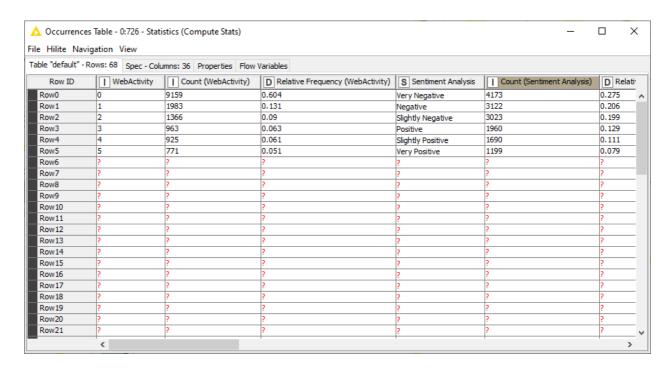
## Exploração de dados KNIME Statistics Node







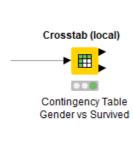
## Exploração de dados KNIME Statistics Node







# **Exploração de dados KNIME Contingency Tables**

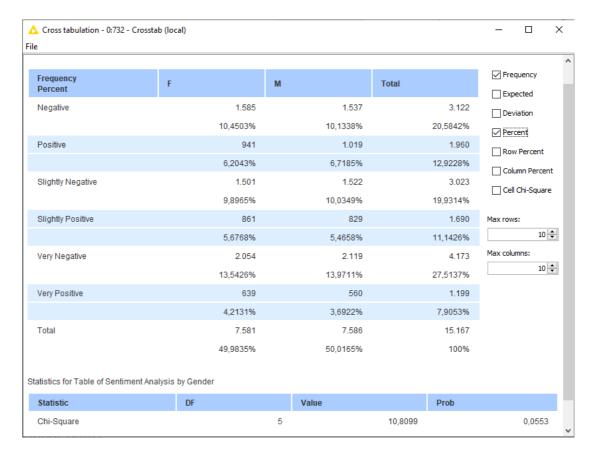






## Exploração de dados KNIME Contingency Tables

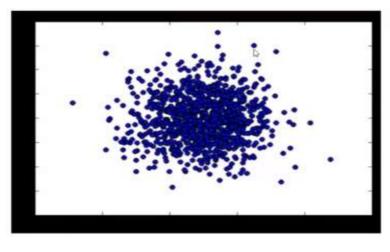


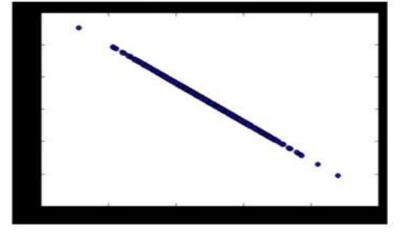




## Covariância

A covariância mede quanto duas variáveis (atributos, colunas, features) dependem uma da outra





(baixa covariância)

(alta covariância)



### Covariância

#### Calcular a covariância:

- o Considere os dados das duas variáveis como vetores de alta dimensão;
- o Converta-os em vetores de variâncias da média;
- o Calcule o produto escalar (cosseno do ângulo entre eles) dos dois vetores;
- Divida pelo tamanho da população;

#### Population Covariance Formula

$$Cov(x,y) = \frac{\sum (x_i - \overline{x})(y_i - \overline{y})}{N}$$

#### Sample Covariance

$$Cov(x,y) = \frac{\sum (x_i - \overline{x})(y_i - y)}{N-1}$$



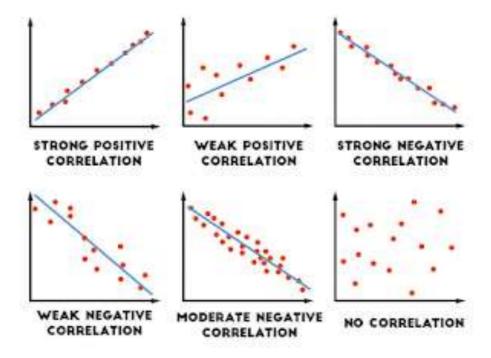
## Covariância & Correlação

- Interpretar a covariância é difícil:
  - o Baixa covariância (próxima de 0) significa que não há muita correlação entre as duas variáveis;
  - o Alta covariância (muito superior a 0, ou negativa para relações inversas) significa que existe uma correlação entre as variáveis;
- Interpretar a correlação é mais fácil:
  - Valor de normalização da covariância dividido pelos desvios padrão de ambas as variáveis:
    - Correlação = -1: correlação inversa perfeita
    - Correlação = 0: sem correlação
    - Correlação = 1: correlação perfeita



## Correlação

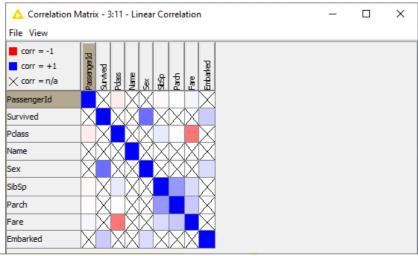
- Mas... a correlação não implica causalidade!!!
  - o Apenas uma experiência controlada e aleatória pode fornecer informações sobre a causalidade;
  - o Use a correlação para decidir quais as experiências a realizar.

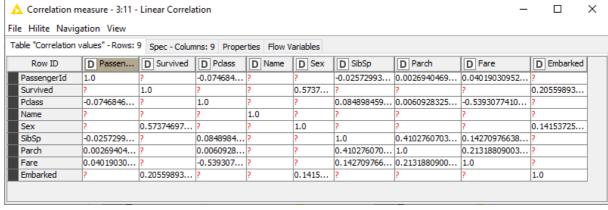




# Linear Correlation

## Matriz de Correlação





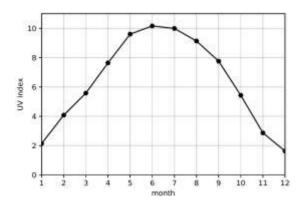


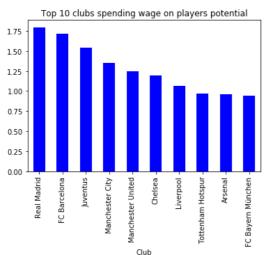
## Matriz de Correlação

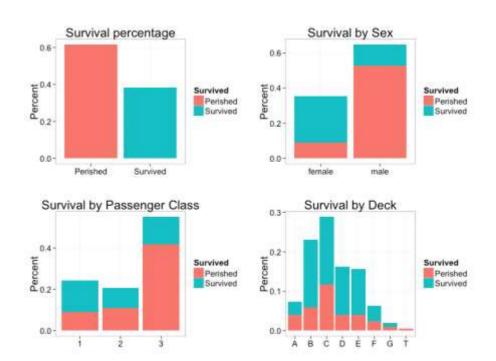
- Queremos manter atributos (features) altamente correlacionados?
- Ambos positivos e negativamente correlacionados?
- E quanto à correlação entre os atributos dependentes e independentes?
- ..



## Visualização de Dados









## Visualização de Dados

